

Sei  $\Sigma = \{a, b, c, d, e\}$ . Finden Sie Sprachen  $\emptyset \subsetneq L_1 \subseteq L_2 \subseteq L_3 \subsetneq \Sigma^*$ , so dass

- (a)  $L_1$  kontextfrei, aber nicht regulär,
- (b)  $L_2$  regulär und
- (c)  $L_3$  nicht kontextfrei ist.

LÖSUNG: (a) Sei  $L_1 = \{a^n b^n \mid n \geq 0\}$ . Diese Sprache ist kontextfrei, da Sie von folgender kontextfreier Grammatik erzeugt wird:  $G = (\{S\}, \{a, b\}, \{S \rightarrow aSb, S \rightarrow \epsilon\}, S)$ . Aber  $L_1$  nicht regulär. Sei  $n \in \mathbb{N}$  beliebig, aber fest. Sei  $x = a^n b^n$ ,  $x \in L_1$  und  $|x| \geq n$ . Für alle möglichen Zerlegungen  $x = uvw$  mit  $|v| \geq 1$  und  $|uv| \leq n$  gilt:  $\exists k \geq 0, j \geq 1 : u = a^k, v = a^j, w = a^{n-j} b^n$  mit  $j + k \leq n$ . Nun ist  $uv^2w = a^{n+j} b^n \notin L$  da  $j \geq 1$  ist. Folglich kann nach Pumping-Lemma  $L_1$  nicht regulär sein.

(b) Sei  $L_2 = \{a^n b^m \mid n, m \geq 0\}$ . Offensichtlich gilt  $L_1 \subseteq L_2$ .  $L_2$  ist regulär, da folgender endlicher Automat  $L_2$  erkennt:  $A = (\{q, p\}, \{a, b\}, \delta, q, \{q, p\})$  mit  $\delta(q, a) = \{q, p\}, \delta(p, a) = \delta(q, b) = \emptyset, \delta(p, b) = \{p\}$ .

(c) Sei  $L_3 = \{a^n b^m c^l d^l e^l \mid n, m, l \geq 0\}$ . Offensichtlich gilt  $L_2 \subseteq L_3$ .  $L_3$  ist nicht kontextfrei. Angenommen  $L_3$  ist kontextfrei. Dann müsste die Konklusion des Pumping-Lemmas für kontextfreie Sprachen gelten. Sei  $n \geq 0$  beliebig aber fest. Dann ist  $w = c^n d^n e^n \in L_3$  und  $|w| \geq n$ . Nun gilt für alle Zerlegungen  $w = uvxyz$  mit  $|vxy| \leq n$  und  $|vy| \geq 1$ , dass in  $vxy$  nicht  $cs$ ,  $ds$  und  $es$  sein können. Also kann  $uv^2xy^2z$  nicht aus  $L_3$  sein, da es nicht mehr gleich viele  $cs$  wie  $ds$  wie  $es$  enthält.



## Wikipedia: Chomsky - Normalform

Eine formale Grammatik  $G = (V, \Sigma, P, S)$  ist in Chomsky - Normalform, wenn jede Produktion aus  $P$  eine der folgenden Formen hat:

- $A \rightarrow BC$
- $A \rightarrow a$
- $S \rightarrow \epsilon$

wobei  $A, B$  und  $C$  Nichtterminalsymbole aus  $V$  sind und  $a$  ein Terminalsymbol aus  $\Sigma$  ist.  $S$  ist das Startsymbol und  $\epsilon$  das leere Wort. Wenn die Produktion  $S \rightarrow \epsilon$  zur Grammatik gehört, dann darf  $S$  nicht auf der rechten Seite einer Produktion stehen.

Läßt man bei der ersten Produktion auf der rechten Seite beliebig viele anstatt zwei Nichtterminalsymbole zu, so spricht man von einer schwachen Chomsky - Normalform.

Konstruktion:

Liegt eine kontextfreie Grammatik  $G = (V, \Sigma, P, S)$  vor, so läßt sich daraus schrittweise eine Grammatik  $G'$  in Chomsky - Normalform generieren, die dieselbe Sprache erzeugt.

1) Ausnahme  $S \rightarrow \epsilon$  behandeln

Enthält die Grammatik  $G$  die Regel  $S \rightarrow \epsilon$ , wird ein neues Startsymbol  $S'$  für  $G'$  eingeführt. Anschließend erhält die neue Grammatik die Regeln  $S' \rightarrow \epsilon$  und  $S' \rightarrow S$ . Damit ist sichergestellt, daß die Grammatik weiterhin das leere Wort ermöglicht und das ursprüngliche Startsymbol weiterhin auf der rechten Seite der Produktion verwendet werden kann.

1) Eine schwache Chomsky - Normalform erzeugen.

Jedem Terminalsymbol  $a$  wird ein Nichtterminalsymbol  $X_a$  zugeordnet. Auf der rechten Seite jeder Produktion werden sämtliche Terminalsymbole  $a$  durch das entsprechende Nichtterminalsymbol  $X_a$  ersetzt. Abschließend werden alle Produktionen  $X_a \rightarrow a$  der Grammatik hinzugefügt.

Rechte Seiten mit mehr als zwei Nichtterminalen ersetzen

Sind auf der rechten Seite einer Produktion mehr als zwei Nichtterminale, so werden zwei benachbarte Nichtterminale  $AB$  durch ein neues Nichtterminal  $Y_{AB}$  ersetzt. Die Produktion  $Y_{AB} \rightarrow AB$  wird zur Grammatik hinzugefügt. Dies wiederholt

man solange, bis keine Produktion mit mehr als zwei Nichtterminalen mehr vorkommt.

#### ④ $\epsilon$ -Produktion entfernen

Streiche die Regeln  $A \rightarrow \epsilon$ , außer  $S' \rightarrow \epsilon$  (falls vorhanden).

Gab es vorher genau eine Produktion mit  $A$  auf der linken Seite, <sup>also  $A \rightarrow \epsilon$</sup>  so streiche das  $A$  überall auf den rechten Seiten der Produktionen, denn es kann nicht zu einem Terminal abgeleitet werden.

Gab es vorher mehrere Produktionen mit  $A$  auf der linken Seite, so füge für jede Regel, die ein solches  $A$  auf der rechten Seite enthält, eine Regel hinzu, in der das  $A$  gestrichen wurde, denn es muß der Fall betrachtet werden, in dem das  $A$  als leeres Wort abgeleitet werden oder etwa nicht. Die Regel  $C \rightarrow AB$  wird dann beispielsweise um die Regel  $C \rightarrow B$  ergänzt.

Aus  $C \rightarrow AB$  wird also:

$C \rightarrow B$

$C \rightarrow AB$

#### ⑤ Kettenregeln (Produktionen der Form $A \rightarrow B$ ) entfernen

Wenn man eine Kettenregel, d.h. eine Produktion der Form  $A \rightarrow B$ , entfernt, fügt man für jede vorhandene Produktion der Form  $B \rightarrow w$  eine neue Produktion  $A \rightarrow w$  hinzu, falls diese keine bereits entfernte Kettenregel ergibt.  $w$  ist hierbei ein beliebiges Wort; die vorangegangenen Änderungen gewährleisten aber, daß  $w$  entweder genau ein Terminalsymbol oder ein Wort aus genau zwei Nichtterminalsymbolen ist.

Vgl.: Zu jeder kontextsensitiven Grammatik existiert eine Grammatik in Kuroda-Normalform mit Produktionsregeln der Form

- $A \rightarrow a$
- $A \rightarrow B$
- $A \rightarrow BC$
- $AB \rightarrow CD$



Eine Sprache heißt pumpbar gdw. es gibt ein  $k \in \mathbb{N}$ , sodaß für alle Wörter  $w \in L$  mit  $|w| \geq k$  es eine Zerlegung von  $w = xyz$  gibt, für die gilt:

1.  $|xy| \leq k$
2.  $\forall i \geq 0: xy^iz \in L$
3.  $|y| > 0$

Pumpinglemma für reguläre Sprache:


$L$  ist regulär  $\Rightarrow L$  ist pumpbar

Beweis: Sei  $L$  regulär, dann existiert ein deterministischer endlicher Automat  $M = (Q, \Sigma, \delta, q_0, F)$  der  $L$  erkennt. Wir setzen  $k = |Q| + 1$ .

Jeder Lauf für Wort  $w$  mit  $|w| \geq k$  besucht mindestens  $k = |Q| + 1$  Zustände

$\rightarrow$  Zumindest 1 Zustand doppelt

Sei  $p$  der erste Zustand, der mehrfach besucht wurde



- Eigenschaft 1:  $|y| > 0$
- Eigenschaft 2:  $|xy| \leq k$
- Eigenschaft 3:  $\forall i \geq 0: xy^iz \in L$



## Pumping-Lemma für kontextfreie Sprachen

Für jede kontextfreie Sprache  $L$  gibt es eine natürliche Zahl  $n$ , sodass gilt: Jedes Wort  $z$  in  $L$  mit Mindestlänge  $n$  hat eine Zerlegung  $z = uvwxy$  mit den folgenden drei Eigenschaften:

1. Die Wörter  $v$ ,  $w$  und  $x$  haben zusammen höchstens die Länge  $n$ , d. h.  $|vwx| \leq n$ .
2. Eines der Wörter  $v$ ,  $x$  ist nicht leer. Also  $|vx| \geq 1$ .
3. Für jede natürliche Zahl (mit 0)  $i$  ist das Wort  $uv^iwx^iy$  in der Sprache  $L$ , d. h. die Wörter  $uvw$ ,  $uvwx$ ,  $uvvwx$  usw. liegen alle in  $L$ .


Neben den kontextfreien Sprachen gibt es auch nicht kontextfreie Sprachen, die dieses Pumping-Lemma erfüllen. Die Umkehrung des Lemmas gilt im Allgemeinen also nicht. Eine Verallgemeinerung des Pumping-Lemmas für kontextfreie Sprachen ist Ogdens Lemma.

### Beweis

Gegeben sei eine kontextfreie Grammatik  $G$  in Chomsky-Normalform mit  $N$  Variablen, für die gilt, dass sie gerade die gewünschte Sprache beschreibt. Sei nun ein Wort  $x$  aus dieser Sprache gegeben, für das gilt:  $|x| \geq 2^{|N|} =: n$ .

Betrachten wir nun einen Ableitungsbaum  $T$  für  $x$  mit Höhe  $h$ . Da unsere Sprache in CNF angegeben wurde, hat  $T$  die Form eines Binärbaumes. Daraus folgt für die Höhe von  $T$   $h \geq \log_2(n) = |N|$ . Es gibt also einen Pfad  $v_0 \dots v_h$  in  $T$  von der Wurzel zu einem Blatt, für den gilt, dass er Länge  $h + 1 > |N|$  hat. Es existieren also zwei Knoten  $v_j, v_k$  auf diesem Pfad mit  $0 \leq j < k \leq h$ , welche die gleichen Variablen von  $G$   $A_j, A_k$  repräsentieren.

Betrachtet man den Teilbaum  $T_k$ , welcher von  $v_k$  aus aufgespannt wird, so bilden dessen Blätter den Teilstring  $w$ . Der Teilbaum  $T_j$ , welcher von  $v_j$  aufgespannt wird, besitzt als Teilbaum den Baum  $T_k$ . Man kann also die Blätter von  $T_j$  aufteilen in Blätter links von  $T_k$  und Blätter rechts von  $T_k$  und erhält somit eine Aufteilung der Blätter von  $T_j$  der Form  $vw x$ . Ebenso unterteilt der Teilbaum  $T_j$  den gesamten Ableitungsbaum in drei Teile  $u, vwx, y$ . Wir erhalten also als Aufteilung die Teilstrings  $u, y$ , welche im Ableitungsbaum links bzw. rechts von dem von  $v_j$  aufgespannten Teilbaum liegen, die Teilstrings  $v, x$ , welche in dem Teilbaum  $T_j$  liegen nicht jedoch in  $T_k$ , und zu guter Letzt den Teilstring  $w$ , welcher in  $T_k$  liegt. Da  $v_j$  und  $v_k$  die gleichen Variablen unserer Grammatik repräsentieren, folgt daraus, dass der Pfad von  $v_j$  nach  $v_k$  beliebig oft wiederholt werden kann. Durch eine Wiederholung des Pfades würden wir Worte der Form  $uv^iwx^iy$  erzeugen, ohne unsere Sprache zu verlassen. Womit wir das Pumping-Lemma für kontextfreie Sprachen bewiesen hätten.



Die Idee des Pumping-Lemmas für kontextfreie Sprachen ist, dass ein Wortteil durch mehrfaches Ableiten derselben Variablen beliebig oft wiederholt werden kann.

### Beispiel

Ist die Sprache  $L = \{a^m b^m c^m \mid m \geq 1\}$  kontextfrei?





## Abschlußeigenschaften

	Regulär	Kontextfrei	Kontextsensitiv	Typ-0
Vereinigung	+	+	+	+
Konkatenation	+	+	+	+
Kleene Hülle	+	+	+	+
Schnitt	+	(-)	+	+
Komplement	+	(-)	+	(-)

Bemerkung 1. CF ist nicht abgeschlossen gegen Durchschnitt und Komplement.

Beweis: Seien  $L = \{a^n b^n c^m \mid n, m \geq 0\}$  und  $L' = \{a^m b^n c^n \mid n, m \geq 0\}$

Dann gilt  $L \cap L' = \{a^n b^n c^n \mid n \geq 0\}$ .

Mit Hilfe des Pumping-Lemmas kann man zeigen, daß  $L \cap L'$  nicht kontextfrei ist (aber kontextsensitiv).

Nach den deMorganschen Regeln gilt  $\overline{L_1 \cap L_2} = \overline{L_1} \cup \overline{L_2}$ . Da CF gegen Vereinigung abgeschlossen ist,

würde aus dem Abschluß gegen

Komplement der Abschluß gegen Durchschnitt folgen.

$$\overline{L_1 \cap L_2} = \overline{L_1} \cup \overline{L_2}$$

Bemerkung 2. Die Klasse der Typ-0-Sprachen ist nicht unter Komplement abgeschlossen.  $\square$

Beweis: Eine Sprache ist vom Typ-0 gdw. sie semi-entscheidbar ist.

Das Selbsthalteproblem  $H$  ist semi-entscheidbar, aber nicht entscheidbar.

Wäre  $H^c$  auch vom Typ-0 (semi-entscheidbar), dann wäre

$H$  entscheidbar  $\hookrightarrow$

Bemerkung 3. Die regulären Sprachen sind nicht abgeschlossen unter unendlicher Vereinigung.

Beweis: Für alle  $k \in \mathbb{N}$  ist die Sprache  $L_k := \{a^k b^k\}$  ein <sup>regulär</sup> Singleton.  
Jedoch ist die unendliche Vereinigung  $L := \bigcup_{k \in \mathbb{N}} L_k = \{a^n b^n \mid n \in \mathbb{N}\}$   
nach dem Pumping-Lemma nicht regulär.

□