



UNIVERSITÄT
LEIPZIG

Neuronale Netze

Einführung und Perceptron

INTERACTIVE VISUAL DATA MINING

NEURONALE NETZE

- Motivation & Definition
- Vorbild Biologie
- Einführung
- Perceptron

NEURONALE NETZE

Künstliche neuronale Netze sind:

- Massiv parallel verbundene Netzwerke aus
- Einfachen (adaptiven) Elementen in
- Hierarchischer Ordnung oder Organisation

Diese Netze sollen in der selben Art wie biologische Nervensysteme mit der Welt interagieren.

(Kohonen 84)

NEURONALE NETZE

– Forschung:

- Modellierung und Simulation biologischer neuronaler Netze
- Speicherung von Information
- Funktionsapproximation
- ...

– Anwendungen:

- Analyse Sensordaten
- Medizin
- Schrifterkennung
- Bilderkennung
- Zeitreihenanalyse
- Sprachverarbeitung
-

NEURONALE NETZE






Figure 1: Neural Network learning to steer an autonomous vehicle (Mitchell 1997)

NEURONALE NETZE

- Künstliche neuronale Netze sind gekennzeichnet durch:
 - Massiv parallele Informationsverarbeitung
 - Propagierung der Informationen durch Kanten
 - Verteilte Informationsspeicherung
 - Black Box Modell
- Phasen:
 - Aufbauphase (Topologie des Netzes)
 - Trainingsphase (Lernen)
 - Arbeitsphase (Propagation)

NEURONALE NETZE


- Vorbild Biologie:
 - Neuronen können
 - Informationen aufnehmen (Dendriten)
 - Informationen verarbeiten (Zellkörper)
 - Informationen weiterleiten (Axon, Synapsen)



NEURONALE NETZE

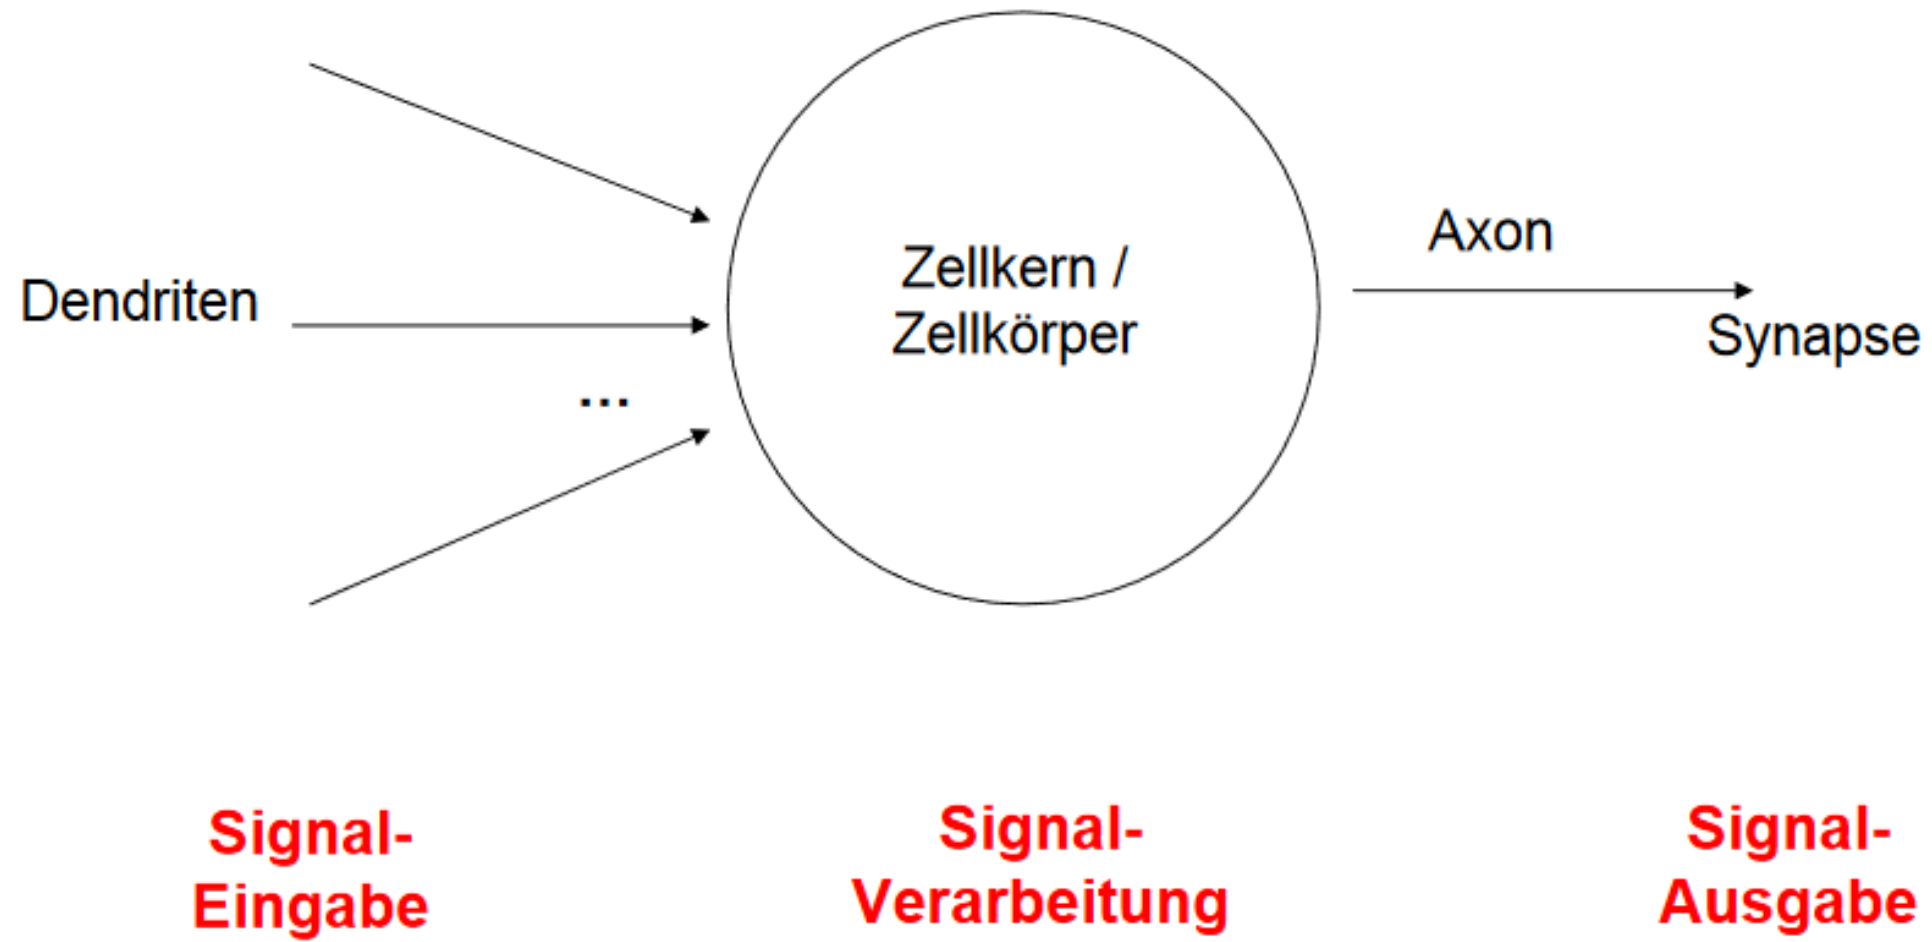
Vorbild Biologie

- Das menschliche Gehirn besteht aus
 - ca. 10^{11} Neuronen, die mit
 - ca. 10^4 anderen Neuronen durch
 - ca. 10^{13} Synapsen verbunden sind



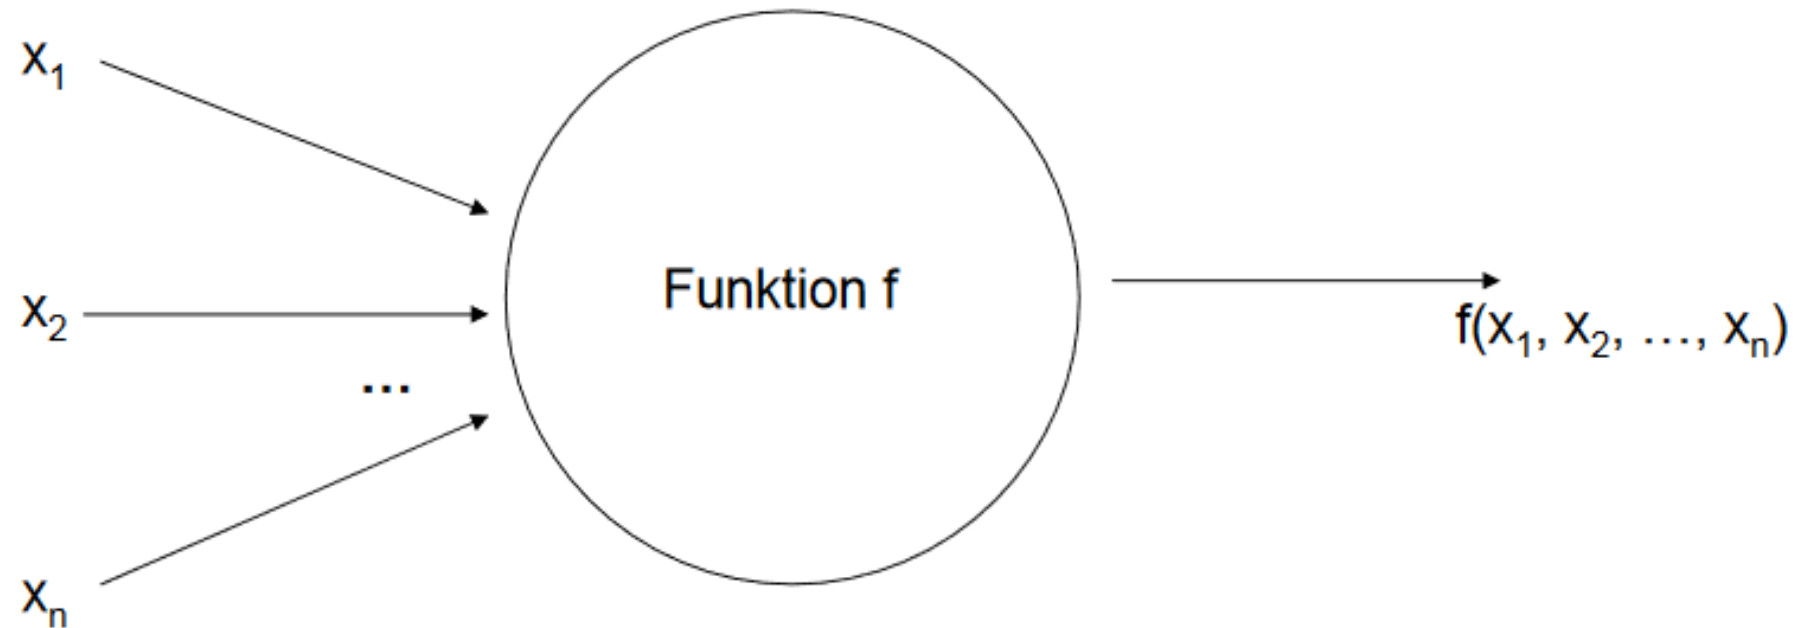
NEURONALE NETZE

— Abstraktion



NEURONALE NETZE

– Modell



McCulloch-Pitts-Neuron 1943:

$$x_i \in \{0, 1\} =: \mathbb{B}$$

$$f: \mathbb{B}^n \rightarrow \mathbb{B}$$

NEURONALE NETZE

- 1943: Warren McCulloch & Walter Pitts
- Beschreibung neurologischer Netzwerke
 - Modell McCulloch Pitts Neuron
 - Grundidee:
 - Neuron ist entweder aktiv oder inaktiv
 - Fähigkeiten entstehen durch Vernetzung der Neuronen
- Es werden nur statische Netze betrachtet
 - Topologie wird vorher festgelegt
 - Es werden keine neuen Verbindungen beim Lernen erstellt
 - Widerspruch zur Biologie!


NEURONALE NETZE

- McCulloch Pitts Neuron
- n binäre Eingangssignale x_1 bis x_n
- Schwellwert $\theta > 0$


$$f(x_1, \dots, x_n) = \begin{cases} 1 & \text{falls } \sum_{i=1}^n x_i \geq \theta \\ 0 & \text{sonst} \end{cases}$$

- Damit sind folgende logische Funktionen realisierbar:

Boolsches AND



Boolsches OR



NEURONALE NETZE

- McCulloch Pitts Neuron

- n binäre Eingangssignale x_1 bis x_n

- Schwellwert $\theta > 0$

- Zusätzlich m binäre hemmende Signale y_1 bis y_m


- Ist ein $y_j = 1$, dann ist die Ausgabe 0

- Sonst gilt:

Summe der Eingänge \geq Schwellwert \rightarrow
Ausgabe = 1


Ansonsten Ausgabe = 0

$$\tilde{f}(x_1, \dots, x_n; y_1, \dots, y_m) = f(x_1, \dots, x_n) \cdot \prod_{j=1}^m (1 - y_j)$$




NEURONALE NETZE

- Verallgemeinerung mit Gewichten



- Ist äquivalent zu



- Dieser Knoten liefert 1 bei

$$0,2 x_1 + 0,4 x_2 + 0,3 x_3 \geq 0,7$$

- Wenn man die Gewichte mit 10 multipliziert

$$2 x_1 + 4 x_2 + 3 x_3 \geq 7$$

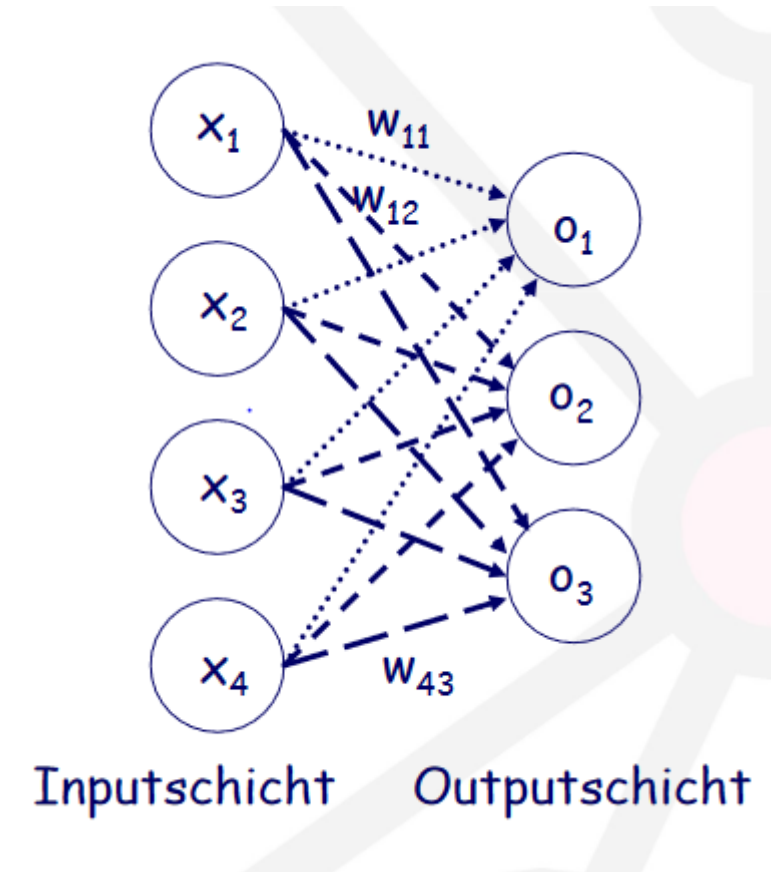
Die Eingänge entsprechend dupliziert, erhält man einen äquivalenten Knoten.

NEURONALE NETZE

- Einfaches Perceptron
 - Motivation
 - Definition
 - Geometrische Interpretation
 - Lernen mittels Delta Regel
 - XOR Problem

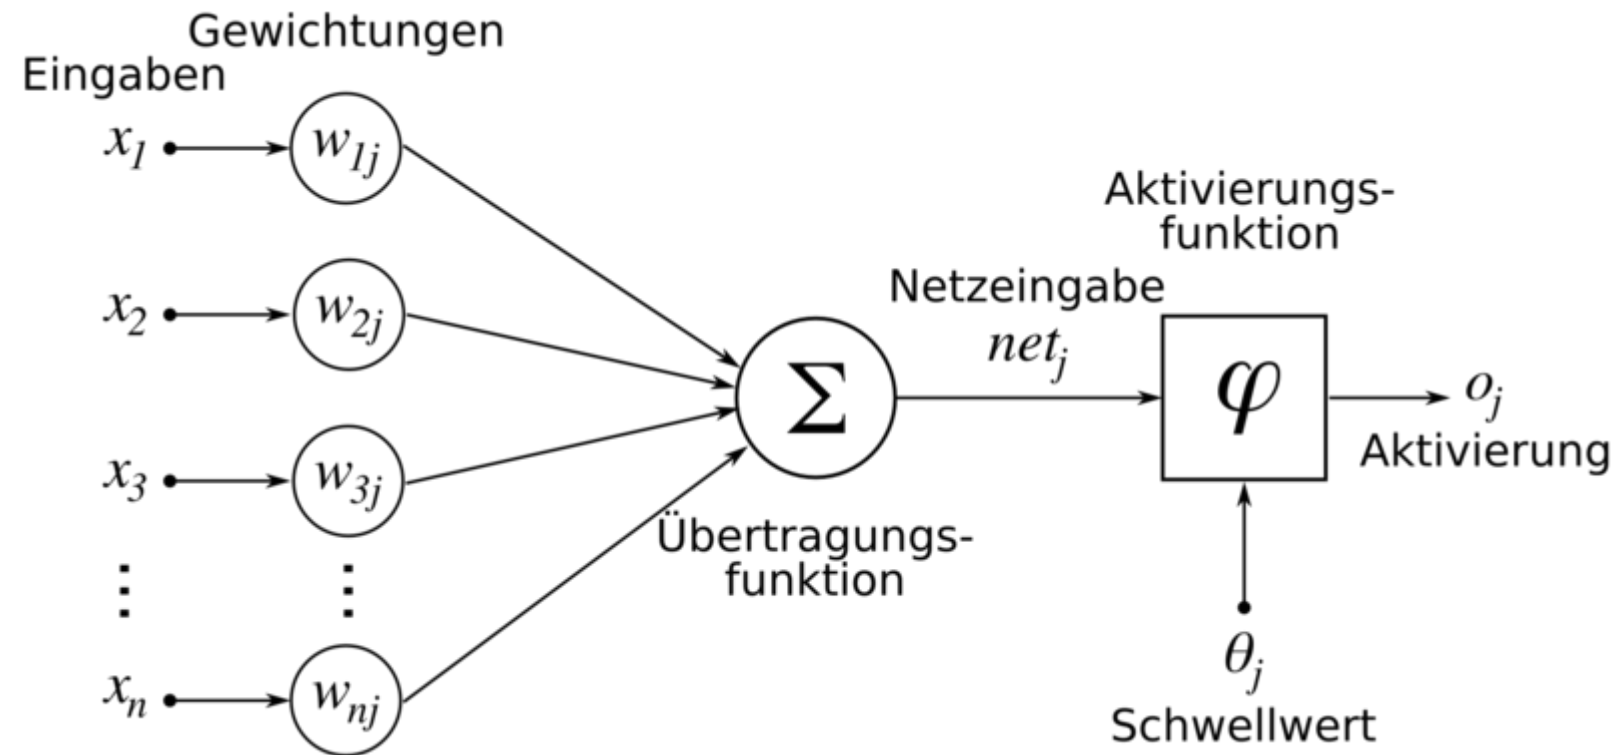
NEURONALE NETZE

- Perceptron (Rosenblatt 1958)
 - Jedes Outputneuron hat einen eigenen unabhängigen Netzbereich
 - Zur Vereinfachung hat jedes Netz im folgenden nur einen Output
 - War historisch als Hardwareimplementierung gedacht
 - Später auf Multilayer Perceptrons erweitert



NEURONALE NETZE


– Genereller Aufbau



NEURONALE NETZE

- Aktivierungsfunktionen
- Schwellwertfunktion:
 - Nimmt nur die Werte 0 und 1 an
 - Schwellwert bestimmt die Aktivierung
 - Alles oder Nichts Funktionsweise


$$\varphi^{\text{hlim}}(v) = \begin{cases} 1 & \text{wenn } v \geq 0 \\ 0 & \text{wenn } v < 0 \end{cases}$$



NEURONALE NETZE

- Aktivierungsfunktionen
- Stückweise lineare Funktion:
 - Abbildung eines begrenzten Intervalls mit einer linearen Funktion
 - Außerhalb konstante Werte


$$\varphi^{\text{pwl}}(v) = \begin{cases} 1 & \text{wenn } v \geq \frac{1}{2} \\ v + \frac{1}{2} & \text{wenn } -\frac{1}{2} < v < \frac{1}{2} \\ 0 & \text{wenn } v \leq -\frac{1}{2} \end{cases}$$



NEURONALE NETZE

- Aktivierungsfunktionen
- Sigmoid Funktion
- Wurden lange als Standardfunktion genutzt
- Steigungsmaß alpha kann modifiziert werden


$$\varphi_a^{\text{sig}}(v) = \frac{1}{1 + \exp(-av)}$$



NEURONALE NETZE

- Aktivierungsfunktionen
 - Rectifier (ReLU) Funktion
 - rectified linear activation unit
 - Abwandlung der stückweisen linearen Funktion
 - Nur positiver Teil wird linear abgebildet

$$\varphi(v) = \max(0, v)$$



NEURONALE NETZE

- Outputneuron hat:
 - Schwellwert s
 - Aktivität a aus den Inputs und Gewichten
 - Nutzt Aktivierungsfunktion, um den Output zu berechnen
 - Historisch wurde die Sprungfunktion verwendet

- Bildet damit eine Trenngerade zwischen 2 Klassen

$$w_1 x_1 + w_2 x_2 \geq \theta \quad \begin{array}{l} \text{J} \rightarrow 1 \\ \text{N} \rightarrow 0 \end{array}$$

- Umgestellt nach x_2

$$x_2 \geq \frac{\theta}{w_2} - \frac{w_1}{w_2} x_1 \quad \begin{array}{l} \text{J} \rightarrow 1 \\ \text{N} \rightarrow 0 \end{array}$$

NEURONALE NETZE

- Bildet damit eine lineare Trenngerade zwischen 2 Klassen

$$w_1 x_1 + w_2 x_2 \geq \theta \begin{cases} \text{J} \rightarrow 1 \\ \text{N} \rightarrow 0 \end{cases}$$


- Umgestellt nach x_2

$$x_2 \geq \frac{\theta}{w_2} - \frac{w_1}{w_2} x_1 \begin{cases} \text{J} \rightarrow 1 \\ \text{N} \rightarrow 0 \end{cases}$$

- Beispiel:


$$0.9 x_1 + 0.8 x_2 \geq 0.6$$

$$x_2 \geq \frac{3}{4} - \frac{9}{8} x_1$$




NEURONALE NETZE


AND




OR



NAND



NOR



NEURONALE NETZE

- Lernverfahren
 - Gegeben ist ein Trainingsdatensatz
 - Daten sind disjunkt in 2 Menge x und y aufgeteilt
 - Gesucht wird eine trennende Hyperebene
 - Basiert auf den Gewichten
 - Teilt x und y auf
- Problem: x und y müssen linear trennbar sein!

NEURONALE NETZE

- Lernverfahren Delta Regel
 - Beim Training werden die Daten dem Netz als Input gezeigt
 - Output für die Beispiele bekannt (supervised)
 - Vergleich von Soll und Ist Zustand im Output
- Bei Abweichung werden Schwellwert und Gewichte adaptiert
- Ist nur auf differenzierbare Aktivierungsfunktionen anwendbar!
- Anpassung kann nach jedem Input oder nach jeder Epoche durchgeführt werden
- Epoche = Ein Durchlauf aller Trainingsdaten

NEURONALE NETZE

- Lernverfahren Delta Regel

$$\Delta w_{ji} = \alpha(t_j - y_j)g'(h_j)x_i$$

- Alpha: konstante Lernrate
- $g(x)$ ist die Aktivierungsfunktion
- g' ist die Ableitung von g
- t_j ist die Sollausgabe

- y_j ist die Istausgabe

- h_j ist die gewichtete Summe der Inputs des Neurons

- x_i ist der Input i

- Mit


$$h_j = \sum x_i w_{ji}$$

$$y_j = g(h_j)$$


- Die gleiche Formel wird auf auf den Schwellwert angewendet

NEURONALE NETZE

- Lernverfahren Delta Regel
- Der Schwellwert ist damit auch nur ein Gewicht!



$$\sum_{i=1}^n w_i x_i \geq \theta$$



$$\sum_{i=1}^n w_i x_i - \theta \geq 0$$

NEURONALE NETZE

- Lernverfahren Delta Regel
- Initialer Schwellwert -1
- Lernfaktor 0.2

Eingang1	Eingang2	Ausgang
0	0	0
0	1	1
1	0	0
1	1	1

	$i_1 = 0/i_2 = 0$	$i_1 = 0/i_2 = 1$	$i_1 = 1/i_2 = 0$	$i_1 = 1/i_2 = 1$
ω_0	1.0	1.0	1.2	1.2
ω_1	1.0	1.0	0.8	0.8
ω_2	1.0	1.0	1.0	1.0

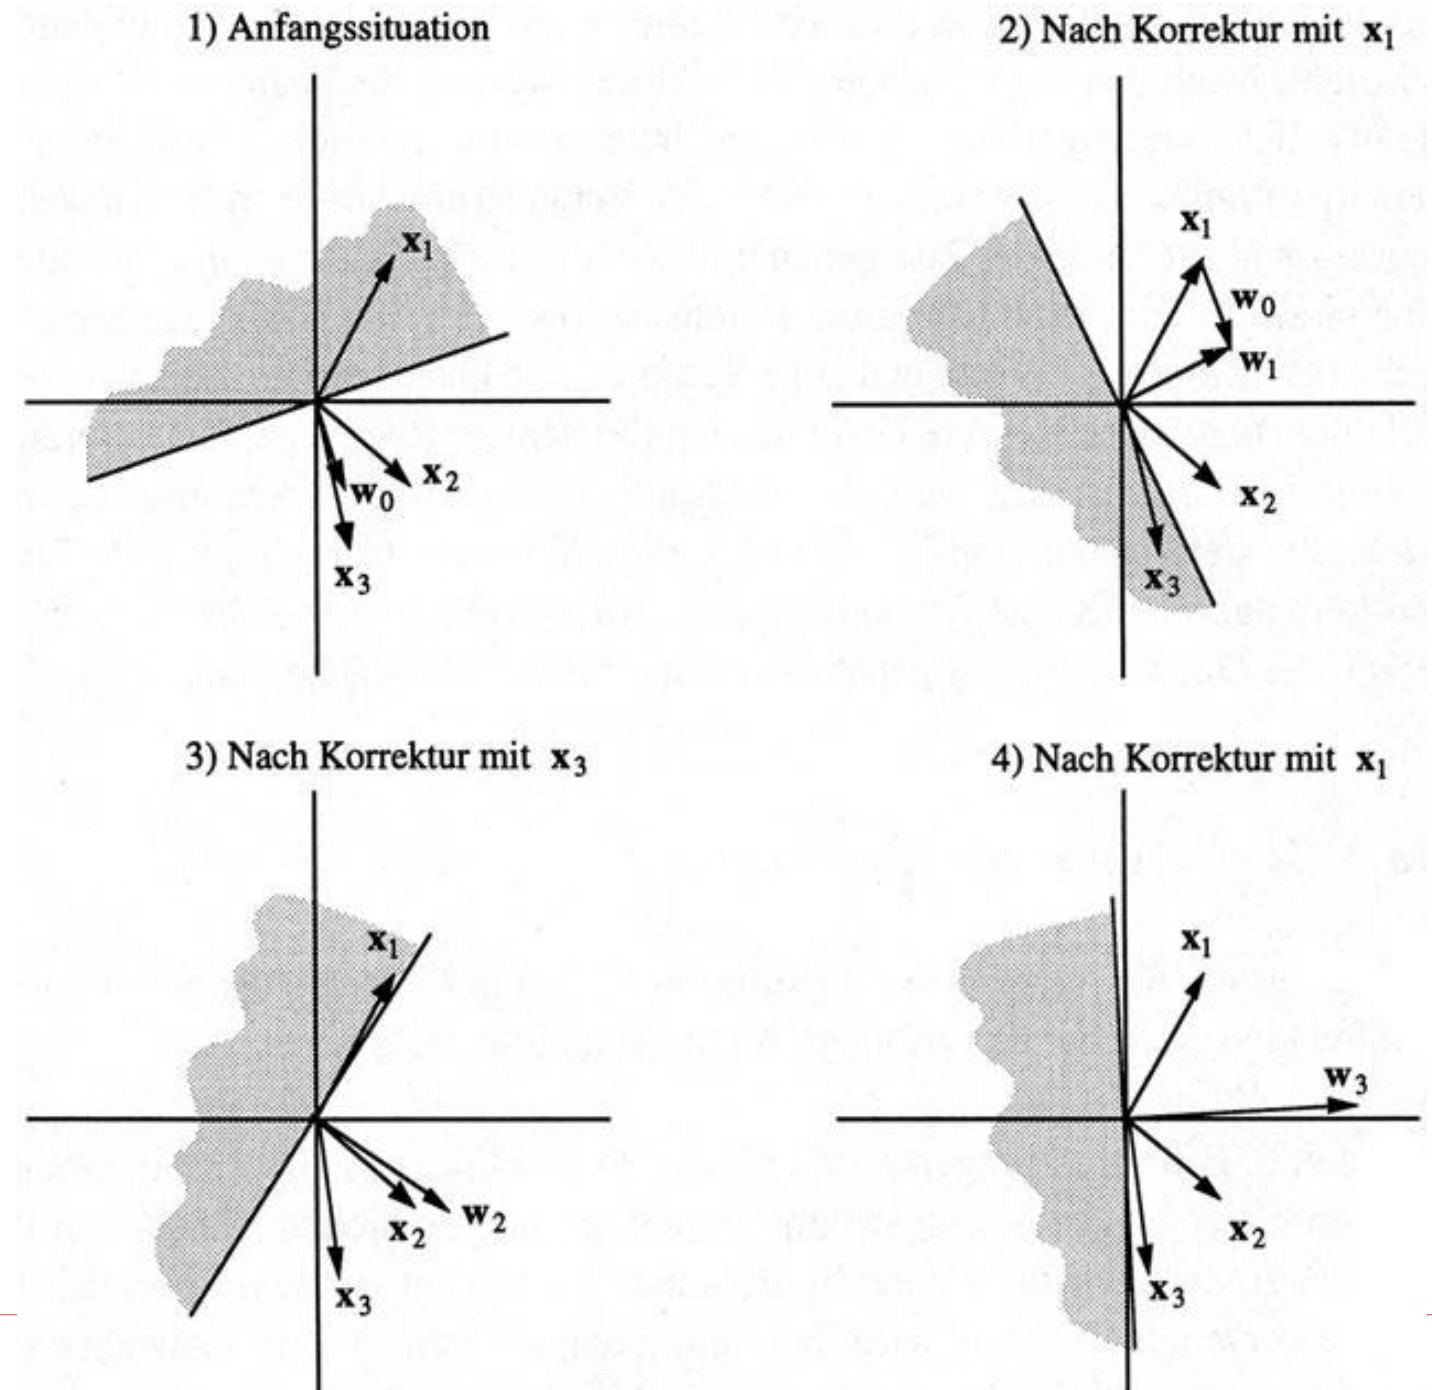
	$i_1 = 0/i_2 = 0$	$i_1 = 0/i_2 = 1$	$i_1 = 1/i_2 = 0$	$i_1 = 1/i_2 = 1$
ω_0	1.2	1.0	1.0	1.0
ω_1	0.8	0.8	0.8	0.8
ω_2	1.0	1.2	1.2	1.2

NEURONALE NETZE

- Lernverfahren Delta Regel
 - Kovergenz und Korrektheit
 - Satz: Wenn ein Perzeptron eine Klasseneinteilung lernen kann, dann lernt es diese mit der Delta Regel in endlich vielen Schritten
- Problem: Falls das Perzeptron das Modell nicht erlernt, kann man nicht entscheiden:
 - Ob genügend Epochen gerlernt wurde oder
 - Das Problem nicht erlernbar ist
 - → Es gibt keine obere Schranke für die Lerndauer
 - → Overfitting Problematik


NEURONALE NETZE

- Lernverfahren Delta Regel
- Geometrische Interpretation nach Rojas



NEURONALE NETZE

– XOR Problem



x_1	x_2	xor
0	0	0
0	1	1
1	0	1
1	1	0

$$w_1 x_1 + w_2 x_2 \geq \theta$$

$$\Rightarrow 0 < \theta$$

$$\Rightarrow w_2 \geq \theta$$

$$\Rightarrow w_1 \geq \theta$$

$$\Rightarrow w_1 + w_2 < \theta$$

$$w_1, w_2 \geq \theta > 0$$

$$\Rightarrow w_1 + w_2 \geq 2\theta$$

Widerspruch!


- Triviales Problem ist mit künstlichen Neuronen nicht lösbar!

NEURONALE NETZE


- XOR Problem
 - 1969 publiziert von Minsky und Papert
 - Folgerung: künstliche neuronale Netze sind eine Sackgasse
 - Forschung wurde daraufhin ca 15 Jahre eingestellt

- Lösungen sind:

- Mehrschichtige Perzeptrons (Feedforward Netze)



- Nichtlineare Trennfunktionen



$$g(x_1, x_2) = 2x_1 + 2x_2 - 4x_1x_2 - 1 \quad \text{mit} \quad \theta = 0$$

NEURONALE NETZE

- Vorteile künstlicher neuronaler Netze
 - Sehr gute Mustererkennung
 - Verarbeitung von Inputs mit
 - Verrauschten Eigenschaften
 - Unvollständigen Eigenschaften
 - Widersprüchlichen Eigenschaften
- Möglicher multimodaler Input (Zahlen, Farben, Töne, Sprache, etc)
- Erstellt ein Modell ohne Hypothesen des Nutzers
- Fehlertolerant
- Im Produktivbetrieb einfach zu nutzen

NEURONALE NETZE

– Nachteile künstlicher neuronaler Netze

- Lange Trainingszeiten (bis zu Monaten)
- Lernerfolg ist nicht garantiert
- Generalisierbarkeit ist nicht garantiert
- Viele Daten sind notwendig
- Komplexes Blackbox Verfahren
- Evaluierung des Netzes ist schwierig
- Anzahl der Knoten und Kanten kann schnell sehr groß werden
- Löst „nur“ das Problem mit einem Modell, liefert aber keine Hinweise auf die wichtigen Features