



UNIVERSITÄT
LEIPZIG

Informationsvisualisierung 1

Sommersemester 2026

Dirk Zeckzer

Institut für Informatik



Teil V

Darstellung von mehrdimensionalen Daten

Übersicht

5. Darstellung von mehrdimensionalen Daten

5.1 Visuelle Abbildung

5.2 Graphische Elemente


5.3 Uni-Variate Daten

5.4 Bi-Variate Daten

5.5 Tri-Variate Daten

5.6 Multi-Variate Daten

Visuelle Abbildung



Graphische Elemente

- ▶ Punkte: 0D
 - ▶ Position
- ▶ Linien: 1D
 - ▶ Position
 - ▶ Länge
- ▶ Flächen: 2D
 - ▶ Position
 - ▶ Ausdehnung in x - und y -Richtung
 - ▶ Fläche
 - ▶ Umfang
- ▶ Volumina: 3D
 - ▶ Position
 - ▶ Ausdehnung in x -, y - und z -Richtung
 - ▶ Volumen
 - ▶ Oberfläche

Graphische Elemente

▶ 2D

- ▶ Punkte (Pixel)
 - ▶ Darstellung: Kreise, Quadrate
 - ▶ haben in 2D eine **Fläche**
- ▶ Linien
 - ▶ gerade
 - ▶ gebogen
 - ▶ haben in 2D eine **Breite**
- ▶ Linienzüge
- ▶ Ebene geometrische Figuren
 - ▶ Geschlossene Linienzüge
 - ▶ Kreise, Ellipsen, ...
 - ▶ Quadrate, Rechtecke, Polygone, ...

▶ 3D

- ▶ Punkte (Pixel)
 - ▶ Darstellung: Kugeln
 - ▶ haben in 3D ein **Volumen**
- ▶ Linien
 - ▶ Darstellung: Zylinder
 - ▶ haben in 3D ein **Volumen**
- ▶ (Ober)-Flächen
 - ▶ eben
 - ▶ gekrümmt
- ▶ Volumina
 - ▶ Kugel, Ellipsoid, ...
 - ▶ Zylinder, Torus, ...
 - ▶ Würfel, Quader, ...

Graphische Elemente

Eigenschaften (2D)

▶ Punkte (Pixel)

▶ Farbe

- ▶ Farbwert (hue)
- ▶ Sättigung (saturation)
- ▶ Helligkeit (brightness, lightness)

▶ Linien

▶ Farbe

▶ Form

- ▶ Gerade
- ▶ Linienzug (Polyline)
- ▶ Gebogen

▶ (Länge: meist durch Objekte, die verbunden werden, gegeben)

▶ Breite

▶ Stil

- ▶ Durchgezogen
- ▶ Strich-Punkt
- ▶ Gepunktet

Graphische Elemente

Eigenschaften (2D)

- ▶ Ebene geometrische Figuren
 - ▶ Farbe
 - ▶ Form
 - ▶ Orientierung
 - ▶ Größe
 - ▶ Textur

Graphische Elemente

Einschränkungen

- ▶ Farbe
 - ▶ Gleichzeitige Verwendung von Sättigung und Helligkeit nicht möglich
 - ▶ In 3D wird die Farbe durch das Beleuchtungsmodell bestimmt
 - ▶ Sättigung
 - ▶ Helligkeit
- ▶ Form, Orientierung und Textur (Stil von Linien)
 - ▶ bedingen Mindestgröße für die Erkennbarkeit
- ▶ Größe (Breite von Linien)
 - ▶ muss begrenzt sein (Minimum, Maximum)
 - ▶ gegebenenfalls muss der Wertebereich skaliert werden
- ▶ Textur sollte keinen visuellen Stress erzeugen

Graphische Elemente

Eignung von graphischen Eigenschaften von graphischen Elementen für Datentypen

Attribute	Nominal	Geordnet	Quantitativ
Farbwert	✓	×	×
Farbintensität	×	✓	○
Form (Stil)	✓	×	×
Orientierung	×	○	○
Größe (1D)	×	○	✓
Größe (2D)	×	○	○
Textur	✓	○	○

Graphische Elemente

Eignung von weiteren graphischen Eigenschaften für Datentypen


Attribute	Nominal	Geordnet	Quantitativ
Position	○	✓	✓

Graphische Elemente: Glyphen

- ▶ Ein Glyph ist graphisches Objekt zur Repräsentation eines multivariaten Datenobjektes
- ▶ Kombinationen von graphischen Dimensionen (Variablen) lassen sich unterscheiden in
 - ▶ separable
 - ▶ integrale
- ▶ Ob graphische Variablen gemeinsam (integral) oder getrennt (separabel) wahrgenommen werden, muss durch Experimente ermittelt werden


Graphische Elemente: Glyphen

- ▶ **Integrale Dimensionen**
 - ▶ Breite und Höhe
 - ▶ Rot und Grün
(ergeben zusammen Gelb)
 - ▶ ...
- ▶ **Trennbare Dimensionen**
 - ▶ Durchmesser und Farbe
 - ▶ ...



Graphische Elemente: Glyphen


- ▶ **Integrale Dimensionen**
 - ▶ Breite und Höhe
 - ▶ Rot und Grün
(ergeben zusammen Gelb)
 - ▶ ...
- ▶ **Trennbare Dimensionen**
 - ▶ Durchmesser und Farbe
 - ▶ ...



Patterns for a speeded classification task. Subjects are required to respond positively only to those glyphs that have the same height as the black bar in the upper-left corner. (a) Integral dimensions. In the first column, a second integral dimension is randomly coded by horizontal size (interference condition). In the second column, width information is redundantly coded with height information. (b) Separable dimension. In the first column, gray information is not correlated with height. In the second column, gray level is a redundant code.


Graphische Elemente: Glyphen

- ▶ **Integrale Dimensionen**
 - ▶ Breite und Höhe
 - ▶ Rot und Grün
(ergeben zusammen Gelb)
 - ▶ ...
- ▶ **Trennbare Dimensionen**
 - ▶ Durchmesser und Farbe
 - ▶ ...
- ▶ Diese Unterscheidung ist nicht strikt;
es gibt Übergänge



Graphische Elemente: Glyphen

- ▶ **Integrale Dimensionen**
 - ▶ Breite und Höhe
 - ▶ Rot und Grün
(ergeben zusammen Gelb)
 - ▶ ...
- ▶ **Trennbare Dimensionen**
 - ▶ Durchmesser und Farbe
 - ▶ ...
- ▶ Diese Unterscheidung ist nicht strikt;
es gibt Übergänge



Graphische Elemente: Glyphen

- ▶ Multidimensionale Daten
 - ▶ 8 Dimensionen
 - ▶ Mindestens 2 Bit pro Dimension
- ▶ Nur trennbare Variablen können verwendet werden
 - ▶ 5 Dimensionen
 - ▶ 32 verschiedene Glyphen
- ▶ Diese können von visueller Vorverarbeitung schnell unterschieden werden

Visual variable	Dimensionality	Comment
Spatial position of glyph	3 dimensions: X, Y, Z.	
Color of glyph	3 dimensions: defined by color opponent theory.	Luminance contrast is needed to specify all other graphical attributes.
Shape	2–3? Dimensions unknown.	The dimensions of shape that can be rapidly processed are unknown. However, evidence suggests that size and degree of elongation are two primary ones.
Orientation	3 dimensions: corresponding to orientation about each of the primary axes.	Orientation is not independent of shape. One object can have rotation symmetry with another.
Surface texture	3 dimensions: orientation, size, and contrast.	Not independent of shape or orientation. Uses up one color dimension.
Motion coding	2–3? Dimensions largely unknown, but phase may be useful.	
Blink coding: The glyph blinks on and off at some rate.	1 dimension.	Motion and blink coding are highly interdependent.

Graphical attributes that may be used in glyph design.

Graphische Elemente

- ▶ Auswahl der visuellen Abbildung in Abhängigkeit von der Dimension der Daten
 - ▶ Dimension: Anzahl der Attribute (Variablen)

Dimension	Bezeichnung
1D	Uni-Variate Daten
2D	Bi-Variate Daten
3D	Tri-Variate Daten
$\geq 4D$	Multi-Variate Daten Hyper-Variate Daten

- ▶ Darstellung der Daten in einem 2- oder 3-dimensionalen visuellen Raum
- ▶ Im Folgenden sind die Daten meistens quantitativ
 - ▶ Uni-, Bi- und Tri-Variate Daten: Position von Markierungen auf orthogonalen Achsen dargestellt
 - ▶ Multi-Variate Daten: Darstellung schwieriger
- ▶ Wahrnehmung ist sehr wichtig für
 - ▶ die visuelle Abbildung
 - ▶ die Bildung von visuellen Strukturen

Uni-Variate Daten (1D)

Betrachtung eines Attributes

► Gegeben

- n Datenpunkte
- 1 Attribut: a_1
- Werte des Attributes
 $X = \{x_i | 1 \leq i \leq n\}$

ID	a_1
id_1	x_1
id_2	x_2
$\dots$	
id_n	x_n

► Ziel

- Verständnis der Verteilung der Werte dieses Attributes

► Definitionen

- $x_{min} = \min(X)$
- $x_{max} = \max(X)$

► Beachte

- Die x_i müssen nicht geordnet sein

Uni-Variate Daten (1D)

Häufigkeitsverteilung

- ▶ Sei $D = \{d_j\}$ die Menge der **verschiedenen** Werte desselben Attributes

- ▶ Dann gilt

- ▶ $D = \{d_j\} \subseteq \{x_i\} = X$
- ▶ $n_d := |\{d_j\}| \leq |\{x_i\}| = n$

- ▶ Absolute Häufigkeit

$$h^a(d_j) := |\{x_i | x_i = d_j\}|$$

Zähle für jeden Wert d_j , wie häufig er vorkommt

- ▶ Es gilt

$$\sum_{j=1}^{n_d} h^a(d_j) = n$$

Uni-Variate Daten (1D)

Häufigkeitsverteilung

- ▶ Sei $D = \{d_j\}$ die Menge der **verschiedenen** Werte desselben Attributes
- ▶ Absolute Häufigkeit

$$h^a(d_j) := |\{x_i | x_i = d_j\}|$$

Zähle für jeden Wert d_j , wie häufig er vorkommt


- ▶ Stelle die absolute Häufigkeit in einem Balkendiagramm dar
- ▶ Form: Rechteck
 - ▶ Breite: konstant
 - ▶ Höhe: $h^a(d_j)$
- ▶ Positionierung: Koordinatensystem
 - ▶ x-Achse: j
 - ▶ y-Achse: 0
- ▶ Farbe: konstant

Uni-Variate Daten (1D)

Häufigkeitsverteilung 1

ID	Wert
1	1
2	3
3	5
4	6
5	6
6	4
7	2
8	4
9	6
10	3
11	5
12	1
13	1
14	5
15	3


Wert	Häufigkeit
1	3
2	1
3	3
4	2
5	3
6	3



Häufigkeitsverteilung 2

ID	Wert
1	1
2	3
3	5
4	6
5	2
6	4
7	3
8	4
9	6
10	3
11	5
12	4
13	3
14	5
15	3

Wert	Häufigkeit
1	1
2	2
3	4
4	3
5	3
6	2



Uni-Variate Daten (1D)

Balkendiagramm: Datentypen

- ▶ Kategorisch:
 - ▶ Reihenfolge unerheblich
- ▶ Geordnet:
 - ▶ Reihenfolge muss beachtet werden

$$\forall i < j : d_i < d_j$$

- ▶ Numerisch Diskret:
 - ▶ Fehlende Werte müssen mit Häufigkeit 0 angezeigt werden

$$\forall d_i : (d_{min} < d_i < d_{max} \wedge d_i \notin D) \longrightarrow h^a(d_i) = 0$$

- ▶ Numerisch Kontinuierlich:
 - ▶ Abstand zwischen zwei Werten muss gleich sein
 - ▶ Besser: Verwendung von Histogrammen

Uni-Variate Daten (1D)

Balkendiagramm: Höhe der Balken

- ▶ Maximale Häufigkeiten größer als die Anzahl der zur Verfügung stehenden Pixel der Zeichnung
 - ▶ Höhe des Balkens für kleine Häufigkeiten kleiner als 1
- ▶ Um immer zwischen Häufigkeit 0 und kleinen Häufigkeiten unterscheiden zu können
 - ▶ Die minimale Höhe eines Balkens für Häufigkeiten grösser 0 auf mindestens 1 Pixel setzen

Uni-Variate Daten (1D)

Häufigkeitsverteilung



- ▶ Logarithmische Skalen
 - ▶ Umfassen die Häufigkeiten mehrere Größenordnungen, so kann eine logarithmische Transformation hilfreich sein

$$h(d_i) = \begin{cases} \log_b(h^a(d_i)) + 1 & h^a(d_i) > 0 \\ 0 & h^a(d_i) = 0 \end{cases}$$

- ▶ Meist: $b = 10$

Uni-Variate Daten (1D)

Wert	Häufigkeit (absolut)	Häufigkeit (logarithmisch)
1	1	1,00
2	10	2,00
3	100	3,00
4	400	3,60
5	4000	4,60
6	700	3,85
7	90	2,95
8	25	2,40
9	5	1,70



Uni-Variate Daten (1D)

Häufigkeitsverteilung

► Relative Häufigkeit

$$h^r(d_j) := \frac{h^a(d_j)}{n}$$

► Eigenschaften

- $0 \leq h^r(d_j) \leq 1$
- $\sum_{j=1}^{n_d} h^r(d_j) = 1$

► Prozentuale Häufigkeit

$$h^p(d_j) := h^r(d_j) \cdot 100$$

► Eigenschaften

- $0 \leq h^p(d_j) \leq 100$
- $\sum_{j=1}^{n_d} h^p(d_j) = 100$

Uni-Variate Daten (1D)

Häufigkeitsverteilung

- ▶ Basis (Bezugspunkt) der Relativierung muss deutlich sein
- ▶ Was ist wichtiger: absoluter oder relativer Wert
- ▶ Bei sehr kleinem n sind relative Werte in der Regel irreführend
 - ▶ $n = 5$
 - ▶ Differenz absolut: 1
→ Differenz prozentual: 20


$h^a(d_j)$	$h^p(d_j)$
0	0%
1	20%
2	40%
3	60%
4	80%
5	100%

Uni-Variate Daten (1D)

Pie Chart


- ▶ Zeigen relative/anteilige Verteilung (meist: prozentuale Verteilung)
- ▶ Meist für Geschäftsgraphiken
- ▶ Kaum Verwendung im wissenschaftlichen Bereich
- ▶ Probleme
 - ▶ Fläche und Winkel sind schwieriger zu interpretieren als Länge
 - ▶ Schwierig für (numerische) Vergleiche
 - ▶ Nutzung von vielen Pie-Charts gleichzeitig ist sehr schwierig

1	110
2	130
3	110
4	140
5	115
6	125
7	145
8	180
9	200
10	190




Uni-Variate Daten (1D)

Bar Chart



Pie Chart




Uni-Variate Daten (1D)

Line Chart

- ▶ Zeigt Form und Verlauf der Verteilung
 - ▶ Zeigt nicht die Werte
 - ▶ Geeignet für
 - ▶ Kontinuierliche Daten
 - ▶ Zeitreihen
 - ▶ Nicht geeignet für
 - ▶ Kategorische Daten
 - ▶ Geordnete Daten
 - ▶ Diskrete Daten
- (erweckt Eindruck, dass Zwischenwerte existieren)

1	110
2	130
3	110
4	140
5	115
6	125
7	145
8	180
9	200
10	190




Uni-Variate Daten (1D)

Dot Chart


- ▶ Punkte anstelle von Balken
- ▶ Geeignet für
 - ▶ Kategorische Daten
 - ▶ Geordnete Daten
 - ▶ Diskrete Daten
 - ▶ Kontinuierliche Daten
 - ▶ Zeitreihen
- ▶ Sinnvoll, falls y-Achse nicht bei 0 beginnt

1	110
2	130
3	110
4	140
5	115
6	125
7	145
8	180
9	200
10	190




Uni-Variate Daten (1D)


Line Chart



Bar Chart



Dot Chart



Uni-Variate Daten (1D)

Häufigkeitsverteilung: Klasseneinteilung

- ▶ Gruppierung der $d_i \in D$
 - ▶ n_k : Anzahl der Klassen
 - ▶ $w = \frac{d_{\max} - d_{\min}}{n_k}$: Breite der Klassen

$$\forall 0 \leq j \leq n_k - 1 : k_j = \{d_i \in D \mid d_{\min} + w \cdot j \leq d_i < d_{\min} + w \cdot (j+1)\}$$

▶

$$h^*(k_j) = \sum_{d_i \in k_j} h^*(d_i)$$

- ▶ Insbesondere bei kontinuierlichen Werten sinnvoll

Uni-Variate Daten (1D)

Häufigkeitsverteilung: Klasseneinteilung

- ▶ Kategorische Werte
 - ▶ Zusammenfassung abhängig von den Kategorien
- ▶ Numerische Werte
 - ▶ Gleich große Intervalle
 - ▶ Anzahl der Klassen
- ▶ Kontinuierliche Werte
 - ▶ Intervalle rechts oder links offen

$$n_k = \begin{cases} \sqrt{n_d} & n_d \leq 1000 \\ 10 \cdot \log(n_d) & n_d > 1000 \end{cases}$$

- ▶ Anzahl der Unterteilungen soll Verlauf widerspiegeln


Uni-Variate Daten (1D)

Häufigkeitsverteilung: Klasseneinteilung


- ▶ Darstellung mit Histogrammen
 - ▶ Balkendiagramm mit Klassen und deren Häufigkeiten
 - ▶ Form: Rechteck
 - ▶ Breite: konstant
 - ▶ Höhe: $h^*(k_j)$
 - ▶ Positionierung: Koordinatensystem
 - ▶ x-Achse: j
 - ▶ y-Achse: 0
 - ▶ Farbe: konstant
- ▶ Bemerkungen
 - ▶ Falls
 - ▶ $\forall d_j \in D : d_j > 0$
 - ▶ und die Werte umfassen mehrere Größenordnungendann kann es sinnvoll sein,
 - ▶ den Logarithmus der d_j zu berechnen
 - ▶ und die Klasseneinteilung auf den logarithmischen Werten vorzunehmen
 - ▶ Falls $\exists j_0 : d_{j_0} = 0$:
füge eine Klasse mit dem Wert 0 und Häufigkeit $h^*(d_{j_0})$ hinzu

Uni-Variate Daten (1D)

Wert	Häufigkeit
1	3
2	1
3	3
4	2
5	3
6	3




Wert	Häufigkeit
1 – 2	4
3 – 4	5
5 – 6	6




Uni-Variate Daten (1D)

Wert	Häufigkeit
1	1
2	2
3	4
4	3
5	3
6	2




Wert	Häufigkeit
1 – 2	3
3 – 4	7
5 – 6	5




Uni-Variate Daten (1D)

Verteilungen

Linkssteile Verteilung




Rechtssteile Verteilung




Uni-Variate Daten (1D)

Verteilungen

Gleich Verteilung





Symmetrische Verteilung



Uni-Variate Daten (1D)

Verteilungen



Uni-Variate Daten (1D): Beschreibende Statistik

- ▶ Ziel: Reduktion
- ▶ Viele Zahlen → wenige Zahlen

Zentrale Tendenz	Variabilität
Modus	Durchschnittliche absolute Abweichung Varianz, Standardabweichung
Median	
Mittelwert	

- ▶ Kategorische Werte
 - ▶ Modus
- ▶ Geordnete Werte zusätzlich
 - ▶ Median
 - ▶ Durchschnittliche absolute Abweichung
- ▶ Kontinuierliche Werte zusätzlich
 - ▶ Mittelwert
 - ▶ Varianz
 - ▶ Standardabweichung

Uni-Variate Daten (1D): Beschreibende Statistik

- ▶ Modus (mode)
 - ▶ Häufigster Wert:

$$modus = \{d_j | h^*(d_j) = \max_{1 \leq i \leq d_n} \{h^*(d_i)\}\}$$

- ▶ Falls eindeutig:
uni-modale Verteilung
- ▶ Falls nicht eindeutig:
multi-modale Verteilung

Uni-Variate Daten (1D): Beschreibende Statistik

- ▶ Median (median)
- ▶ Mittlerer Wert
- ▶

$$median = \begin{cases} x_i & i = \frac{n+1}{2} & n \text{ ungerade} \\ \frac{x_i + x_{i+1}}{2} & i = \frac{n}{2} & n \text{ gerade} \end{cases}$$

- ▶ ist gleich dem 2.ten Quartil

- ▶ Durchschnittliche absolute Abweichung
- ▶

$$\bar{x} = \frac{1}{n} \cdot \sum_{i=1}^n |x_i - median|$$

- ▶ Es gilt:
 $\sum_{i=1}^n |x_i - m|$ ist minimal
 $\Updownarrow$
 $m = median$

Uni-Variate Daten (1D): Beschreibende Statistik

► Population

- Menge aller möglichen Elemente, die gemessen werden sollen $\{X_i\}$
- Theoretische Konstruktion
- Größe der Population: $N = |\{X_i\}|$

► Messwerte

- Menge aller Elemente, die tatsächlich gemessen wurden $\{x_i\}$
- Teilmenge der zugehörigen Population
- Anzahl der Messwerte: $n = |\{x_i\}|$

	Population	Messwerte
Mittelwert	$\mu = \frac{\sum_{i=1}^N X_i}{N}$	$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$
Varianz	$\sigma^2 = \frac{\sum_{i=1}^N (X_i - \mu)^2}{N}$	$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$
Standardabweichung	$\sigma = \sqrt{\frac{\sum_{i=1}^N (X_i - \mu)^2}{N}}$	$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$

Uni-Variate Daten (1D): Beschreibende Statistik

Mittelwert (mean)

► Alternative Berechnung

$$\begin{aligned}\bar{x} &= \frac{1}{n} \cdot \sum_{i=1}^n x_i \\ &= \frac{1}{n} \cdot \sum_{j=1}^{n_d} h^a(d_j) \cdot d_j \\ &= \sum_{j=1}^{n_d} \frac{1}{n} \cdot h^a(d_j) \cdot d_j \\ &= \sum_{j=1}^{n_d} h^r(d_j) \cdot d_j\end{aligned}$$

► Es gilt

$$\sum_{i=1}^n (x_i - \bar{x}) = 0$$

$$\begin{aligned}\sum_{i=1}^n (x_i - \bar{x})^2 \text{ ist minimal} \\ \Updownarrow \\ \bar{x} = \textit{mean}\end{aligned}$$

Uni-Variate Daten (1D): Beschreibende Statistik

- ▶ Anzahl der Freiheitsgrade
 - ▶ Gegeben:
 - ▶ n Beobachtungen
 - ▶ m Mittelwerte
 - ▶ Frage: Wie viele Beobachtungen können variieren?
 - ▶ Antwort: $n - m$
 - ▶ Begründung für $m = 1$:
Wegen $\sum_{i=1}^n (x_i - \bar{x}) = 0$
können nur $n - 1$ der n Variablen x_i
frei gewählt werden
 - ▶ Daraus ergibt sich der Divisor für s^2

Uni-Variate Daten (1D): Beschreibende Statistik

Bemerkungen

- ▶ Mittelwert, Varianz, Standardabweichung
 - ▶ Empfindlich gegen Ausreißer
 - ▶ Keine (geringe) Aussagekraft bei nicht-symmetrischen Verteilungen
 - ▶ Begrenzte Aussagekraft bei multi-modalen Verteilungen
- ▶ Median
 - ▶ Begrenzte Aussagekraft bei multi-modalen Verteilungen

Verteilung	
Links-seitig	$Modus \leq Median \leq Mittelwert$
Symmetrisch	$Modus = Median = Mittelwert$
Rechts-seitig	$Modus \geq Median \geq Mittelwert$

Uni-Variate Daten (1D): Beschreibende Statistik

► Symmetrie

► Schiefe (skewness)

$$schiefe = \frac{1}{n} \cdot \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3$$

Schiefe	Verteilung
≈ 0	Symmetrisch
$\gg 0$	Links-seitig
$\ll 0$	Rechts-seitig

► Vergleich mit der Normalverteilung

► Wölbung (kurtosis)

$$wölbung = \frac{1}{n} \cdot \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^4$$


► Exzess

$$exzess = wölbung - 3$$

Exzess	Verteilung
≈ 0	Normalgipflig
$\gg 0$	Steilgipflig (schmäler, höher)
$\ll 0$	Flachgipflig (breiter, flacher)

Uni-Variate Daten (1D)

Vergleich mehrerer Verteilungen



► Bemerkungen


- gut:
Vergleich zwischen Häufigkeit 1 und Häufigkeit 2 pro d_j
- nicht immer optimal:
Vergleich der d_j innerhalb Häufigkeit 1 oder Häufigkeit 2
 - Insbesondere, falls kleine Unterschiede bei großem Wertebereich der Häufigkeiten auftreten

Uni-Variate Daten (1D)

Vergleich mehrerer Verteilungen

► Alternative: **Stacked Bar-Chart**

- Gegeben: mehrere Attribute mit Häufigkeiten
- Nur sinnvoll, falls Aggregation der Häufigkeiten im Vordergrund steht
 - Häufigkeit 1: Vergleich einfach
 - Häufigkeit 2: Vergleich nicht offensichtlich
- Ansonsten: betrachte aggregierten Wert als eigenes Attribut



Uni-Variate Daten (1D)

Normalverteilung

► Dichtefunktion

$$f(x, \mu, \sigma) = \frac{1}{\sqrt{2 \cdot \pi \cdot \sigma^2}} \cdot e^{-\frac{(x-\mu)^2}{2 \cdot \sigma^2}}$$

► Mittelwert, Median, Modus: μ

► Varianz: σ^2

► Schiefe: 0

► Wölbung: 3

► Exzess: 0

► Standardnormalverteilung

► $\mu = 0, \sigma = 1$

$$f(x) = \frac{1}{\sqrt{2 \cdot \pi}} \cdot e^{-\frac{x^2}{2}}$$




Abbildung: [Wikipedia]

Uni-Variate Daten (1D)

Poisson-Verteilung

► Dichtefunktion

$$f(k, \lambda) = \frac{\lambda^k}{k!} \cdot e^{-\lambda}$$

- Mittelwert: λ
- Median: $\lambda - \ln(2) \leq \text{median} \leq \lambda + \frac{1}{3}$
- Varianz: λ
- Schiefe: $\frac{1}{\sqrt{\lambda}}$
- Wölbung: $3 + \frac{1}{\lambda}$
- Für kleine λ stark asymmetrisch
- Für $\lambda \geq 30$
 - Annähernd normalverteilt
($\mu = \lambda, \sigma^2 = \lambda$)




Abbildung: [Wikipedia]

Uni-Variate Daten (1D)

Exponentialverteilung

► Dichtefunktion

$$f(x, \lambda) = \begin{cases} \lambda \cdot e^{-\lambda \cdot x} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

► Mittelwert: $\frac{1}{\lambda}$

► Median: $\frac{\ln(2)}{\lambda}$

► Varianz: $\frac{1}{\lambda^2}$

► Schiefe: 2

► Wölbung: 9




Abbildung: [Wikipedia]

Uni-Variate Daten (1D)

Kummulierte Häufigkeiten

- ▶ Voraussetzung: geordnete Daten
- ▶ Frage: Wie viele Werte sind kleiner als der aktuelle Wert?
- ▶ Seien die Werte d_j geordnet: $\forall i < j : d_i \leq d_j$
- ▶ Summiere die Häufigkeiten vom kleinsten bis zum aktuellen Datenpunkt auf

$$H^*(d_k) = \sum_{j=1}^k h^*(d_j)$$



$$d_{p\%} := \max_{1 \leq j \leq n_d} \{d_j | H^*(d_j) \leq p\%\}$$

Uni-Variate Daten (1D)

Quantile

- ▶ Gliederung der Verteilung in Teilbereiche
- ▶ Das Quantil ist der größte Wert d_i unterhalb dessen höchstens $p\%$ der Werte liegen
- ▶ Typisch: Quartile Q_i
 - ▶ 4 Teilbereiche ($n = 4$)
 - ▶ Quartil Q_1 : bis zu 25% der Werte
 - ▶ Quartil Q_2 : bis zu 50% der Werte
 - ▶ Quartil Q_3 : bis zu 75% der Werte
 - ▶ Quartil Q_4 : 100% der Werte
- ▶ Bemerkung
 - ▶ Quartil Q_2 entspricht dem Median

Uni-Variate Daten (1D)

Boxplot

- ▶ Median:
 - ▶ Darstellung: Linie
- ▶ $[d_{25\%}, d_{75\%}]$
 - ▶ Interquartile-Range: $IQR = d_{75\%} - d_{25\%}$
 - ▶ Darstellung: Box

▶ Tukey-Boxplot

- ▶ Whisker
 - ▶ Oberer Whisker: $d_{75\%} + 1,5 \cdot IQR$
 - ▶ Unterer Whisker: $d_{25\%} - 1,5 \cdot IQR$
 - ▶ Darstellung: Balken
- ▶ Ausreißer
 - ▶ Darstellung: individuelle Datenpunkte
 - ▶ Bis $3 \cdot IQR$: "milde Ausreißer"

▶ Min-Max-Boxplot

- ▶ Whisker
 - ▶ Oberer Whisker: d_{max}
 - ▶ Unterer Whisker: d_{min}
 - ▶ Darstellung: Balken
- ▶ Ausreißer
 - ▶ Darstellung: keine

Uni-Variate Daten (1D)

Werte

15

20

25

30

33

34

35

37

40

75




Abbildung: Links: Tukey-Boxplot ohne senkrechte Linien;
Mitte-Links: Tukey-Boxplot;
Mitte-Rechts: Alternative Darstellung des Tukey-Boxplots;
Rechts: Min-Max-Boxplot

Bi-Variate Daten (2D)

► Gegeben

► n Datenpunkte

► 2 Attribute: a_1, a_2

► Werte der Attribute

$$X = \{x_{ij} | 1 \leq i \leq n \wedge 1 \leq j \leq 2\}$$

ID	a_1	a_2
id_1	$x_{1,1}$	$x_{1,2}$
id_2	$x_{2,1}$	$x_{2,2}$
$\dots$		
id_n	$x_{n,1}$	$x_{n,2}$

► Typische Fragen:

► Welchen Zusammenhang gibt es zwischen den Attributen?

► Korrelation
(positive Korrelation)

► Anti-Korrelation
(negative Korrelation)

► Keinen Zusammenhang

► Positive Korrelation

$$\forall 1 \leq i, j \leq n : x_{i,1} < x_{j,1} \rightarrow x_{i,2} \leq x_{j,2}$$

► Negative Korrelation

$$\forall 1 \leq i, j \leq n : x_{i,1} < x_{j,1} \rightarrow x_{i,2} \geq x_{j,2}$$

Bi-Variate Daten (2D)




- ▶ Prinzipiell lassen sich mehrere Attribute mit den bisherigen Charts darstellen
- ▶ Vorgehen:
 - ▶ Wähle ein primäres Attribut
 - ▶ Alle anderen Attribute (“Häufigkeiten”) werden in Bezug auf das primäre Attribut dargestellt
- ▶ Vorteile
 - ▶ Gut für Vergleiche von Attributen gleicher Charakteristik
- ▶ Einschränkungen
 - ▶ Bezug immer nur zu einem Attribut
 - ▶ Häufigkeiten sollten in der gleichen Größenordnung liegen

Bi-Variate Daten (2D)

- ▶ Small-Multiples
 - ▶ Ein Diagramm pro Attribut
 - ▶ Mehrere Diagramme auf der gleichen Zeichenfläche
- ▶ Beispiel Pie-Chart
 - ▶ Mehrere Pie-Charts notwendig
 - ▶ Vergleich bereits innerhalb eines Pie-Charts schwierig

Bi-Variate Daten (2D)


Bar-Charts



Bi-Variate Daten (2D)

Gekoppelte Histogramme

- ▶ Englisch: linked histograms
- ▶ Kopplung durch
 - ▶ Farbe
 - ▶ Pattern (Textur)
 - ▶ Interaktion



(a) Histograms of two attributes
(b) Histograms with adjustable limits for selection purposes
(c) Selected objects are 'ranged down' for easier interpretation

Abbildung: [Spence2001]

Bi-Variate Daten (2D)

- ▶ Tatsächlich wurden schon bisher immer mindestens 2 Attribute betrachtet

Attribut 1	Attribut 2
Wert	Häufigkeit pro Wert
Kategorie	Häufigkeit pro Kategorie

- ▶ Wichtiges Unterscheidungsmerkmal für Attribut 1: Farbe
- ▶ Daraus folgt: Anzahl der gleichzeitig zu betrachtenden Werte oder Kategorien ist auf $\approx 6 - 10$ begrenzt

Bi-Variate Daten (2D)

Scatterplot

- ▶ Gegeben:

$$X = \{x_{ij} | 1 \leq i \leq n \wedge 1 \leq j \leq 2\}$$

- ▶ Für zwei Attribute

- ▶ Mindestens geordnet
- ▶ Meist: numerisch

- ▶ Erlaubt es, eine Korrelation zwischen den beiden Attributen zu erkennen

- ▶ Darstellung:

- ▶ Position $(x, y) = (x_{i,1}, x_{i,2})$
- ▶ Kreis an der Position (x, y)

- ▶ Zusätzlich

- ▶ Koordinatenachsen
- ▶ Eventuell Regressionsgerade


Bi-Variate Daten (2D)

Scatterplot


- ▶ Beachte:
 - ▶ Overplotting bei gleichen Werten
 - ▶ $(x_{i,1}, x_{i,2}) = (x_{j,1}, x_{j,2}), i \neq j$
 - ▶ Skalierung der Achsen
 - ▶ Äquidistant $\leftrightarrow$ Logarithmisch
 - ▶ Achsenkreuzung bei $(0,0)$ oder nicht

Bi-Variate Daten (2D)

Scatterplot



Scatterplot mit Regressionslinie



Tri-Variate Daten (2D)

► Gegeben

► n Datenpunkte

► 3 Attribute

► Werte der Attribute

$$X = \{x_{ij} | 1 \leq i \leq n \wedge 1 \leq j \leq 3\}$$

► Typische Fragen:

► Welchen Zusammenhang gibt es zwischen den Attributen?

► Korrelation

► Anti-Korrelation


► Keinen Zusammenhang

ID	a_1	a_2	a_3
id_1	$x_{1,1}$	$x_{1,2}$	$x_{1,3}$
id_2	$x_{2,1}$	$x_{2,2}$	$x_{2,3}$
...			
id_n	$x_{n,1}$	$x_{n,2}$	$x_{n,3}$

Tri-Variate Daten (2D)

3D-Scatterplot

- ▶ Logische oder geometrische 2D-Projektion der 3D Darstellung
- ▶ Probleme:
 - ▶ 2D-Darstellung eines 3D-Raumes
 - ▶ Wie bestimmt man die Werte der Attribute aus der Darstellung?
 - ▶ Verdeckungsproblem
 - ▶ Datensatz: "Cars" (Autos)



Tri-Variate Daten (2D)

Small Multiples: drei 2D-Scatterplots

► Betrachtung aller achsenparallelen Projektionen (2D-Scatterplots)

► Alle drei möglichen 1-1 Beziehungen können untersucht werden

FIGURE 3.13

Projection of the points in Figure 3.12 onto all pairs of axes



Abbildung: [Spence2001]

Tri-Variate Daten (2D)




Abbildung: Scatterplot-Matrix: Übersichtliche Anordnung von Scatterplots [Spence2001]




Abbildung: Brushing: Markierung gleicher Punkte [Spence2001]

Tri-Variate Daten (2D)

Alternative Darstellung

- ▶ Dimensionen 1 & 2: Position
- ▶ Dimension 3: Größe oder Farbe
- ▶ Nachteil
 - ▶ Unterschiedliche Qualität in der Darstellung der Dimensionen macht es schwierig(er), Korrelationen zu sehen




Abbildung: [Spence2001]

Multi-Variate Daten

► Gegeben

► n Datensätze

► $m > 3$ Attribute

► Werte der Attribute

$$X = \{x_{ij} | 1 \leq i \leq n \wedge 1 \leq j \leq m\}$$

► Typische Fragen:

► Welchen Zusammenhang gibt es zwischen den Attributen?

► Korrelation

► Anti-Korrelation

► Keinen Zusammenhang

ID	a_1	a_2	a_3	$\dots$	a_m
id_1	$x_{1,1}$	$x_{1,2}$	$x_{1,3}$	$\dots$	$x_{1,n}$
id_2	$x_{2,1}$	$x_{2,2}$	$x_{2,3}$	$\dots$	$x_{2,n}$
$\dots$					
id_n	$x_{n,1}$	$x_{n,2}$	$x_{n,3}$	$\dots$	$x_{n,m}$

Multi-Variate Daten

► Problem:

- Mehr als drei Attribute können nicht mehr nur über die Position repräsentiert werden

► Lösungen:

- Übertragung der Tri-Variaten Ansätze
 - Scatterplot-Matrizen
 - Repräsentation mittels anderer visueller Attribute (z.B. Größe)
- Alternative Methoden

Multi-Variate Daten

► “Cars”-Datensatz

Baujahr	Year
Beschleunigung	Acceleration
Leistung	Horsepower
Zylinder	Cylinders
Gewicht	Weight
Herstellungsland	Origin
Reichweite	MPG

► Beispiele: [PWR2004]

Multi-Variate Daten

1. Geometrische Ansätze (Projektion)
2. Achsenbasierte Ansätze
3. Heatmap

Multi-Variate Daten

Geometrische Ansätze (Projektion)


- ▶ Scatterplot-Matrix
 - ▶ Entspricht orthogonaler Projektion
- ▶ Hyperslice
 - ▶ Ohne strikte Festlegung auf orthogonale Projektionen
 - ▶ n^2 Schnitte fester Breite durch Daten legen
- ▶ Prosection Views
 - ▶ Auswahl einer n -dimensionalen Teilmenge (Hyperwürfel)
 - ▶ Wird bei Projektion mit anderer Farbe dargestellt

Multi-Variate Daten: Scatterplot-Matrix


- ▶ Scatterplot:
Korrelation zwischen 2 Attributen
- ▶ m Attribute $\rightarrow m \cdot m$ Attributpaare
- ▶ Bilde $m \times m$ Matrix von Scatterplots

	j_1	j_2	$\dots$	j_m
j_1	$j_1 \times j_1$	$j_1 \times j_2$	$\dots$	$j_1 \times j_m$
j_2	$j_2 \times j_1$	$j_2 \times j_2$	$\dots$	$j_2 \times j_m$
$\dots$				
j_m	$j_m \times j_1$	$j_m \times j_2$	$\dots$	$j_m \times j_m$

Multi-Variate Daten: Scatterplot-Matrix




(a)



(b)

Multi-Variate Daten: Scatterplot-Matrix

- ▶ Eigenschaften
 - ▶ Scatterplots auf der Diagonale
 - ▶ Gleiches Attribut für x- und y-Achse
 - ▶ Besser: Histogramm (Bar-Chart)
 - ▶ Oberes und unteres Dreieck der Matrix enthalten gespiegelte Scatterplots
- ▶ $\rightarrow \frac{m^2 - m}{2}$ **verschiedene** binäre Korrelationen



(b)

Multi-Variate Daten: Scatterplot-Matrix




Abbildung: Scatterplot [LMvW2010]: Erkennung von Korrelationen

Multi-Variate Daten: Hyperslice




Abbildung: [vWvL1993],[AGK2002]

Multi-Variate Daten: Prosection-Views




Abbildung: [FB1994], [SDTS1995], [AGK2002]

Multi-Variate Daten


Achsenbasierte Ansätze

1. Scatterplot & Scatterplot Matrizen
2. Parallele Koordinaten
3. Star Plot
4. Flexible Linked Axes


Multi-Variate Daten: Parallele Koordinaten

- ▶ m Attribute $\rightarrow m$ Achsen
- ▶ Anordnung der Achsen: parallel
 - ▶ Scatterplot: orthogonal
- ▶ Jede Achse j wird skaliert:
 - ▶ $\min_{1 \leq i \leq n}(x_{ij})$
 - ▶ $\max_{1 \leq i \leq n}(x_{ij})$
- ▶ Für jedes i wird ein Polygonzug mit Kanten $(x_{i,j}, x_{i,j+1})$, $1 \leq j \leq m-1$ gezeichnet

- ▶ Beispiel
 - ▶ $n = 3, m = 2$
 - ▶ blau und rot: gleiche Richtung
 - ▶ grün: entgegengesetzt zu blau und rot



Multi-Variate Daten: Parallele Koordinaten



Multi-Variate Daten: Parallele Koordinaten

- ▶ Linienzüge zeigen lineare Abhängigkeiten der Daten
- ▶ Die Polygonzüge schneiden sich zwischen zwei Achsen in maximal einem Punkt
- ▶ Man kann Regeln für k -dimensionale Unterräume ableiten [Inselberg 1998]




Abbildung: [<http://davis.wpi.edu/xmdv/>]

Multi-Variate Daten: Parallele Koordinaten




Abbildung: Leichtes Rauschen verursacht Probleme [AGK2002]

Multi-Variate Daten: Parallele Koordinaten




Abbildung: Parallele Koordinaten [LMvW2010]: Erkennung von Korrelationen

Multi-Variate Daten: Parallele Koordinaten

- ▶ Eigenschaften
 - ▶ Anzeige von $m - 1$ Korrelationen
 - ▶ Reihenfolge der Achsen bestimmt, welche Korrelationen sichtbar sind
 - ▶ [HYFC2014]
 - ▶ Positive Korrelationen und deren Stärke sind relativ schwer zu erkennen
 - ▶ Negative Korrelationen und deren Stärke sind relativ einfach zu erkennen
 - ▶ Mehr Überlappungen als bei Punkt-basierten Darstellungen
- ▶ Erweiterungen
 - ▶ Brushing (Parvis)
 - ▶ Transferfunktionen
 - ▶ Clusterbildung
 - ▶ Fokus und Kontext (Kapitel “Interaktion”)

Multi-Variate Daten: Parallele Koordinaten




Abbildung: Parvis




Abbildung: Parvis: Brushing

Multi-Variate Daten: Parallele Koordinaten




Abbildung: Parvis: Brushing + Histogram

Multi-Variate Daten: Parallele Koordinaten




Abbildung: Parvis: Auswahl über Achsenabschnitte und Winkel (in rot) → Fokus

Multi-Variate Daten: Parallele Koordinaten




Abbildung: Lineare Transferfunktion angewendet auf eine hochauflösende Textur um Überdeckungen zu reduzieren und einen Überblick über die Daten zu geben. [Johan2005]

Multi-Variate Daten: Parallele Koordinaten




Abbildung: Logarithmische Transferfunktion angewandt auf einen ausgewählten Cluster: Die Struktur bleibt erhalten und Regionen geringer Dichte werden hervorgehoben. [Johan2005]

Multi-Variate Daten: Parallele Koordinaten




Abbildung: Transferfunktion unter Verwendung der Quadratwurzel: Ausreißer von lokalen Clustern werden hervorgehoben. [Johan2005]

Multi-Variate Daten: Parallele Koordinaten





Abbildung: Komplementäre Ansicht der Cluster: uniforme Bandstruktur. [Johan2005]


Multi-Variate Daten: Star-Plot

- ▶ m Attribute $\rightarrow m$ Achsen
- ▶ Anordnung der Achsen: Stern-förmig
- ▶ Verbindung von $x_{i,j}$ mit $x_{i,j+1}$,
 $0 \leq j \leq m-1$
- ▶ Zusätzliche Verbindung von $x_{i,m}$ mit $x_{i,1}$
- ▶ Anzeige von m Korrelationen
- ▶ Ergibt geschlossenen Polygonzug (Polygon)
- ▶ Meist zum qualitativen Vergleich der Form



Multi-Variate Daten: Star-Plot

- ▶ Andere Bezeichnungen
 - ▶ Radar-Chart
 - ▶ Kiviat-Diagramm



Multi-Variate Daten: Star-Plot Varianten




Abbildung: Ein Stern für alle Datenpunkte






Abbildung: Ein Stern pro Datenpunkt

[<http://seamonkey.ed.asu.edu/~behrens/asu/reports/compre/comp1.html>]

Multi-Variate Daten: Star-Plot




(a)



(b)

Multi-Variate Daten: Star-Plot

- ▶ Eigenschaften
 - ▶ siehe auch: Parallele Koordinaten
 - ▶ Unterschiedliche Qualität der Achsen durch unterschiedliche Richtungen
 - ▶ Abstand zwischen zwei Achsen
 - ▶ Klein nahe dem Zentrum
 - ▶ Groß nahe dem Rand



Multi-Variate Daten: Heatmap

- ▶ Daten
 - ▶ Darstellung von
 - ▶ Korrelationen zwischen zwei Attributen
 - ▶ in einer Matrix
 - ▶ Stärke der Korrelation im Intervall $[-1;1]$




Abbildung: [<https://commons.wikimedia.org/w/index.php?curid=1612199>]

Multi-Variate Daten: Heatmap

- ▶ Visuelle Abbildung
 - ▶ Wertebereich: $[-1; 1]$
 - ▶ Je ein Farbton für
 - ▶ positive Werte
 - ▶ negative Werte
 - ▶ Größe der Werte
 - ▶ Sättigung
 - ▶ Helligkeit
- ▶ GröÙte Sättigung oder Helligkeit
 - ▶ negative Werte: -1
 - ▶ positive Werte: 1
- ▶ Neutrale Farbe für 0
 - ▶ Schwarz
 - ▶ Weiß




Abbildung: [<https://commons.wikimedia.org/w/index.php?curid=1612199>]

Multi-Variate Daten: Heatmap

- ▶ Mapping in der Abbildung
 - ▶ 0: neutral → schwarz
 - ▶ < 0 : rot
 - ▶ > 0 : grün
- ▶ Absoluter Betrag des Wertes
 - ▶ Helligkeit
- ▶ Mapping ungünstig bei rot-grün Sehschwäche





Abbildung: [<https://commons.wikimedia.org/w/index.php?curid=1612199>]

Multi-Variate Daten: Heatmap

- ▶ Mapping in der Abbildung
 - ▶ 0: neutral → schwarz
 - ▶ < 0 : rot
 - ▶ > 0 : grün
 - ▶ keine Werte: neutral → weiß
- ▶ Absoluter Betrag des Wertes
 - ▶ Helligkeit



Multi-Variate Daten

- ▶ Einige Techniken sind besonders geeignet für
 - ▶ kategorische Attribute
 - ▶ ordinale Attribute
- ▶ Mischungen möglich mit
 - ▶ kontinuierlichen Attributen
- ▶ Ordinale Attribute
 - ▶ Führen mit einer kleinen Wertmenge zu auffälligen Clustern
 - ▶ Diese springen dem Anwender ins Auge
 - ▶ Überbetonen damit diese Attribute

Literatur

- [Spence2001] R. Spence.
Information Visualization.
Addison-Wesley, Reading, MA, USA, 2001.
- [WGK2011] M. Ward, G. Grinstein, D. Keim.
Interactive Data Visualization: foundations, techniques, and
applications.
A K Peters. Ltd, 2011.
- [AGK2002] M. Ankerst, G. Grinstein, D. Keim.
Visual Data Mining.
Tutorial at KDD 2002.

Literatur

- [Cleveland] W. S. Cleveland.
Visualizing Data.
AT&T Bell Laboratories, Murray Hill, NJ, revised edition.
- [vWvL1993] Jark van Wijk, Robert van Liere.
Hyperslice.
Proc. IEEE Visualization, 1993.
- [FB1994] George W. Furnas, Andreas Buja.
Prosecution Views: Dimensional Inference through Sections
and Projections.
Journal of Computational and Graphical Statistics,
Vol. 3, No. 4, 1994, pp. 323–353.

Literatur

- [SDTS1995] H. Su, H. Dawkes, L. Tweedie, R. Spence.
An Interactive Visualization Tool for Tolerance Design.
Technical Report, Imperial College, London, 1995.
- [AC1991] Alpen und Carten.
Hyperbox.
Proc. IEEE Visualization, pp. 133–139, 1991.
- [HYFC2014] Lane Harrison, Fumeng Yang, Steven Franconeri, Remco Chang.
Ranking Visualizations of Correlation Using Weber's Law.
IEEE TVCG Vol. 20(12), 2014.

Literatur

- [Joha2005] Jimmy Johansson.
Revealing Structure within Clustered Parallel Coordinates Displays.
InfoVis, 2005.