



UNIVERSITÄT
LEIPZIG

5. Vorlesung: Clustering

INTERACTIVE VISUAL DATA MINING

Übersicht

5. Clustering

5.1 Überblick

5.2 k-means Clustering


5.3 Clusterqualität

5.4 Hierarchisches Clustering



Lernziele:

- Clustering definieren und Einsatzgebiete verstehen
- Clustering-Strategien unterscheiden und Eigenschaften erklären
- k-means Algorithmus anwenden und interpretieren
- Clusterqualität mit gängigen Metriken bewerten und zur Wahl von k nutzen
- Hierarchische Clustering-Verfahren anwenden und Dendrogramme interpretieren

Erzeugung von Clustern



Erzeugung von Clustern



Erzeugung von Clustern

- Clustering

- Gegeben

Sei $D = \{d_1, \dots, d_n\}$ eine Menge von Objekten.

- Gesucht

Klassen $K = \{C_1, \dots, C_k\}$, $k \ll n$

- Bedingungen

- $D = \bigcup_{i=1}^k C_i$

- $\forall i \neq j: C_i \cap C_j = \emptyset$ (Partitionierung)

- Unüberwachtes Lernverfahren


- Motivation

- Suche nach Gemeinsamkeiten und Unterschieden


- Suche nach zusätzlicher Struktur in den Daten

- Ersetzen von Mengen von Datenpunkten (die Cluster) durch ihre Repräsentanten

- Analyse der Cluster anstelle der Datenpunkte




Erzeugung von Clustern




<https://scikit-learn.org/stable/modules/clustering.html>

Erzeugung von Clustern

- Partitionierendes Clustering
 - Unterteilung des Raumes
 - Zeichne Grenzen zwischen Clustern
 - Beispiel: k-means clustering




- Hierarchisches Clustering
 - Erzeugt einen Baum
 - Verwende Dendrogramme zur Darstellung
 - Beispiele:
 - Hierarchical Agglomerative Clustering
 - Divisive Hierarchical Clustering



Erzeugung von Clustern

- Überlappendes Clustering
 - Darstellung: Venn-Diagramm



- Probabilistisches Clustering
 - Weise jedem Element eine Wahrscheinlichkeit zu, mit der es zu den Clustern gehört
 - Die Wahrscheinlichkeiten summieren sich zu 1


	1	2	3
a	0,4	0,1	0,5
b	0,1	0,8	0,1
c	0,3	0,3	0,4
d	0,1	0,1	0,8
e	0,4	0,2	0,4
f	0,1	0,4	0,5
g	0,7	0,2	0,1
h	0,5	0,4	0,1

Erzeugung von Clustern

- Dichtebasiertes Clustering
- Idee: Cluster entstehen in Bereichen hoher Dichte, Ausreißer werden ignoriert.
- Vorteil: Kann beliebige Formen von Clustern finden, robust gegen Ausreißer.
- Häufige Verfahren:
 - DBSCAN (Density-Based Spatial Clustering of Applications with Noise)
 - HDBSCAN (Hierarchical DBSCAN)
 - OPTICS (Ordering Points To Identify the Clustering Structure)

– Weitere Verfahren


- Grid-basiertes Clustering
- Spektrales Clustering
- Graph-basiertes Clustering
- Und vieles mehr...



k-means Clustering

1. Spezifiziere die Anzahl der Cluster: k
2. Wähle zufällig k Punkte $z_1, \dots, z_k$: Cluster-Zentren
3. Weise alle Instanzen d_i ihrem nächsten Cluster-Zentrum zu
4. Metrik: z.B. Euklid'sche Distanz
5. Berechne das neue Zentrum (mean) aller Cluster aus den zugehörigen Instanzen
6. Falls Cluster nicht stabil $\rightarrow$ Schritt 3

- Cluster sind stabil
 - Die Zuweisung der Instanzen zu den Clustern bleibt unverändert
- Komplexität Schritt 3: $O(k \cdot n \cdot m)$
- Komplexität Schritt 5: $O(n \cdot m)$



k-means Clustering

- Qualität

- Berechne

$$q = \sum_{i=1}^k \sum_{j=1}^{n_i} (d_{i,j} - z_i)^2$$

- z_i : Zentrum des i -ten Clusters
 - $d_{i,j}$: j -ter Punkt des i -ten Clusters
 - $n_i = |C_i|$


- Problematik

- Berechnet ein lokales Minimum q , aber nicht notwendigerweise das globale Minimum
 - Ergebnis ist abhängig von
 - k
 - den gewählten Startzentren der Cluster
 - der „empty-Cluster“ Strategie
 - Splitte „größten Cluster“
 - größte Anzahl
 - größte Varianz
 - Nehme vom Zentroiden des Clusters am weitesten entfernten Punkt

k-means Clustering Algorithmus

– Interaktive Demo:

○ <http://alekseynp.com/viz/k-means.html>



k-means Clustering

- Verbesserungsmöglichkeit
 - Lasse k-means mehrfach mit verschiedenen Startzentren laufen
 - Wähle Ergebnis mit geringstem q
- Optimierung der Wahl der Startzentren: k-means++
 - Wähle ersten Startpunkt zufällig
 - Wähle nächsten Punkt aus den verbleibenden Punkten mit Wahrscheinlichkeit proportional zur Entfernung zu allen bisherigen Punkten
 - Erhöht
 - Konvergenzgeschwindigkeit
 - Genauigkeit

k-means Clustering

- Beschleunigung:
 - Raumteilungsverfahren
 - k-d-Bäume (k-dimensionale Bäume)
 - Ball-Trees
 - Parallelisierung

k-means Clustering

- k-d-Bäume (k-dimensionale Bäume)
 - k : Anzahl der Dimensionen
 - entspricht der Anzahl der Attribute m
 - Aufbau: $O(k \cdot n \cdot \log n)$
 - Sortiere n Punkte nach k Attributen
- Nearest-Neighbor-Suche: $O(n \cdot \log n)$
- Sinnvoll bei
 - Vielen Datenpunkten
 - Wenigen Dimensionen
(Langsam für $m > 8$ [HD2015])

k-means Clustering

- Wie findet man optimales k ?

1. Schätzung der Anzahl der Cluster [MKB1979]:

$$k = \sqrt{\frac{n}{2}}$$

2. Nutze Domänenwissen zur Abschätzung der Anzahl der Cluster (ist vorzuziehen)
3. Variiere Anzahl der Cluster k , ausgehend von initialem Wert (z.B. $k - 2, \dots, k + 2$)

- Problem: Evaluation des Ergebnisses

- Optimal: $k = n \rightarrow q = 0$
- im Allgemeinen werden größere k bevorzugt

- Mögliche Lösung: Cluster Indices

- Relative Indices
 - Davies-Bouldin Index [DB1979]
 - Modified Hubert Γ [HA1985]
- Dunn Index [BP1998]
- Silhouette Coefficient [Rou1987]

Clusterqualität

Davies Bouldin Index

- Kohäsion

$$S_i = \left(\frac{1}{n_i} \sum_{j=1}^{n_i} |d_{i,j} - z_i|^p \right)^{\frac{1}{p}}$$

- Trennung

$$M_{i,j} = \|z_i - z_j\|_p = \left(\sum_{k=1}^m |z_{i,k} - z_{j,k}|^p \right)^{\frac{1}{p}}$$

- Maß für Qualität des Clusterings für i und j

$$R_{i,j} = \frac{S_i + S_j}{M_{i,j}}$$

- Schlechtester Wert für i
 $D_i = \max_{j \neq i} \{R_{i,j}\}$

- Davies-Bouldin Index

$$DB := \frac{1}{k} \sum_{i=1}^k D_i$$

Clusterqualität

Davies Bouldin Index


- Komplexität
 - S_i : $O(n \cdot m)$
 - $M_{i,j}$: $O(m)$
 - $R_{i,j}$: $O(n \cdot m + n \cdot m + m) = O(n \cdot m)$
 - D_i : $O(k \cdot n \cdot m)$
 - DB : $O(k \cdot k \cdot n \cdot m) = O(k^2 \cdot n \cdot m)$

Clusterqualität

Davies Bouldin Index

k	Davies Bouldin Index
3	1,06957
4	1,16492
5	1,02300
6	1,00282
7	1,06513
8	1,02402
9	1,02164

- Wähle k mit kleinstem Index: 6



Clusterqualität

Dunn Index

- Berechnung

$$DI_k = \frac{\min_{1 \leq i < j \leq k} \delta(C_i, C_j)}{\max_{1 \leq l \leq k} \Delta_l}$$

- $\delta(C_i, C_j)$: Abstand zwischen Cluster i und j
- Δ_l : Kohäsion des Clusters l
- Komplexität: abhängig von $\delta(C_i, C_j)$ und Δ_l

- Δ_l

- Maximale Distanz zweier Elemente des Clusters l

$$\Delta_l = \max_{x, y \in C_l} d(x, y)$$

- Durchschnittliche Distanz zweier Elemente des Clusters l

$$\Delta_l = \frac{1}{|C_l| \cdot (|C_l| - 1)} \cdot \sum_{x, y \in C_l, x \neq y} d(x, y)$$

- Abstände aller Punkte vom Zentrum des Clusters l

$$\Delta_l = \frac{\sum_{x \in C_l} d(x, z_l)}{|C_l|}$$

Clusterqualität

Dunn Index

– $\delta(C_i, C_j)$

- Minimaler Abstand zwischen zwei Punkten

$$\delta(C_i, C_j) = \min_{x \in C_i, y \in C_j} \{d(x, y)\}$$

- Maximaler Abstand zwischen zwei Punkten

$$\delta(C_i, C_j) = \max_{x \in C_i, y \in C_j} \{d(x, y)\}$$

- Durchschnitt aller Abstände zwischen zwei Punkten

$$\delta(C_i, C_j) = \frac{1}{|C_i| \cdot |C_j|} \sum_{x \in C_i, y \in C_j} d(x, y)$$

– $\delta(C_i, C_j)$

- Abstand der Cluster-Zentren

$$\delta(C_i, C_j) = d(z_i, z_j)$$

- Durchschnitt der Abstände zum anderen Cluster-Zentrum

$$\delta(C_i, C_j) = \frac{1}{|C_i| + |C_j|} \cdot \left(\sum_{x \in C_i} d(x, z_j) + \sum_{x \in C_j} d(x, z_i) \right)$$

- Maximum der minimalen Abstände von Punkten zweier Cluster

$$\delta(C_i, C_j) = \max\{\delta'(C_i, C_j), \delta'(C_j, C_i)\}$$


$$\delta'(C_i, C_j) = \max_{x \in C_i} \min_{y \in C_j} \{d(x, y)\}$$

Clusterqualität

Dunn Index

k	Dunn Index
3	$3,00291 \cdot 10^{-5}$
4	$3,67348 \cdot 10^{-5}$
5	$1,95366 \cdot 10^{-5}$
6	$0,55217 \cdot 10^{-5}$
7	$3,67917 \cdot 10^{-5}$
8	$2,71530 \cdot 10^{-5}$
9	$3,25993 \cdot 10^{-5}$

- Wähle k mit dem größten Index: 7



Clusterqualität

- Modified Hubert Γ

- Clusterindikator

$$L(i) = k$$

Objekt i gehört zu Cluster k

- Matrizen

$$X(i, j) = |d_i - d_j|$$

$$Y(i, j) = |z_{L(i)} - z_{L(j)}|$$

- Modified Hubert Γ

$$\Gamma = \sum_{i=1}^{n-1} \sum_{j=i+1}^n (X(i, j) \cdot Y(i, j))$$

- Komplexität

- $O(n \cdot n \cdot m \cdot m) = O(n^2 \cdot m^2)$


- unabhängig von k

Clusterqualität

- Modified Hubert Γ

k	Modified Hubert
3	$1,01844 \cdot 10^{11}$
4	$0,97873 \cdot 10^{11}$
5	$1,11428 \cdot 10^{11}$
6	$1,15922 \cdot 10^{11}$
7	$1,15276 \cdot 10^{11}$
8	$1,08876 \cdot 10^{11}$
9	$1,10869 \cdot 10^{11}$

- Wähle k nach dem größten Anstieg: 5
- Oder wähle k mit dem größten Index: 6



Clusterqualität

Silhouette Coefficient

- Berechnung

$$s(d_i) = \frac{d(d_i, C_n) - d(d_i, C_l)}{\max\{d(d_i, C_l), d(d_i, C_n)\}}$$

- Abstand zwischen d_i und einem Cluster C

$$d(d_i, C) = \frac{1}{n_C} \cdot \sum_{d_j \in C} d(d_i, d_j)$$

- C_l : Cluster von d_i

- $C_n = \operatorname{argmin}_{C \neq C_l} d(d_i, C)$: Cluster, der Element mit kleinstem Abstand zu d_i enthält

- Komplexität


$$O(n^2 \cdot m \cdot k)$$

- Auswertung

	relationship
$0,75 < s(i) \leq 1$	strong
$0,5 < s(i) \leq 0,75$	normal
$0,25 < s(i) \leq 0,5$	weak
$0 < s(i) \leq 0,25$	no

Clusterqualität

- Silhouette Coefficient




Clusterqualität

- Frage: Welches Clustering ist die richtige?
 - Im Allgemeinen nicht entscheidbar
 - Wissen für ein Kriterium, dass ein Wert für k besser ist als ein anderer, das heißt aber nicht dass es korrekter ist
 - Metriken nicht alleine verwenden, sondern mehrere vergleiche
- Zusatzfragen
 - Welches Verfahren soll gewählt werden?
 - Welche Parameter sollen für das Verfahren gewählt werden?
 - Wie viele Cluster sollen gewählt werden?

Evidence Accumulation


- Ensemble-Clustering
 - Unterteile (Split)
 - Unterteile die Daten in mehrere Kugelförmige Cluster
 - Berechne N -mal k-means mit unterschiedlichen Initialisierungen
 - Verbinde (Combine)
 - Berechne
$$co_assoc(i,j) = \frac{votes_{i,j}}{N}$$
 - $votes_{i,j}$: Anzahl der Durchläufe bei denen i und j im gleichen Cluster liegen

- Vereinige (Merge)
 - Verwende Minimalen Spannbaum mit Schwellwert t um Cluster zu bestimmen



Evidence Accumulation

- Algorithmus
 - N -mal
 - Wähle k Cluster-Zentren
 - Berechne Clustering mit k-means
 - Aktualisiere die Co-Assoziationsmatrix
$$co_assoc(i, j) \leftarrow co_assoc(i, j) + \frac{1}{N}$$
 - Für alle Paare (i, j)
 - Falls $t \leq co_assoc(i, j)$ vereinige die Cluster in denen i und j liegen
 - Für alle Objekte, die nicht in einem Cluster liegen
 - Bilde ein-elementigen Cluster mit diesem Objekt



Evidence Accumulation

– Ergebnis 4-mal k-means mit $k = 2$

Objekt	Lauf 1	Lauf 2	Lauf 3	Lauf 4
d_1	1	2	2	1
d_2	1	2	2	1
d_3	1	2	1	1
d_4	1	2	1	1
d_5	2	1	2	2
d_6	2	1	2	2
d_7	2	1	2	2

– Assoziationsmatrix

	d_1	d_2	d_3	d_4	d_5	d_6	d_7
d_1	1	1	0,75	0,75	0,25	0,25	0,25
d_2	1	1	0,75	0,75	0,25	0,25	0,25
d_3	0,75	0,75	1	1	0	0	0
d_4	0,75	0,75	1	1	0	0	0
d_5	0,25	0,25	0	0	1	1	1
d_6	0,25	0,25	0	0	1	1	1
d_7	0,25	0,25	0	0	1	1	1

Evidence Accumulation

- Ergebnis 4-mal k-means mit $k = 2$

	d_1	d_2	d_3	d_4	d_5	d_6	d_7
d_1	1	1	0,75	0,75	0,25	0,25	0,25
d_2	1	1	0,75	0,75	0,25	0,25	0,25
d_3	0,75	0,75	1	1	0	0	0
d_4	0,75	0,75	1	1	0	0	0
d_5	0,25	0,25	0	0	1	1	1
d_6	0,25	0,25	0	0	1	1	1
d_7	0,25	0,25	0	0	1	1	1


- Ergebnis
 - $0 \leq t \leq 0,25$:
 $\{d_1, d_2, d_3, d_4, d_5, d_6, d_7\}$
 - $0,25 < t \leq 0,75$:
 $\{d_1, d_2, d_3, d_4\}, \{d_5, d_6, d_7\}$
 - $0,75 < t \leq 1$:
 $\{d_1, d_2\}, \{d_3, d_4\}, \{d_5, d_6, d_7\}$

Evidence Accumulation


- Bemerkungen
 - Zur Unterteilung können beliebige Cluster-Verfahren benutzt werden
 - Die Matrix benötigt $O(n^2)$ Speicher
→ ungünstig bei großem n
 - Alternative
 - Speichere für jeden Durchlauf in welchem Cluster das Objekt liegt
(Speicher: $O(n \cdot k)$)
 - Berechne Hamming-Distanz der Clustervektoren
 - Hamming Distanz 1 gruppiert alle Objekte, welche in allen Durchläufen im jeweils gleichen Cluster waren

Hierarchisches Clustering

- Hierarchical Agglomerative Clustering
 - Bottom-Up Technik
 - Anfangszustand:
 - Jedes Objekt ist in einer eigenen Klasse
 - $g = m$
 - $\forall i: C_i^0 = \{d_i\}$
 - $G^0 := \{C_1^0, \dots, C_g^0\}$




- Divisive Hierarchical Clustering
 - Top-Down Technik
 - Anfangszustand:
 - Alle Objekte sind in einer Klasse
 - $g = 1$
 - $G^0 = \{C_1^0\} = \{\{d_1, \dots, d_m\}\}$



Hierarchisches Clustering


- Hierarchical Agglomerative Clustering

- Wähle ein Ähnlichkeitsmaß s
- Vereinige die beiden ähnlichsten Klassen:
 - Seien $j \neq k: s(C_j^0, C_k^0)$ maximal
 - $C_j^1 = C_j^0 \cup C_k^0$
 - $G^1 = G^0 \setminus \{C_j^0, C_k^0\} \cup C_j^1$



- Divisive Hierarchical Clustering

- Wähle ein Abstandsmaß t
- Unterteile C_1^0 in zwei Klassen:
 - $G^1 := \{C_1^1, C_2^1\}$
 - $C_1^1 \cup C_2^1 = D$
 - $C_1^1 \cap C_2^1 = \emptyset$
 - $t(C_1^1, C_2^1)$ ist maximal



Hierarchisches Clustering

- Hierarchical Agglomerative Clustering

- Wiederhole bis nur noch eine Klasse vorhanden ist:

$$G^m = \{C_1^m\} = \{\{d_1, \dots, d_m\}\}$$

- Endzustand entspricht Ausgangszustand des „Divisive Hierarchical Clustering“

- Divisive Hierarchical Clustering



- Wiederhole bis jede Klasse genau ein Objekt enthält:

- $g = m$

- $\forall i: C_i^m = \{d_i\}$


- $G^m := \{C_1^m, \dots, C_g^m\}$

- Endzustand entspricht Ausgangszustand des „Hierarchical Agglomerative Clustering“




Hierarchisches Clustering

- Dendrogramm
 - Baumartige Darstellung des hierarchischen Clustering
 - Zeigt, wie Datenpunkte schrittweise zu Clustern zusammengeführt werden
 - Keine vorherige Festlegung der Clusteranzahl nötig
 - Anzahl der Cluster kann visuell bestimmt werden





Hierarchisches Clustering

- Achsen-Interpretation
 - x-Achse: Datenpunkte bzw. Cluster (Reihenfolge ist nicht entscheidend)
 - y-Achse (Höhe): Distanz zwischen Clustern
- Wie liest man ein Dendrogramm?
 - Unten (Blätter): einzelne Datenpunkte
 - Vertikale Linien: Zusammenführung von Clustern
 - Höhe der Verbindung:
 - niedrig = hohe Ähnlichkeit (frühe Fusion)
 - hoch = geringe Ähnlichkeit (späte Fusion)



Hierarchisches Clustering

- Wie wählen wir die Anzahl Cluster?
 - Visuell
 - Suche nach „großen Sprüngen“ in der Höhe
 - Domänenwissen
- Fester Schwellwert
 - Horizontale Schnittlinie im Dendrogramm
 - Alles Verbindungen unterhalb der Linie bleiben erhalten
 - niedriger Cut → viele kleine Cluster
 - hoher Cut → wenige große Cluster
- Multi-Level Cuts
 - Wähle für Teilbäume verschiedene Schwellwert je nach Struktur der Daten
 - Algorithmisch z. B. Dynamic Tree Cut Peter Langfelder et al. (2008).



Bildquelle: Vogogias, A., et al. (2016). Mlcut: Exploring multi-level cuts in dendrograms for biological data. In *Computer graphics and visual computing conference (CGVC)*.

Hierarchisches Clustering

- Hierarchical Agglomerative Clustering
- Oft: Euklid'sche Distanz
- Beachte: nicht invariant bezüglich Skalierung





- Maße:

- Single Linkage:





$$t_{SL}(C_k, C_l) := \min_{d_i \in C_k, d_j \in C_l} \{ |d_i - d_j|_2 \}$$

- Complete Linkage:

$$t_{CL}(C_k, C_l) := \max_{d_i \in C_k, d_j \in C_l} \{ |d_i - d_j|_2 \}$$



Hierarchisches Clustering



Bildquelle: <https://www.learndatasci.com/glossary/hierarchical-clustering/>