



UNIVERSITÄT
LEIPZIG

10. Vorlesung Neuronale Netze Fortführung

INTERACTIVE VISUAL DATA MINING

Übersicht

10. Neuronale Netze - Fortsetzung

10.1 CNN

10.2 Autoencoder

10.3 Generative Adversarial Networks


10.4 XAI

10.5 RNN, LSTM

NEURONALE NETZE

- (Deep) Feed Forward Networks
 - Propagation immer in Richtung der Ausgabeknoten
- Einfache Perceptrons
- Multilayer Perceptrons
- Tiefe wird über die Anzahl an Hidden Layer und Kanten erreicht

Feed Forward (FF)



Deep Feed Forward (DFF)




NEURONALE NETZE

- Motivation: Warum CNN?
 - Vollvernetzte Netze skalieren nicht auf Bilder
 - Jedes Pixel ist ein eigener Eingang
 - Bild 1000×1000 Pixel in RGB = 3 Mio. Eingänge
 - Eine Schicht mit 1000 Neuronen $\Rightarrow$ ca. 3 Mrd. Gewichte
 - Räumliche Struktur geht verloren
 - Benachbarte Pixel gehören zusammen, werden aber unabhängig behandelt
 - Kein Wissen über Verschiebung
 - Objekt oben links vs. unten rechts müsste neu gelernt werden
- Die Idee hinter CNNs
 - Lokale Filter (Kernel) statt vollständiger Vernetzung
 - Gewichte werden über das ganze Bild geteilt (Weight Sharing)
 - Dadurch deutlich weniger Parameter
 - Robuster gegen Verschiebung und Skalierung
 - Nutzt die räumliche Struktur der Daten aus

NEURONALE NETZE

- Konvolution
 - Beispielsweise sind in Bilddaten Kanten und Texturen relevant für die Erkennung
 - Zusammensetzen von Pixeln zu Strukturen in Netzen nur mit vielen Neuronen
 - Zusammenspiel von Farbwerten ebenso kompliziert
 - Idee: Vorverarbeitung des Bildes mittels Filter, sodass Kanten und Texturen vorab extrahiert werden



NEURONALE NETZE

- Konvolution
 - Nutzung eines Kernels, um die Datenwerte zu transformieren
 - In der Regel in eine kleinere Matrix
 - Verschiedene Kernel möglich, z.B. um Kanten zu erkennen
 - Konzept aus der Bildverarbeitung

1 _{x1}	1 _{x0}	1 _{x1}	0	0
0 _{x0}	1 _{x1}	1 _{x0}	1	0
0 _{x1}	0 _{x0}	1 _{x1}	1	1
0	0	1	1	0
0	1	1	0	0

Image

4		

Convolved
Feature


NEURONALE NETZE

- Konvolution

- 1D Konvolution


- Transformation eines Datenbereichs in 1D auf einen 1D Datenbereich

- Z.B. für Zeitserien



- 3D Konvolution

- Insbesondere für 3 dimensionale Bilddaten (MRT etc)



NEURONALE NETZE

- Konvolution
 - Datenbereiche werden durch spezifische Filter auf bestimmte Eigenschaften zusammengefasst
 - Daten können dann im Netz schneller verarbeitet werden
- Kernel werden per Neuronen im Netz dargestellt
- Neuronen haben gemeinsame Gewichte
 - Extrahierte Features sind an jeder Stelle gleich wichtig
 - Deutlich weniger Kanten notwendig
 - Robuster gegenüber Translation, Skalierung

NEURONALE NETZE


- Pooling
 - Reduktion der Eingabedaten für die weitere Verarbeitung
 - Speicherbedarf & Rechenzeit
- Extraktion von dominanten Features
 - Translations- und Positionsinvariant

3.0	3.0	3.0
3.0	3.0	3.0
3.0	2.0	3.0

3	3	2	1	0
0	0	1	3	1
3	1	2	2	3
2	0	0	2	2
2	0	0	0	1


NEURONALE NETZE

- Pooling
- Berechnung für einen Ausschnitt der Daten einen Repräsentanten:
 - Max Pooling
 - Übernahme des größten Wertes als Repräsentanten
 - Average Pooling
 - Mittelwert als Repräsentant
- Max Pooling ist in der Regel performanter



NEURONALE NETZE


- Deep Convolutional Networks
 - Eine oder mehrere Convolution Layer
 - Feature Extraktion per Faltung
 - Pooling
 - Danach Verarbeitung durch ein tiefes Netz



NEURONALE NETZE


- Durchbruch: ImageNet & AlexNet (2012)
 - ImageNet (ab 2009): ca. 14 Mio. Bilder, ILSVRC mit 1000 Klassen
- Erst große Datensätze machen tiefe Netze trainierbar
- 2012: AlexNet (Krizhevsky et al.) gewinnt ILSVRC deutlich
 - Tiefes CNN auf GPUs, ReLU + Dropout
- Auslöser des Deep-Learning-Booms

Top-5-Fehlerrate (ILSVRC)



NEURONALE NETZE

- Autoencoder
- Daten werden durch Hidden Layer komprimiert und dann durch weniger Ausgabeknoten rekonstruiert
- Approximation
- Benötigt keine annotierten Daten
- Unsupervised Learning
- Extrahiert wichtige Features oder Dimensionen aus den Daten



NEURONALE NETZE


- Autoencoder
 - Encoder komprimiert die Eingabe in einen niedrigdimensionalen Raum (Latent Space / Flaschenhals)
 - Decoder rekonstruiert daraus die Eingabe
 - Loss = Rekonstruktionsfehler
 - Ziel ist die Eingabe selbst → keine Labels nötig (self-supervised)
- Anwendungen:
 - Dimensionsreduktion
 - Denoising: Rauschen aus Daten entfernen
 - Anomalieerkennung: großer Rekonstruktionsfehler = Ausreißer
 - Variante: Variational Autoencoder (VAE) zur Datengenerierung

NEURONALE NETZE

- Generative Adversarial Networks
 - Kombination von Netzen
 - Ein Netz generiert aus Zufallsdaten eine Ausgabe
 - Ein zweites Netz bekommt „echte“ und generierte Daten präsentiert
 - Backpropagation in beiden Netzen, je nach Fehlerart
- “Echter” Datenpunkt wird als generiert klassifiziert
 - Erkennungsnetz wird auf den Fehler trainiert
- Generierter Datensatz wird als generiert klassifiziert
 - Generatornetz wird auf den Fehler trainiert
- Beide Netze werden durch die Epochen stetig besser
- Nutzung bei Bildern, Texten oder Spiel-KI

NEURONALE NETZE

- Generative Adversarial Networks
 - Generator G: macht aus Zufallsrauschen z möglichst echte Daten
 - Diskriminator D: unterscheidet echte von generierten Daten
- Wettstreit (Minimax / Nullsummenspiel):
G will D täuschen, D will G entlarven
- Im Gleichgewicht erzeugt G Daten, die D nicht mehr unterscheiden kann
- Bekanntes Problem: Trainingsinstabilität / Mode Collapse



NEURONALE NETZE

- GAN – Beispiel: Style Transfer
 - Stil eines Bildes auf ein anderes übertragen
 - Inhalt bleibt, der Stil ändert sich
- Bild-zu-Bild-Übersetzung mit GANs
 - Foto ↔ Gemälde
 - Pferd ↔ Zebra, Sommer ↔ Winter
- Generator erzeugt das Bild, Diskriminator prüft den Zielstil
 - CycleGAN braucht keine paarweisen Trainingsbilder




NEURONALE NETZE

- Explainable Artificial Intelligence (XAI)
 - Relativ neues Forschungsfeld seit 2004
 - Öffnen des Blackbox Verfahrens (posthoc)
 - Sog. „Glassbox“ Verfahren
 - Mittlerweile auch im Fokus der Gesetzgebung z. B. DSGVO oder EU AI Act: Auskunft- & Begründungspflichten
- XAI beinhaltet Themen wie:
 - Erstellung von erklärbaren Modellen, welche aber auch eine hohe Genauigkeit haben
 - Zugriffsmöglichkeiten im Modell für den Nutzer (human in the loop)
 - Transparenz der genutzten Datenverarbeitung
 - Debugging: Fehler, Shortcuts & Datenlecks im Modell finden
 - Fairness: Diskriminierung aufdecken


NEURONALE NETZE

- Darstellung des Netzes
- Visuelle Darstellung als Graph mit Layern
- Kantengewichte werden nach Ausprägung eingezeichnet
- Welche Pfade sind besonders schwach/stark?
- Skalierungsprobleme
- <http://alexlenail.me/NN-SVG/AlexNet.html>




NEURONALE NETZE

- Saliency Map
- Markierung der Bereiche in den Daten, die besonders wichtig für die Klassifikation waren
- Insbesondere in der Bildverarbeitung nützlich
- Rückrechnung des Klassifikationsergebnisses durch das Netz
- Identifikation von Neuronen, die besonders stark aktiviert wurden



NEURONALE NETZE

- Saliency Map
- Beispielsweise durch die „Layer-wise Relevance Propagation“
- Klassifikationsergebnis wird Layerweise auf den Einfluss der einzelnen Neuronen analysiert
- Eingangsneuronen erhalten damit einen Wert für ihre Bedeutung
- Erstellung eines „Negativs“ der Eingabedaten
- Vergleich der „Bilder“




NEURONALE NETZE


- Saliency Map
 - Funktioniert gut mit Bilddaten
 - Textdaten sind auch möglich, Zusammenhänge werden aber unklar
 - Auswertung von hochdimensionalen Daten weiterhin problematisch
- <https://lrpserver.hhi.fraunhofer.de/handwriting-classification>
- <https://lrpserver.hhi.fraunhofer.de/text-classification>

NEURONALE NETZE

- Class Activation Mapping
- Nutzung eines Global Average Pooling Layers vor der Klassifikation
- Addition der einzelnen Pooling Ergebnisse, um klassenspezifische Saliency Map zu erstellen
- Kann auch zur Lokalisierung im Bild genutzt werden



NEURONALE NETZE



Class activation maps of top 5 predictions




Class activation maps for one object class

NEURONALE NETZE

- Recurrent Neural Networks
 - Neuronen können nun auch mit Neuronen der gleichen oder vorherigen Schicht verbunden werden
 - Zyklen
 - Hilfreich bei Sequenzen
 - Bilderkennung
 - Sprachübersetzung

NEURONALE NETZE


- Recurrent Neural Networks
 - Das Netz besitzt einen Hidden State (Gedächtnis), der von Schritt zu Schritt weitergereicht wird
 - Je Zeitschritt: Eingabe x_t + vorheriger Hidden State $h_{(t-1)} \rightarrow$ neuer Hidden State h_t
 - Unrolling: dasselbe Netz (gleiche Gewichte) wird über die Zeit aufgefaltet
 - Training per Backpropagation Through Time
 - Über viele Zeitschritte verschwindet oder explodiert der Gradient $\rightarrow$ lange Abhängigkeiten schwer lernbar



NEURONALE NETZE

- RNN – Sprachbeispiel
- Aufgabe: das nächste Wort vorhersagen
- Satz: „Der Himmel ist ____“
 - Das Netz liest die Wörter nacheinander
 - Der Hidden State (Gedächtnis) wird weitergereicht
- Vorhersage nutzt den gesamten bisherigen Kontext
 - Ergebnis hier: „blau“
- Kurze Zusammenhänge funktionieren gut

RNN – aufgefaltet über die Zeit




Hidden State (Gedächtnis) fließt weiter →

NEURONALE NETZE


- Long Short Term Memory
- Verbesserung für Netze mit vielen Layern
- Bei der Backpropagation wird der Fehler von hinten nach vorne immer weiter skaliert
 - Verschwindet oder Explodiert dadurch
- Tiefe Netze werden dadurch nicht vollständig „genutzt“

Long / Short Term Memory (LSTM)



NEURONALE NETZE

- Long Short Term Memory
 - Input Gate steuert den Effekt, den ein neuer Wert auf die Zelle C hat
 - Forget Gate steuert den Effekt, wie stark ein Wert in der Zelle bleibt oder vergessen wird
 - Output Gate steuert den Effekt, wie stark dieser Effekt im nächsten Neuron wirken soll
 - Hierdurch bleibt der Fehler konstanter erhalten und Rekurrente Netze sind besser lernbar



NEURONALE NETZE

- LSTM – Sprachbeispiel
 - Problem: lange Abhängigkeiten im Satz
 - Das entscheidende Wort steht weit vorne („Frankreich“)
 - Gesucht ist am Satzende: „Französisch“
 - Einfaches RNN vergisst weit entfernten Kontext
 - Verschwindender Gradient
 - LSTM-Gates halten den Kontext über viele Schritte
 - Forget-, Input- und Output-Gate

Lange Abhängigkeit

Ich bin in **Frankreich** aufgewachsen, ...
deshalb spreche ich fließend ____



LSTM hält „Frankreich“ im Zellzustand – auch viele Wörter später