



UNIVERSITÄT
LEIPZIG

6. Vorlesung: Dimensionsreduktion

INTERACTIVE VISUAL DATA MINING

Übersicht der Vorlesung (aktualisiert)

07.4. Einführung

14.4. Data Mining & Datenaufbereitung

21.4. Entscheidungsbäume

28.4. Regression und Nearest Neighbor Klassifikation

05.5. Clustering

12.5. Dimensionsreduktion

19.5. **Kein Termin**

26.5. Support Vektor Maschine

02.6. Evaluierung

09.6. **Kein Termin**

16.6. Neuronale Netze 1

23.6. Neuronale Netze 2

30.6. Vertiefung: Transformer?

07.7. Wiederholung

ÜBERSICHT

6. Dimensionsreduktion

- 6.1 Einleitung
- 6.2 Factor Analyse
- 6.3 Principal Component Analysis (PCA)
- 6.4 Multi-Dimensional Scaling (MDS)
- 6.5 T-distributed Stochastic Neighborhood Embedding (t-SNE)
- 6.6 Uniform Manifold Approximation and Projection for Dimension Reduction (UMAP)
- 6.7 Ausblick


Lernziele:

- . Verstehen, warum Dimensionsreduktion notwendig ist und wie man Ergebnisse interpretiert.
- . Factor Analyse, PCA und MDS verstehen, sowie die Gemeinsamkeiten und Unterschiede kennen.
- . Grenzen und typische Artefakte von Dimensionsreduktion kennen.
- . T-SNE und UMAP verstehen sowie Unterschiede zwischen den Methoden und Einfluss der Parameter kennen.


EINLEITUNG

– Curse of Dimensionality

- In niedrigen Dimensionen sind Daten relativ dicht
- In hohen Dimensionen wird der Raum extrem groß und leer
- Nächste und fernste Punkte haben fast gleiche Distanz, dadurch verlieren Distanzen an Bedeutung



- Um die gleiche Dichte wie in 2D zu erreichen, bräuchte man exponentiell mehr Datenpunkte



EINLEITUNG

- Ausgangssituation
 - Tabelle mit n Datenpunkten und m Attributen

ID	Attribut 1	Attribut 2	Attribut 3	...	Attribut m
id_1	$a_{1,1}$	$a_{1,2}$	$a_{1,3}$		$a_{1,m}$
id_2	$a_{2,1}$	$a_{2,2}$	$a_{2,3}$		$a_{2,m}$
...					
id_n	$a_{n,1}$	$a_{n,2}$	$a_{n,3}$		$a_{n,m}$

- Problem
 - Mehr Daten oder Attribute als Darstellungsfläche
- Lösung
 - Datenauswahl
 - Einschränkung der Attribute
 - Einschränkung der Attributwerte (Filtern)
 - Dimensionsreduktion
 - Clustering

EINLEITUNG

- Projektion

- Wähle $d \in \{2, 3\}$ Attribute
- Führt in der Regel zu vielen „gleichen“ Datenpunkten → Overplotting
- Probleme
 - Welche Attribute werden betrachtet?
 - Berücksichtigt die Werte und die Verteilung der Werte der Datenpunkte nicht

- Dimensionsreduktion

- Ersetze gegebene Attribute

$$A = \{A_1, \dots, A_m\}$$

durch eine Menge von weniger Attributen

$$D = \{D_1, \dots, D_d\}$$

$$d \ll m$$

- Meist: $d \in \{2, 3\}$
- Alternativen:
 - $D \subseteq A$: entspricht Projektion
 - $D \cap A = \emptyset$
 - Die neuen Attribute werden aus den alten berechnet
 - Kombination aus beidem

EINLEITUNG

- Verfahren:
 - Factor Analysis
 - Principal Component Analysis (PCA)
 - Multi-Dimensional Scaling (MDS)
 - T-distributed Stochastic Neighborhood Embedding (t-SNE)
 - Uniform Manifold Approximation and Projection (UMAP)
- Andere Möglichkeiten
 - Autoencoder
 - Visuelle Metaphern, um die Dimensionen anzuordnen
 - Viele Varianten von PCA, MDS, t-SNE und UMAP
- **Achtung!**
- Für alle Verfahren gilt:
 - Information, die nicht erhoben wurde, wird durch eine Analyse nicht hinzugefügt
 - Beware of „garbage in, garbage out“:
 - Das Verfahren findet immer Faktoren
 - Hintergrund-/Domänen-Wissen ist notwendig, um zu entscheiden, ob die Faktoren einen Wert haben


FACTOR ANALYSIS

- Arten
 - Typ Q
 - Zusammenfassung der Datenpunkte
 - Aufwändige Berechnung
 - Meist wird stattdessen Clustering verwendet
 - Typ R
 - Finde „verborgene Dimensionen“ (Gruppen von korrelierten Variablen)
- Ziele:
 - Identifikation von Strukturen
 - Zusammenfassung der Daten
 - Reduktion der Daten
- Eigenschaften:
 - Gruppen sind disjunkt
 - Gruppen können von ihren Mitgliedern repräsentiert werden

FACTOR ANALYSIS

– Typ Q Faktor-Analyse – Clustering

	V_1	V_2	V_3
A	7	7	8
B	8	6	6
C	2	2	3
D	3	1	1



– Faktor-Analyse

– Gruppe 1: A, C

– Gruppe 2: B, D

– Clustering

– Gruppe 1: A, B

– Gruppe 2: C, D

FACTOR ANALYSIS

- Typ R
- Anzahl der Datenpunkte $\gg$ Anzahl der Variablen
 - Minimum 50 – 100 Datenpunkte
 - typische Faustregel für mittlere Datensätze: $\# \text{Datenpunkte} = 5-10 \cdot \# \text{Variablen}$
 - Stabiler: $\# \text{Datenpunkte} = 20 \cdot \# \text{Variablen}$
- Verwendung von möglichst wenig Variablen
- Verwendung von möglichst vielen Datenpunkten
- Anwendbarkeit
 - Bartlett's Test auf Sphärizität
 - Nullhypothese: die Korrelationsmatrix ist gleich der Einheitsmatrix
 - Signifikanz: $p < 0,05$
 - Nullhypothese wird abgelehnt $\rightarrow$ Faktoranalyse möglich
 - Voraussetzung: multivariate Normalverteilung
 - $X^2 = -\left(n - 1 - \frac{2 \cdot m + 5}{6}\right) \log(\det(R))$
 - R : Korrelationsmatrix

FACTOR ANALYSIS

Auswahl der Variablen: Measure of Sampling Adequacy (MSA)

- Gesamt und für jede der m Variablen
- Variablen mit kleineren Werten werden von der Faktoranalyse ausgenommen
- $\forall 1 \leq j \leq m$:

$$MSA_j := \frac{\sum_{k \neq j} r_{jk}^2}{\sum_{k \neq j} r_{jk}^2 + \sum_{k \neq j} p_{jk}^2}$$

- r_{jk} : Korrelation zwischen j und k
- p_{jk} : partielle Korrelation zwischen j und k

- Auswertung
 - $< 0,5$: Variable ungeeignet
 - $0,6 < MSA_j \leq 0,8$: Variable brauchbar
 - $> 0,8$: Variable gut geeignet

- Partielle Korrelation:

$$p_{jk,l} = \frac{r_{jk} - r_{jl} \cdot r_{kl}}{\sqrt{(1 - r_{jl}^2) \cdot (1 - r_{kl}^2)}}$$

FACTOR ANALYSIS

- Spektrale Zerlegung : $R = U\Lambda U^T$
- Λ Eigenwertmatrix:
 - Eigenwerte geben an, wie viel Varianz ein Faktor erklärt, betrachte nur Werte ≥ 1
- U Eigenvektormatrix
 - Eigenvektoren zeigen, wie stark jede Variable zu einem Faktor gehört (Ladung).
- Auswahl der Faktoren
 - Fest: zum Beispiel in der Visualisierung
 - Betrachte Eigenwerte ≥ 1
 - Betrachtete Varianz: Üblich: 95%
 - Summiere die von den Faktoren berücksichtigte Varianz bis ein Schwellwert überschritten wird
- Projiziere Werte X mit den k ausgewählten Eigenvektoren
 - $Z = X U_k$
- Nachbearbeitung Rotation
 - Zeilen: Variablen
 - Spalten: Faktoren
 - Einträge: Beitrag der Variablen zu einem Faktor
- VARIMAX
 - Optimierte Beiträge der Variablen zu einem Faktor, so dass sie nahe 1 oder nahe 0 sind
 - Verschiebt das Koordinatensystem so, dass jede Variable möglichst nahe an einer Achse (einem Faktor) liegt

FACTOR ANALYSIS



- Varianz besteht aus
 - Gemeinsame Varianz mehrerer Variablen
 - Anteil der Varianz einer Variable, der von den gemeinsamen Faktoren erklärt wird.
 - Zeigt, wie stark die Variable mit anderen Variablen zusammenhängt
 - Spezifische Varianz einer Variablen
 - Anteil der Varianz, der nur von dieser einen Variable stammt, also nicht durch Faktoren erklärt wird.
 - Fehler-Varianz
 - Zufällige Messfehler, die nicht durch Faktoren erklärbar sind.
- Common Factor Analysis
 - Betrachtet nur die gemeinsame Varianz der Variablen
 - Spezifische und Fehler-Varianz werden nicht betrachtet
- Component Analysis / Principal Component Analysis
 - Betrachtet gesamte Varianz der Variablen

PRINCIPAL COMPONENT ANALYSIS (PCA)

- Gegeben: m möglicherweise korrelierte beobachtete Variablen $x_1, \dots, x_m$
- Ergebnis: $p < m$ unkorrelierte Variablen (principal components)
- Anforderung: p soll so klein wie möglich sein
- Visualisierung: $p \in \{2, 3\}$
Alternativ: Wähle p , so dass eine möglichst große Varianz abgedeckt wird und verwende Scatterplot-Matrizen

PRINCIPAL COMPONENT ANALYSIS (PCA)

- 30 Beobachtungen
- t_1 : Richtung der größten Variation (Diffusion, Abweichung)
- t_2 : Richtung der zweitgrößte Variation (Diffusion, Abweichung)
- ...



PRINCIPAL COMPONENT ANALYSIS (PCA)

- Andere Namen
 - Karhunen-Loève Transformation (KLT, Bildverarbeitung)
 - Empirical orthogonal functions (Meteorologie, Geophysik)
 - Hotelling Transformation
 - Proper orthogonal decomposition (POD)
 - Deutsch: Hauptkomponentenanalyse
- Ziele
 - Berechne eine reduzierte Menge von Dimensionen
 - Orthogonal
 - Linear
 - Ordne die Dimensionen absteigend bezüglich der Varianz
- Varianz
 - Maß für den Informationsgehalt einer Variable
- Mathematisch
 - Suche eine neue Basis des Vektorraumes

PRINCIPAL COMPONENT ANALYSIS (PCA)

- Konstruktion

- Gegeben: $X = (X_1, \dots, X_m), X_j = (x_{1,j}, \dots, x_{n,j})^T$

- Mittelwert: $\mu = (\mu_1, \dots, \mu_m), \mu_j = \frac{1}{n} \cdot \sum_{i=1}^n x_{i,j}$

- Zentrierte Werte: $Y = (y_{ij}), y_{ij} = x_{ij} - \mu_j$

- Kovarianz-Matrix: $C = \frac{1}{n-1} \cdot Y^T Y$

- Symmetrisch $\rightarrow$ spektrale Zerlegung möglich

- Spektrale Zerlegung: $C = U \Lambda U^T, U^T U = I_m$

- Eigenwert Matrix: $\Lambda = \begin{pmatrix} \lambda_1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \lambda_m \end{pmatrix}$

- Eigenvektor Matrix: $U = (u_1, \dots, u_m)$

- Ordne die Eigenwerte absteigend: $i > j \rightarrow \lambda_i > \lambda_j$

PRINCIPAL COMPONENT ANALYSIS (PCA)

- Anwendung auf die Daten:
 - $U_p = (u_1, \dots, u_p)$ die Matrix der besten p Eigenvektoren und die neuen PCA-Koordinaten: $Z = Y U_p$
- Eigenschaften:
 - λ_1, u_1 : größte Varianz
 - ...
 - λ_p, u_p : p -größte Varianz
 - Die höchsten p Eigenwerte beschreiben einen Großteil der Varianz
 - Principal components mit einer Varianz nahe 0 können verwendet werden, um Ausreißer zu identifizieren
- Einschränkungen:
 - Das Ergebnis ist abhängig von der Skalierung der einzelnen Variablen (Attribute)
 - Ausreißer haben einen großen Einfluss auf das Ergebnis
 - Lineare Methode
 - Interpretation der Basis (Ergebnisse)

PRINCIPAL COMPONENT ANALYSIS (PCA)



Bildquelle: <https://numiqo.com/lab/pca>

MULTI-DIMENSIONAL SCALING (MDS)

- Gegeben: eine Tabelle mit Ähnlichkeiten/Abständen
- Gesucht: Abbildung der Datenpunkte von einem Koordinatensystem in ein anderes, welche die Abstände möglichst gut widerspiegelt
- Es existieren viele mögliche Zielkoordinatensysteme, die die gegebenen Distanzen annähernd erfüllen
- Bedingungen
 - Minimum: die Dimension des Zielsystems soll so klein wie möglich sein
 - Fehlerminimierung und Monotonie: Die Abstände im Zielraum sollen die ursprünglichen Distanzen bestmöglich approximieren, wobei die Rangordnung der Distanzen erhalten bleibt (kleinere Originaldistanzen entsprechen kleineren Zielabständen).
 - Metrisches MDS: Minimiert die Abweichung der tatsächlichen Distanzen.
 - Nichtmetrisches MDS: Minimiert die Abweichung unter Erhalt der Rangordnung der Distanzen

MULTI-DIMENSIONAL SCALING (MDS)


- Gegeben: $X = (x_1, \dots, x_n)$, $x_i \in \mathbb{R}^m$
- Gesucht: $Y = (y_1, \dots, y_n)$, $y_i \in \mathbb{R}^d$, $d \ll m$
- $t_{ij} = \|x_i - x_j\|$
- Bedingung: $\|y_i - y_j\| \approx t_{ij}$, $\forall i, j$
- In der Visualisierung: $d = 2$ oder $d = 3$
- Minimierung der Kostenfunktion:
$$\min \sum_{i < j} (\|y_i - y_j\| - t_{ij})^2$$

MULTI-DIMENSIONAL SCALING (MDS)


- Metrisches Multi-Dimensional Scaling
- Gegeben: Distanzmatrix T ($n \times n$) von n Punkten mit Distanzen t_{ij}
- $A = (a_{ij}) = -\frac{t_{ij}^2}{2}$
- $B = (b_{ij})$, mit $b_{ij} = a_{ij} - \frac{1}{n} \sum_{k=1}^n a_{ik} - \frac{1}{n} \sum_{l=1}^n a_{lj} + \frac{1}{n^2} \sum_{k=1}^n \sum_{l=1}^n a_{kl}$
- Bestimme mittels spektraler Zerlegung (Eigenwertzerlegung) die Eigenwerte λ_i und die zugehörigen Eigenvektoren u_i der symmetrischen Matrix B mit $B u_i = \lambda_i u_i$ bzw. $B = U \Lambda U^T$
- Wähle die d Eigenvektoren mit den größten Eigenwerten
- Vergleichbar mit der PCA

DIMENSIONAL REDUCTION ARTIFACTS


- Geometrische Verzerrungen: Beeinflussen die Abstände zwischen Punkten, erhalten jedoch Nachbarschaften.



- Topologische Verzerrungen: Betreffen sowohl Abstände als auch Nachbarschaften.




Bildquelle: Visualizing distortions and recovering topology in continuous projection techniques, M. Aupetit, Neurocomputing, 2007



Bildquelle: ProxiViz: an Interactive Visualization Technique to Overcome Multidimensional Scaling Artifacts, N. Heulot, M. Aupetit, JD. Fekete, VIS 2012


T-DISTRIBUTED STOCHASTIC NEIGHBORHOOD EMBEDDING (T-SNE)

- Daten werden in 2 - 3 dimensionalen Raum eingebettet zur Visualisierung von Mustern (nur Visualisierung!)
- T-SNE versucht die lokale Verteilung (Nachbarschaften) der Daten zu bewahren, aber globale Abstände werden weniger genau dargestellt
- Achtung: Distanzen zwischen Clustern haben keine Bedeutung
- Nicht-deterministisches Ergebnis
- Nicht-lineare Methode, anders als PCA. Das bedeutet, sie kann komplexe, nicht-lineare Strukturen in den Daten besser abbilden.



T-SNE


- t-SNE hat mehrere Parameter
 - Anzahl der Dimensionen
- Perplexity: Wie viele Datenpunkte sollen im Gauss Kernel liegen
 - Niedrig: wenig Nachbarn – mehr lokal
 - Hoch: viele Nachbarn – mehr global
- Maximale Iterationen
- theta: Schwellwertparameter für die Barnes-Hut Optimierung, um weit entfernte Punkte zusammenzufassen



Bildquelle: <https://biostatsquid.com/easy-t-sne-explained-with-an-example/>


T-SNE

- Platziere einen Gauss-Kernel über dem Punkt i und berechne die Wahrscheinlichkeiten aller Nachbarn.
- Für jeden Punkt i muss die Breite des Kernels (σ_i) angepasst werden (Perplexity).
- Berechne die bedingten Wahrscheinlichkeiten $p_{j|i}$ zwischen allen Punkten i und j auf Basis der Distanz und dem Kernel
- Wandel die abhängigen Wahrscheinlichkeiten in symmetrische Wahrscheinlichkeiten p_{ij} um.



$$p_{j|i} = \frac{\exp(-\|\mathbf{x}_i - \mathbf{x}_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|\mathbf{x}_i - \mathbf{x}_k\|^2 / 2\sigma_i^2)}$$


$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{2N}$$



T-SNE

- Platziere jeden Punkt zufällig in eine 2D Ebene
- Berechne für jeden Punkt eine Wahrscheinlichkeit q_{ij} basierend auf der Student t-Verteilung
 - Ein Freiheitsgrad (df=1)
- Optimierte die Einbettung durch Gradient Walk, bis die Wahrscheinlichkeiten zu den hochdimensionalen Wahrscheinlichkeiten “passen” (iteratives verschieben)
- Kullback-Leibler Divergenz wird minimiert als Metrik für die Platzierung

$$q_{ij} = \frac{(1 + \|\mathbf{y}_i - \mathbf{y}_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|\mathbf{y}_k - \mathbf{y}_l\|^2)^{-1}}$$




$$KL(P||Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

T-SNE

- Skaliert schlecht auf großen Datensätze (Optimierungen notwendig)
- Hohe Rechen- und Speicherkomplexität $O(n^2)$
- Laufzeit abhängig von Start- und Zieldimension, Perplexity und Iterationen
- Mit Optimierungen (z. B. Barnes-Hut): $O(n \log n)$ durch Verwendung eines Quadrees zur Beschleunigung der Gradientenberechnung
- Vorverarbeitung mit PCA zur Reduktion der Rechenzeit ist möglich
- Erzeugt keine deterministischen Ergebnisse

LIVE DEMO

– Demo: <https://distill.pub/2016/misread-tsne/>




T-VISNE



Chatzimpampas, A., Martins, R. M., & Kerren, A. (2020). t-viSNE: Interactive assessment and interpretation of t-sne projections. IEEE TVCG

UMAP


- Uniform Manifold Approximation and Projection for Dimension Reduction (UMAP)
- t-SNE: probabilistischer Ansatz (Wahrscheinlichkeiten) vs. UMAP: topologischer Ansatz (Mannigfaltigkeit + Graphstruktur)
- Berechnet auch bedingte Wahrscheinlichkeiten, diese konstruieren aber einen k-Nearest-Neighbor-Graphen
- Nutzt als zentralen Parameter die Anzahl der Nearest-Neighbor anstatt Perplexity und ist deutlich schneller



UMAP

- Konstruiere Graphen: Für jeden Datenpunkt finde die k nächsten Nachbarn
- σ_i lokale Skalierung, sodass die Nachbarschaftsdichte zwischen Punkten trotz unterschiedlicher lokaler Verteilungen vergleichbar wird.
- Berechne für jedes Nachbarpaar x_i, x_j die lokale Ähnlichkeit:

$$p_{ij} = \exp \left(- \frac{\max(0, d(x_i, x_j) - \rho_i)}{\sigma_i} \right)$$




- Lokale Mindestdistanz:

$$\rho_i = \min\{d(x_i, x_j) \mid x_j \in \text{kNN}(i)\}$$

UMAP

- Konstruiere Graphen: Für jeden Datenpunkt finde die k nächsten Nachbarn
- σ_i lokale Skalierung, sodass die Nachbarschaftsdichte zwischen Punkten trotz unterschiedlicher lokaler Verteilungen vergleichbar wird.
- Berechne für jedes Nachbarpaar x_i, x_j die lokale Ähnlichkeit:

$$p_{ij} = \exp \left(- \frac{\max(0, d(x_i, x_j) - \rho_i)}{\sigma_i} \right)$$




- Lokale Mindestdistanz:

$$\rho_i = \min\{d(x_i, x_j) \mid x_j \in \text{kNN}(i)\}$$

UMAP

- Konstruiere Graphen: Für jeden Datenpunkt finde die k nächsten Nachbarn
- σ_i lokale Skalierung, sodass die Nachbarschaftsdichte zwischen Punkten trotz unterschiedlicher lokaler Verteilungen vergleichbar wird.
- Berechne für jedes Nachbarpaar x_i, x_j die lokale Ähnlichkeit:

$$p_{ij} = \exp \left(- \frac{\max(0, d(x_i, x_j) - \rho_i)}{\sigma_i} \right)$$



- Lokale Mindestdistanz:

$$\rho_i = \min\{d(x_i, x_j) \mid x_j \in \text{kNN}(i)\}$$

- Symmetrisierung: Die gerichteten Ähnlichkeiten werden kombiniert


$$p_{ij}^{\text{sym}} = p_{ij} + p_{ji} - p_{ij} \cdot p_{ji}$$

UMAP

- Punkte werden im niedrigdimensionalen Raum (z. B. 2D) initialisiert: zufällig oder mit spektraler Methode
- Spektrale Initialisierung nutzt Eigenvektoren der Graph-Laplacian Matrix L (Gradmatrix – Adjazenzmatrix)
- Diagonale → kodiert Anzahl Nachbarn
Rest → kodiert Nachbarschaft
- Eigenvektoren → geben eine Anordnung der Punkte im Raum. Stark verbundene Punkte bekommen ähnliche Werte

$$D = \begin{bmatrix} 2 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 2 \end{bmatrix}$$


$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$



$$L = \begin{bmatrix} 2 & -1 & -1 & 0 \\ -1 & 3 & -1 & -1 \\ -1 & -1 & 3 & -1 \\ 0 & -1 & -1 & 2 \end{bmatrix}$$

UMAP

- Optimierung iterativ: ziehe Nachbarn zusammen und drücke Nicht-Nachbarn auseinander
- Minimiere die Differenz zwischen hoch- und niedrigdimensionaler Struktur mit Cross Entropie (entspricht Maximierung der Log-likelihood siehe VL 4)
 - Cross-Entropie misst, wie unterschiedlich zwei Wahrscheinlichkeitsverteilungen sind
- Niedrigdimensionale Ähnlichkeit
 - a steuert die Skalierung der Kurve
 - b steuert die Form der Abnahme
 - Standardmäßig werden a und b so gewählt, dass der Parameter *min_dist* erfüllt wird




$$-\sum_{i,j} \left[p_{ij}^{sym} \log q_{ij} + (1 - p_{ij}^{sym}) \log(1 - q_{ij}) \right]$$

$$q_{ij} = \frac{1}{1 + a \|y_i - y_j\|^{2b}}$$

UMAP VS. T-SNE

- Demo: <https://pair-code.github.io/understanding-umap/>




UMAP - ZUSAMMENFASSUNG

- Konserviert oft globale Strukturen in der Einbettung besser als t-SNE
- Kann durch diese Veränderungen wesentlich mehr Datenpunkte verarbeiten:
 - k-Nearest-Neighbor-Graph anstatt globale Paarvergleiche, dadurch werden nur lokale Beziehungen betrachtet, ohne eine globale Normalisierung über alle Punkte durchführen zu müssen
 - Die Optimierung erfolgt anschließend effizient über Stochastic Gradient Descent
- Limitierungen von t-SNE und UMAP:
 - Die Achsen in der Einbettung haben keine interpretierbare Bedeutung
 - Abstände zwischen Clustern sind nicht quantitativ zuverlässig.
 - Beide Verfahren sind primär auf lokale Struktur ausgelegt.

OVERPLOTING

- Bei starken Overplotting bieten sich Overlap Removal Algorithmen an
- DGrid: Hilaraca et al. (2023). A grid-based method for removing overlaps of dimensionality reduction scatterplot layouts.



Bildquelle: Instance-Centric Visualization of Probabilistic Multi-Label Data, F. Kuschetzki & C. Meinecke, EuroVis Workshop on Visual Analytics, 2026

PAPER BROWSER

Papers: 71

Keywords search:

Search...

OPEN SUMMARY DIALOG

Visualization Types:

2D (63) 3D (9) 1D+ (6) 2D+ (8)

Dimension Reduction Methods:

PCA (57) OTHER (8) TSNE (10)

UMAP (7) OTHERS (1)

Annotation:

LABEL (36) HIGHLIGHT (19) CAPTION (58)

NONE (6)

Interpretation:

SINGLE CLUSTERS (23)


COMPARE CLUSTERS (44) GP (15)

SINGLE POINTS (10) COMPARE POINTS (6)

RELATIONS TO OTHER VARIABLES (24)


OUTLIERS (5) GLOBAL (14) NONE (3)

Raspberry, Rape, Thyme, Sunflower and Mint Honeys Authentication ...
Sensors 2020




2d pca label highlight
caption single clusters
compare clusters

Quantitative analysis of SERS spectra of MnSOD over fluctuated aptamer signals using multivariate ...
Nanophotonics 2019




2d pca highlight
caption compare clusters
gp

Principal Component Analysis as a Statistical Tool for Concrete Mix ...
Materials 2021




3d 2d pca highlight
caption single points
compare points single clusters
relations to other variables

In Situ X-ray Diffraction Study of Xe and CO2 Adsorption in Y Zeolite: compare between Rietveld and PCA ...
Crystals 2020




2d 1d+ pca caption
single clusters gp
relations to other variables

Event generation and statistical sampling for physics with deep generative models and a density ...
Nature Communications 2021



2d pca other caption
single points gp

The Use of UV Spectroscopy and SIMCA for the Authentication of Indonesian Honeys According to ...
Molecules 2021




2d pca caption
single clusters compare clusters
gp

Research on the application of liquid-liquid extraction-gas chromatography-mass spectrometry.
International Journal of Food Engineering 2020



2d pca label highlight
caption single clusters
compare clusters gp

Metabolite Fingerprinting Using 1H-NMR Spectroscopy and Chemometrics for Classification of ...
Molecules 2021




2d pca other label
caption single clusters
compare clusters gp



A Critical Analysis of the Usage of Dimensionality Reduction in Four Domains (2025) Cashman et al. IEEE TVCG
<https://dimension-reduction-vis.github.io/>

TRENDS

(a) Citation # of DR techniques over subject domains




(b) Citation # of each technique



Bildquelle: A Critical Analysis of the Usage of Dimensionality Reduction in Four Domains (2025) Cashman et al. IEEE TVCG

TRENDS



Bildquelle: A Critical Analysis of the Usage of Dimensionality Reduction in Four Domains (2025) Cashman et al. IEEE TVCG