



UNIVERSITÄT
LEIPZIG

2. Vorlesung: Data Mining & Datenaufbereitung

INTERACTIVE VISUAL DATA MINING

Übersicht

2. Data Mining und Datenaufbereitung

2.1 Data Mining

2.2 Konzepte, Instanzen und Attribute

2.3 Datenaufbereitung

Lernziele:

- Data Mining definieren und dessen Methoden, Probleme und Ziele erklären können
- Grundbegriffe wie Konzepte, Instanzen und Attribute definieren und diese Begriffe auf konkrete Probleme anwenden, sowie Attributtypen unterscheiden und korrekt einordnen
- Datenprobleme identifizieren und typische Schritte der Datenaufbereitung beschreiben und geeignete Methoden zielgerichtet auswählen

Data Mining

- Warum?
 - Riesige Menge an Daten
 - Wachsende Lücke zwischen Produktion und Auswertung der Daten
- Ziel:
 - Extraktion von nützlichen und versteckten Informationen
- Methode:
 - Mustererkennung in den Daten
 - Nutzung von verschiedenen Data Mining Verfahren, um die Muster in den Daten (semi-)automatisch zu finden

Data Mining

- Data Mining ist definiert als Prozess zum Erkennen von Mustern in Daten
 - Muss automatisch oder zumindest semi-automatisch sein
 - Die gefundenen Muster müssen Informationen enthalten, die nützlich sind
 - Die gefundenen Muster ermöglichen nicht triviale Aussagen über neue Daten
 - Daten sind in großer Menge vorhanden
 - Methodenarten:
 - Black Box: Innere Abläufe sind nicht einfach nachvollziehbar
 - White Box: Zeigt die Struktur eines Musters offen und nachvollziehbar an
-  Visualisierung kann genutzt werden, um eine Black Box zu öffnen

Data Mining

- Data Mining sucht strukturierte Muster
 - Bilden die Struktur eindeutig ab
 - Sind untersuchbar
 - Sind begründbar
 - Sind nützlich für zukünftige Entscheidungen

Data Mining

Alter	Fehlsichtigkeit	Hornhaut- verkrümmung	Tränen- produktion	Empfohlene Linsen
Jung	Kurzsichtig	nein	reduziert	keine
Jung	Kurzsichtig	nein	normal	weich
Jung	Kurzsichtig	ja	reduziert	keine
Jung	Kurzsichtig	ja	normal	hart
Jung	weitsichtig	nein	reduziert	keine
Jung	weitsichtig	nein	normal	weich
...	...	...	...	...

Data Mining

- Extrahierte Regeln:
 - Wenn Tränenproduktion = reduziert
-> Empfehlung = keine
 - Ansonsten:
 - Wenn Hornhautverkrümmung =
nein und Tränenproduktion =
normal
-> weich
 - Darstellbar als Entscheidungsbaum
- Probleme:
 - Regeln bilden nur den Datensatz
ab
 - Vollständige Datensätze sind aber
nicht die Norm
 - Reale Datensätze weisen Lücken
auf
 - Reale Daten beinhalten Fehler

Data Mining


- Weitere Probleme:
 - Die Anzahl der Regeln sollte nicht größer als die Anzahl der Datenpunkte sein
 - Overfitting?
 - Die Aufzählung aller Regeln ist oft nicht erreichbar
 - In welcher Reihenfolge sucht man?
- Bias
- Wie beschreibt man die Daten?
- Filtern einer Menge von Beschreibungen
- Visualisierung notwendig?

Data Mining

- Beschreibungsprobleme
 - Weist die Sprache Einschränkungen auf, welche Muster erkannt werden können?
 - z.B. nur lineare Zusammenhänge
 - z.B. kein ODER
- Nutzung von Vorwissen
 - Einteilung des Suchraums?


Data Mining

- Suchbias
 - Schwierigkeiten, den gesamten Suchraum abzuarbeiten
 - Nutzung von Heuristiken
 - Greedy Algorithmen
- Reihenfolge kann wichtig sein
 - Top down
 - Bottom up
- Instanz basierte Methoden lernen einzelne Beispiele und generalisieren
 - Das schränkt den Suchraum ein



Data Mining

- Overfitting
 - Modell lernt Details und Ausreißer, nicht nur allgemeine Muster



- Jeder Datenpunkt als eigene Regel daher zu spezifisch
→ Kombination von Regeln

- Vermeidung von Overfitting
 - Bottom Up: (forward-pruning)
 - Starte mit einfachen Regeln
 - Erstelle darauf aufbauend komplexere Regeln
 - Stop, wenn die Regeln komplex genug sind
 - Top Down (Backward-pruning)
 - Start mit generellen Regeln zu simplen Regeln

Data Mining

- Ethische Fragen tauchen in praktischen Anwendungen oft auf, wenn Daten zur Unterscheidung oder Entscheidung genutzt werden
 - Kreditanträge: Verwendung von Informationen (z. B. Geschlecht, Herkunft) ist unethisch
 - Dieselben oder ähnliche Daten können in einem medizinischen Kontext ethisch vertretbar sein (z. B. zur Diagnose oder Behandlung)
- Daten können indirekt auf sensible Merkmale schließen lassen
 - z. B. Postleitzahl kann mit Herkunft oder Einkommen korrelieren
- Wichtige Fragen:
 - Wer hat Zugang zu den Daten?
 - Für welchen Zweck werden die Daten gesammelt?
 - Welche Schlussfolgerungen dürfen daraus gezogen werden?
 - Wer profitiert von den Ergebnissen?
 - Werden die Ergebnisse verantwortungsvoll verwendet?
- Statistische Korrektheit $\neq$ ethische Rechtfertigung

Konzepte, Instanzen und Attribute


- Instanzen
 - Einzelnes Beispiel (Datenpunkt) für das zu lernende Konzept
 - Hintergrundwissen kann wichtig sein
- Attribute
 - Jede Instanz wird durch Attribute beschrieben
 - Meistens numerische oder kategoriale Werte
- Konzept
 - Kann gelernt werden: Funktion, die Instanzen einer Klasse zuordnet
- Konzeptbeschreibungen: Gelernte Repräsentation des Konzepts
 - Kann aus den Attributen abgeleitet werden
 - Verständlich
 - Nachvollziehbar
 - Diskutierbar
 - Kann man auf Beispiele anwenden

Konzepte

- Lernverfahren:
 - Klassifikation
 - Assoziation
 - Clustering
 - Regression
- Ergebnis sind Konzeptbeschreibungen

Konzepte

- Klassifikation
 - Bsp. Kontaktlinsen:
 - Aggregiert die Daten
 - Gibt Empfehlungen, welche Linsen genutzt werden sollen




- Supervised Lernverfahren
 - Stellt iterativ neue Ergebnisse bereit für jeden neuen Datenpunkt
 - Ergebnis ist die „Klasse“ der Beispiele
 - Erfolg des Lernverfahrens kann beurteilt werden

Konzepte

- Assoziationen
 - Offenlegung von interessanten Strukturen in Daten
 - Kann jedes Attribut Vorhersagen, nicht nur die Klasse
 - Kann mehr als einen Attributwert vorhersagen
 - Es gibt wesentlich mehr Assoziationsregeln als Klassifikationsregeln
- Regeln brauchen oft einem Minimum an notwendigen Daten zur Unterstützung
- Regeln brauchen oft ein minimales Level an Genauigkeit
- Notwendige Prüfung, ob die Regeln sinnvoll sind
- Typischerweise für kategorische Daten


Konzepte

- Clustering
 - Keine spezifischen Klassen (unüberwacht)
 - Gruppiert Daten in ähnliche Gruppen
 - Herausforderungen:
 - Finden der Cluster
 - Zuordnung von neuen Instanzen
- Wie viele Cluster braucht man?
- Subjektive Analyse, ob das Ergebnis sinnvoll ist
- Kann mit nachträglicher Klassifikation kombiniert werden, um neue Instanzen hinzuzufügen



Konzepte

- Regression
 - Ergebnis ist ein numerischer Wert anstatt einer Kategorie
 - Vorhersage von neuen Instanzen ist eher unwichtig
 - Supervised Lernverfahren
- Wichtiger ist meist die Struktur der Beschreibung
 - Wichtige Attribute
 - Relation der Attribute



Instanzen

- Input von Maschine Learning Verfahren ist eine Menge von Instanzen
- Instanz
 - Einzelnes, unabhängiges Beispiel eines Konzeptes
 - Charakterisiert durch die Attribute
 - z. B. Objekt das klassifiiziert werden soll
- Beispiel Datenbanken:
 - Viele Tabellen sind durch Relationen verbunden
 - Für Maschine Learning werden diese in eine Tabelle gepresst, damit alle Attribute in einer Tabelle stehen
 - Denormalisierung

Instanzen

- Denormalisierung
 - Mehrere Relationen werden zu einer verbunden
- Beispiel:
 - Tabelle 1: Name, Geschlecht, Eltern 1, Eltern 2
 - Tabelle 2: Erste Person, Zweite Person, ist Schwester?
- Denormalisiert:
 - Erste Person: Name, Geschlecht, Eltern 1, Eltern 2, Zweite Person: Name, Geschlecht, Eltern 1, Eltern 2
- Braucht man „ist Schwester?“ noch?

Instanzen

- Suche nach Relationen
 - Z.B. nach Vorfahren
 - Können beliebig lange Pfade werden
 - Rekursion notwendig
- Schwierig bei fehlerhaften Daten


Attribute

- Feste, vordefinierte Menge von Merkmalen/Features
- Verschiedene Attribute können in verschiedenen Instanzen gültig sein
- Beispiel Fahrzeuge
 - Landfahrzeuge: Anzahl der Räder
 - Schiffe: Anzahl der Masten
- Standardlösung: Markiere Attribute als irrelevant, wenn sie nicht anwendbar sind
- Es kann Abhängigkeiten zwischen Attributen geben
 - „Geburtsname“ und „Familienstand“

Attribute

- Attributarten:
 - Kategorial (nominal)
 - Ungeordnet
 - Z.B. Apfel, Birne
 - Ordinal
 - Geordnete Kategorien
 - T-Shirt in S, M, L, XL, XXL
 - Quantitativ (metrisch)
 - Unterstützen arithmetische Operationen (gibt auch hier Einschränkungen)
 - Feste Abstände
 - 1m, 2m, 3m, 4m, 5m

- Ordnungen:
 - Sequentiell
 - Divergierend
 - Zyklisch



Attribute

- Welche Art von Attribut liegt vor?
 - → Hat es eine Reihenfolge?
 - → Sind Abstände interpretierbar und gleich?
- Alter in Gruppen
 - Beispiel: 0–18, 19–35, 36–60, > 60
- Postleitzahl
 - Beispiel: 04109, 80331, 10115
- Wie zufrieden sind Sie?
 - 1 = sehr unzufrieden, 2 = unzufrieden, 3 = neutral, 4 = zufrieden, 5 = sehr zufrieden

➔ Attribute Types

➔ Categorical




➔ Ordered

➔ Ordinal



➔ Quantitative



➔ Ordering Direction

➔ Sequential



➔ Diverging



➔ Cyclic



Attribute

- Welche Art von Attribut liegt vor?
 - → Hat es eine Reihenfolge?
 - → Sind Abstände interpretierbar und gleich?
- Alter in Gruppen
 - Beispiel: 0–18, 19–35, 36–60, > 60
- Postleitzahl
 - Beispiel: 04109, 80331, 10115
- Wie zufrieden sind Sie?
 - 1 = sehr unzufrieden, 2 = unzufrieden, 3 = neutral, 4 = zufrieden, 5 = sehr zufrieden

• Likert-Items/Skalen

- Ich bin mit meinem Studium zufrieden.
 - 1 = stimme gar nicht zu, 2 = stimme eher nicht zu, 3 = teils/teils, 4 = stimme eher zu, 5 = stimme voll zu
- Ordinal, werden aber unter bestimmten Bedingungen wie metrisch behandelt.

➔ Attribute Types

➔ Categorical




➔ Ordered

➔ Ordinal



➔ Quantitative



➔ Ordering Direction

➔ Sequential





➔ Diverging



➔ Cyclic



Datenaufbereitung



Datenaufbereitung

- Benötigt häufig am meisten Zeit
- Daten sind meistens von enttäuschend schlechter Qualität
- Datenaufbereitung ist zwingend notwendig!
- Schlechter Input resultiert in schlechten Output
- Sind die Daten dokumentiert?
- Gibt es fehlende Werte?
- Gibt es fehlerhafte Werte?
- Wie sind Strings codiert?
- Ist das Format konsistent?
- Gibt es Duplikate?
- Müssen Werte transformiert werden?

Datenaufbereitung

Verknüpfung von Daten:

- Aus verschiedenen Quellen
 - Syntax der Quellen
 - Sprache / Vokabular
 - Zeitbereiche
 - Primärschlüssel
 - Fehlerarten
 - Aggregationsstufen
- Data Warehouse
 - Datenbankintegration
 - Nützlicher Schritt vor der Analyse
- Nutzung von Schematemplates für Daten
 - Daten haben definierte Syntax

Datenaufbereitung

Sparse Data

- Tabellen beschreiben vollständige Daten gut
 - Z.B. Speicherung von Graphen kann in einer sparse besetzten Adjazenzmatrix resultieren
 - Speicherplatzprobleme
- Speicherung in Key Value Listen
 - Graphen: Edgelist mit Knoten, Knoten
 - Wörter in Dokument: Position, Wort
 - Aber missing values müssen explizit markiert werden

Datenaufbereitung

Feature Engineering

- Neue Features aus bestehenden Attributen ableiten (z.B. Alter aus Geburtsdatum).
- Text: Wortanzahl, Länge der Sätze, Häufigkeit bestimmter Schlüsselwörter
- Transformation (z. B. Normalisierung / Standardisierung)
- Kombination von Features (z. B. Verhältnis, Differenz)
- Domänenwissen einfließen lassen

Feature Selection



- Relevante Attribute auswählen, irrelevante weglassen.
- Reduziert Dimensionalität, verbessert Effizienz und verhindert Overfitting
- Teste Feature Kombinationen entferne schlechte
- Filter:
 - Korrelation: Entferne Features, die stark miteinander korrelieren
 - Varianzschwelle: Entferne Features mit kaum Variation
 - Statistische Tests

Datenaufbereitung

Verarbeitung von Attributen

- Numerische Werte können als natürlicher oder reele Zahlen interpretiert werden
- Normalisierung kann das Intervall eingrenzen
 - Nützlich für reele Zahlen
- Normalisierung zwischen [0 ,1]

$$v' = \frac{v - \min}{\max - \min}$$





Datenaufbereitung


- Standardisierung
 - Berechne Mittelwert m und Standardabweichung d der Daten

$$v' = \frac{v - m}{d}$$

- Kategorische Daten können als numerische Werte interpretiert werden
 - Markiere nominale Daten!







Datenaufbereitung



Datenaufbereitung

- Manche Methoden setzen Normalverteilung voraus
- Long-Tail-Verteilungen enthalten wenige extrem große Werte
 - Problem für Klassifikation
 - Modell lernt nur die häufige Klasse, seltene Klassen werden ignoriert




Datenaufbereitung

One-Hot-Encoding

- Viele Verfahren benötigen numerische Daten, aber kategoriale Attribute haben keine inhärente Reihenfolge
- Wandelt kategoriale Daten in binäre Vektoren um
- Jeder Kategorie wird eine Zeile/Spalte zugeordnet. Ist eine Kategorie aktiv, steht dort eine 1, ansonsten eine 0
- Verhindert, dass Algorithmen numerische Rangfolge interpretieren

- Nachteil: Viele Kategorien → viele neue Zeilen/Spalten → Modell langsamer (Sparse Data)
- Bis ca. 2013 Standard in der Sprachverarbeitung. Eine Zeile/Spalte pro Wort im Vokabular.



Datenaufbereitung

Missing values

- Werden oft mit out of range Einträgen codiert
 - Numerisch: -1, 999, etc.
 - Kategorisch: “ “, “-”, "NA"
- Unterschiedliche Arten von missing values:
 - Unbekannt
 - Nicht aufgezeichnet
 - Irrelevant
- Fehlende Werte müssen bewertet werden
 - Was ist der Grund? Ist der fehlende Wert selber eine wichtige Information?
 - Kann auch zum Ausschluss eines Datenpunkts führen
 - Datenimputation notwendig?
 - Median / Mittelwert
 - Modus
 - Vorhersagen mit Modellen

Datenaufbereitung

Fehlerhafte Werte

- Falsch geschriebene Werte
- Abkürzungen vs. vollständige Namen
 - Personennetzwerke basieren auf Namen
 - C. Meinecke <-> Christofer Meinecke
- Numerische Werte können Messfehler haben
- Duplikate
- Veraltete Daten
 - Daten können sich verändern

Daniel Gerighausen <-> Daniel Wiegrefe

Datenaufbereitung



Art	Insel	Schnabellänge (mm)	Schnabeltiefe (mm)	Flügelänge (mm)	Körpermasse (g)	Geschlecht
Adelie	Torgersen	39.1	18.7	181	3750	m
Adelie	Torgersen	39.5	17.4	186	3800	w
Gentoo	Biscoe	46.1	132	211	4500	male
Gentoo	Biscoe	50.0	16.3	230	5700	m
Chinstrap	Dream	46.5	17.9	192	3500	w
Chinstrap	Dream	45.6	18.4	190	3700	m
Adelie	Dream	34.1	18.1	193	3475	w
Gentoo	Biscoe	999	14.5	220	5000	m
Adelie	Torgersen	37.8	NA	18.6	3400	w
Chinstrap	Dream	46.5	17.9	192	3500	w

Datenaufbereitung

Zusammenfassung

- Datenaufbereitung ist extrem wichtig
- Muss vor der eigentlichen Analyse gemacht werden
- Analyse der Verteilungen, z.B. mit Histogrammen
- Visualisierung der Daten, um Outlier zu erkennen
- Sehr aufwendig und zeitintensiv
- Muss sauber dokumentiert werden
- Domänenwissen ist notwendig
 - Fehlerhafte Werte erkennen
 - Verteilungen sinnvoll?