



UNIVERSITÄT  
LEIPZIG

3. Vorlesung: Klassifikation & Entscheidungsbäume

## **INTERACTIVE VISUAL DATA MINING**

# Übersicht

## 3. Entscheidungsbäume

3.1 Klassifikation

3.2 Entscheidungsbäume

3.3 Ensemble-Verfahren


3.4 Beispiel Visualisierungen

Lernziele:


- Entscheidungsbäume beschreiben, deren Funktionsweise erklären, sowie Vor- und Nachteile von Entscheidungsbäumen erläutern
- Den ID3-Algorithmus auf neue Datensätze anwenden um Entscheidungsbäume zu konstruieren, sowie Erweiterungen des ID3-Algorithmus beschreiben und deren Nutzen erklären
- Erklären können, wie Entscheidungsbäume zu Ensemble-Verfahren kombiniert werden und welche Vorteile sich daraus ergeben
- Mögliche Entscheidungsbaum Visualisierungen kennen

# Klassifikation

- Klassifikation ist eine Form des überwachten Lernens.
- Ziel: Ein Modell lernt aus Trainingsdaten, um neue Daten in diskrete Klassen einzuteilen.




- Binäre Klassifizierung
  - Zwei Klassen
  - Beispiel: Krankheitstest → Positiv / Negativ




# Klassifikation

- Klassifikation ist eine Form des überwachten Lernens.
- Ziel: Ein Modell lernt aus Trainingsdaten, um neue Daten in diskrete Klassen einzuteilen.




- Multi-Klassen Klassifikation
  - Mehr als zwei Klassen, jede Instanz gehört zu genau einer Klasse
  - Beispiel: Tierklassifikation → Hund, Katze, Maus, ...




# Klassifikation


- Klassifikation ist eine Form des überwachten Lernens.
- Ziel: Ein Modell lernt aus Trainingsdaten, um neue Daten in diskrete Klassen einzuteilen.



- Multi-Label Klassifikation
  - Mehrere Klassen können gleichzeitig zutreffen
  - Häufig z. B. bei Bildern und Texten



# Decision Trees



PROTIP: IF YOU EVER NEED TO DEFEAT ME,  
JUST GIVE ME TWO VERY SIMILAR OPTIONS  
AND UNLIMITED INTERNET ACCESS.



# Decision Trees



# Decision Trees





# Decision Trees

## Was sind Entscheidungsbäume?

- Instanzen mit Attributen werden als Baum dargestellt
  - Baum ist gerichtet
  - Attribute mit Entscheidung sind Knoten
  - Ordnung nach "Aussagekraft" (Wurzel am wichtigsten)
  - Blätter geben die Klassenzugehörigkeit für eine Instanz an.
- Baum  $t$  sagt die Werte  $c_1, \dots, c_n$  eines Attributes (Klasse) für die Instanz  $X$  voraus
    - $t: X$  ist Element von  $\{c_1, \dots, c_n\}$
  - Regeln sind in Form von if ... , then ... aufgestellt
    - Pfade des Baums kodieren die Regeln
    - if Attribut  $A > 5$  and Attribut  $B = \text{"ja"}$  then Klasse = 1

# Decision Trees

## Anwendungsbereiche

- Klassifikation und Regression
- Beispiele
  - Medizinische Diagnosen
  - Klassifikation von biologischen Arten
  - Umweltforschung
  - Klassifikation von Materialien
  - Bewertung von Kreditwürdigkeit


## • Bedingungen:

- Instanzen werden durch Attribute-Werte Paare beschrieben
  - {Farbe=rot, Größe=groß, Gewicht=leicht}
- Zielattribut muss definiert sein (Klassen)
- Für manche Algorithmen müssen Attribute diskret sein

# Decision Trees

## Warum Entscheidungsbäume?

- Regeln sind einfach ablesbar
- Sind gut darstellbar
- Whitebox Verfahren
- Relativ schnell berechenbar
- Baummodelle gehören nach wie vor zu den besten Methoden für tabellarische Daten
  - Grinsztajn et al. "Why do tree-based models still outperform deep learning on typical tabular data?"  
NeurIPS 2022



Bildquelle: <https://medium.com/@shamanth.kuthpadi2003/decision-classification-trees-d2cd92707203>

# Decision Trees

| Aussichten | Luftfeuchtigkeit | Wind    | Entscheidung |
|------------|------------------|---------|--------------|
| Bedeckt    | hoch             | stark   | ja           |
| Bedeckt    | normal           | stark   | ja           |
| Bedeckt    | hoch             | schwach | ja           |
| Bedeckt    | normal           | schwach | ja           |
| Regen      | hoch             | stark   | nein         |
| Regen      | normal           | stark   | nein         |
| Regen      | hoch             | schwach | ja           |
| Regen      | normal           | schwach | ja           |
| Sonnig     | hoch             | stark   | nein         |
| Sonnig     | normal           | stark   | ja           |
| Sonnig     | hoch             | schwach | nein         |
| Sonnig     | normal           | schwach | ja           |

# Decision Trees

| Aussichten | Luftfeuchtigkeit | Wind    | Entscheidung |
|------------|------------------|---------|--------------|
| Bedeckt    | hoch             | stark   | ja           |
| Bedeckt    | normal           | stark   | ja           |
| Bedeckt    | hoch             | schwach | ja           |
| Bedeckt    | normal           | schwach | ja           |
| Regen      | hoch             | stark   | nein         |
| Regen      | normal           | stark   | nein         |
| Regen      | hoch             | schwach | ja           |
| Regen      | normal           | schwach | ja           |
| Sonnig     | hoch             | stark   | nein         |
| Sonnig     | normal           | stark   | ja           |
| Sonnig     | hoch             | schwach | nein         |
| Sonnig     | normal           | schwach | ja           |

# Decision Trees

| Aussichten | Luftfeuchtigkeit | Wind    | Entscheidung |
|------------|------------------|---------|--------------|
| Bedeckt    | hoch             | stark   | ja           |
| Bedeckt    | normal           | stark   | ja           |
| Bedeckt    | hoch             | schwach | ja           |
| Bedeckt    | normal           | schwach | ja           |
| Regen      | hoch             | stark   | nein         |
| Regen      | normal           | stark   | nein         |
| Regen      | hoch             | schwach | ja           |
| Regen      | normal           | schwach | ja           |
| Sonnig     | hoch             | stark   | nein         |
| Sonnig     | normal           | stark   | ja           |
| Sonnig     | hoch             | schwach | nein         |
| Sonnig     | normal           | schwach | ja           |

# Decision Trees

| Aussichten | Luftfeuchtigkeit | Wind    | Entscheidung |
|------------|------------------|---------|--------------|
| Bedeckt    | hoch             | stark   | ja           |
| Bedeckt    | normal           | stark   | ja           |
| Bedeckt    | hoch             | schwach | ja           |
| Bedeckt    | normal           | schwach | ja           |
| Regen      | hoch             | stark   | nein         |
| Regen      | normal           | stark   | nein         |
| Regen      | hoch             | schwach | ja           |
| Regen      | normal           | schwach | ja           |
| Sonnig     | hoch             | stark   | nein         |
| Sonnig     | normal           | stark   | ja           |
| Sonnig     | hoch             | schwach | nein         |
| Sonnig     | normal           | schwach | ja           |




# Decision Trees

| Aussichten | Luftfeuchtigkeit | Wind    | Entscheidung |
|------------|------------------|---------|--------------|
| Bedeckt    | hoch             | stark   | ja           |
| Bedeckt    | normal           | stark   | ja           |
| Bedeckt    | hoch             | schwach | ja           |
| Bedeckt    | normal           | schwach | ja           |
| Regen      | hoch             | stark   | nein         |
| Regen      | normal           | stark   | nein         |
| Regen      | hoch             | schwach | ja           |
| Regen      | normal           | schwach | ja           |
| Sonnig     | hoch             | stark   | nein         |
| Sonnig     | normal           | stark   | ja           |
| Sonnig     | hoch             | schwach | nein         |
| Sonnig     | normal           | schwach | ja           |

# Decision Trees

| Aussichten | Luftfeuchtigkeit | Wind    | Entscheidung |
|------------|------------------|---------|--------------|
| Bedeckt    | hoch             | stark   | ja           |
| Bedeckt    | normal           | stark   | ja           |
| Bedeckt    | hoch             | schwach | ja           |
| Bedeckt    | normal           | schwach | ja           |
| Regen      | hoch             | stark   | nein         |
| Regen      | normal           | stark   | nein         |
| Regen      | hoch             | schwach | ja           |
| Regen      | normal           | schwach | ja           |
| Sonnig     | hoch             | stark   | nein         |
| Sonnig     | normal           | stark   | ja           |
| Sonnig     | hoch             | schwach | nein         |
| Sonnig     | normal           | schwach | ja           |

# Decision Trees



# Decision Trees

## Herausforderungen

- Kann man die Reihenfolge der Attribute so wählen, dass der Baum möglichst klein wird?
  - Priorisierung
- Kontinuierliche Werte?
- Fehler und fehlende Werte?

# Decision Trees

## Iterative Dichotomiser 3 (ID3)

- Nutzt Top-Down Greedy Tree Induction
- Lernt den Baum von oben nach unten (top down)
- Wählt das beste Attribut zum spalten aus (greedy)
  - “Beste” im Sinne der Informationsentropie
- Rekursion auf den Kinderknoten

## Pseudocode:

1. Wähle X als das “beste” Attribut und spalte damit die Daten
2. Erstelle für alle vorkommenden Werte von X Kindsknoten mit den zugehörigen Daten
3. Gehe zu den Kindsknoten und starte bei 1. (Rekursion), bis keine Attribute mehr übrig sind, oder alle Datenpunkte zu einer Klasse gehören → Erstelle ein Blatt mit der Mehrheitsklasse der Datenpunkte

# Decision Trees

## Probleme ID3

- Bleibt oft in lokalen Optima stecken (Top-Down Greedy Tree Induction)
- Nur diskrete Daten
- Overfitting

- Wachsen bei bestimmter Tiefe stoppen
  - Tiefe vorher festlegen
  - Schwellwert für Anzahl an Instanzen oder Verbesserung
- Post-Pruning des Baums
  - Reduced-error pruning
  - Brauchen dafür einen Validierungsdatensatz

# Decision Trees

## Bewertungsfunktion Entropie

- Entropie ist ein Maß über den Informationsgehalt in den Daten bzw. für die Unsicherheit über die Klassenverteilung
  - Wenn alle Beispiele zur gleichen Klasse gehören → Entropie = 0
  - Wenn die Klassen gleich verteilt sind → maximale Entropie (hängt von Anzahl der Klassen ab)

$$Entropie(S) = - \sum_{i=1}^c p_i \cdot \log_2(p_i)$$

- $S$  = Datensatz / Trainingsbeispiele
- $c$  = Anzahl der Klassen
- $p_i$  = Anteil / Wahrscheinlichkeit der Klasse  $i$

# Decision Trees

## Information Gain

- Deskriptor, wie gut ein Attribut die Instanzen klassifiziert
- Vergleicht Entropie vor und nach dem Split mit Attribut A und gibt Auskunft über das Sinken der Entropie nach dem Split
- Je höher der Information Gain, desto besser das Attribut
- $$\text{Gain}(S, A) = \text{Entropie}(S) - \sum_{v \in \text{Werte}(A)} \frac{|S_v|}{|S|} \cdot \text{Entropie}(S_v)$$
- $S$  = Trainingsbeispiele / Alle Instanzen im Knoten
- $A$  = gewähltes Attribut
- $\text{Werte}(A)$  = Alle Werte die  $A$  annehmen kann
- $S_v$  = Untermenge von  $S$ , in der alle Instanzen Attribut  $A = v$  haben



# Decision Trees

## Am Beispiel

| Tag | Aussichten | Temperatur | Luftfeuchtigkeit | Wind    | Entscheidung |
|-----|------------|------------|------------------|---------|--------------|
| 1   | Sonne      | heiß       | hoch             | schwach | nein         |
| 2   | Sonne      | heiß       | hoch             | hoch    | nein         |
| 3   | Bedeckt    | heiß       | hoch             | schwach | ja           |
| 4   | Regen      | angenehm   | hoch             | schwach | ja           |
| 5   | Regen      | kalt       | normal           | schwach | ja           |
| 6   | Regen      | kalt       | normal           | hoch    | nein         |
| 7   | Bedeckt    | kalt       | normal           | hoch    | ja           |
| 8   | Sonne      | angenehm   | hoch             | schwach | nein         |
| 9   | Sonne      | kalt       | normal           | schwach | ja           |
| 10  | Regen      | angenehm   | normal           | schwach | ja           |
| 11  | Sonne      | angenehm   | normal           | hoch    | ja           |
| 12  | Bedeckt    | angenehm   | hoch             | hoch    | ja           |
| 13  | Bedeckt    | heiß       | normal           | schwach | ja           |
| 14  | Regen      | angenehm   | hoch             | hoch    | nein         |

# Decision Trees

- Entropie über den Datensatz:
- Entropy (S) =  $-9/14 \cdot \log_2(9/14) - 5/14 \cdot \log_2(5/14) = 0.94$
- Information Gain von Aussichten:
- $$\begin{aligned} \text{Gain}(S, \text{Aussichten}) &= \text{Entropie}(S) - 5/14 \cdot \text{Entropie}(\text{Sonne}) \\ &\quad - 4/14 \cdot \text{Entropie}(\text{Bedeckt}) \\ &\quad - 5/14 \cdot \text{Entropie}(\text{Regen}) \\ &= 0.94 - 5/14 \cdot 0.971 - 4/14 \cdot 0 - 5/14 \cdot 0.971 \end{aligned}$$

$$\text{Gain}(S, \text{Aussichten}) = 0,246$$

# Decision Trees

- Entropie über den Datensatz:
- Entropy (S) =  $-9/14 \cdot \log_2(9/14) - 5/14 \cdot \log_2(5/14) = 0.94$

$$\text{Gain}(S, \text{Aussichten}) = 0,246$$

$$\text{Gain}(S, \text{Luftfeuchtigkeit}) = 0,151$$

$$\text{Gain}(S, \text{Wind}) = 0,048$$

$$\text{Gain}(S, \text{Temperatur}) = 0,029$$

# Decision Trees

- Aussichten ist eindeutig der beste Split
- Information Gain muss für Teilbäume Neuberechnet werden

| Tag | Temperatur | Luftfeuchtigkeit | Wind    | Entscheidung |
|-----|------------|------------------|---------|--------------|
| 1   | heiß       | hoch             | schwach | nein         |
| 2   | heiß       | hoch             | hoch    | nein         |
| 8   | angenehm   | hoch             | schwach | nein         |
| 9   | kalt       | normal           | schwach | ja           |
| 11  | angenehm   | normal           | hoch    | ja           |

Sonne

| Tag | Temperatur | Luftfeuchtigkeit | Wind    | Entscheidung |
|-----|------------|------------------|---------|--------------|
| 3   | heiß       | hoch             | schwach | ja           |
| 7   | kalt       | normal           | hoch    | ja           |
| 12  | angenehm   | hoch             | hoch    | ja           |
| 13  | heiß       | normal           | schwach | ja           |

Bedeckt

| Tag | Temperatur | Luftfeuchtigkeit | Wind    | Entscheidung |
|-----|------------|------------------|---------|--------------|
| 4   | angenehm   | hoch             | schwach | ja           |
| 5   | kalt       | normal           | schwach | ja           |
| 6   | kalt       | normal           | hoch    | nein         |
| 10  | angenehm   | normal           | schwach | ja           |
| 14  | angenehm   | hoch             | hoch    | nein         |

Regen

# Decision Trees

- Aussichten ist eindeutig der beste Split
- Information Gain muss für Teilbäume Neuberechnet werden

| Tag | Temperatur | Luftfeuchtigkeit | Wind    | Entscheidung |
|-----|------------|------------------|---------|--------------|
| 1   | heiß       | hoch             | schwach | nein         |
| 2   | heiß       | hoch             | hoch    | nein         |
| 8   | angenehm   | hoch             | schwach | nein         |
| 9   | kalt       | normal           | schwach | ja           |
| 11  | angenehm   | normal           | hoch    | ja           |

## Sonne

- Beispiel Teilbaum Sonne
  - $\text{Gain}(\text{Sonne, Luftfeuchtigkeit}) = 0.97 - \left(\frac{3}{5}\right) * 0 - \left(\frac{2}{5}\right) * 0 = 0.97$
  - $\text{Gain}(\text{Sonne, Temperatur}) = 0.97 - \left(\frac{2}{5}\right) * 0 - \left(\frac{2}{5}\right) * 1 - \left(\frac{1}{5}\right) * 0 = 0.57$
  - $\text{Gain}(\text{Sonne, Wind}) = 0.97 - \left(\frac{2}{5}\right) * 1 - \left(\frac{3}{5}\right) * 0.981 = 0.019$

# Decision Trees

## C4.5 Algorithmus

- Quinlan, 1993
- Erweiterung vom ID3
- Kann fehlende Attribute in Trainingsdaten verarbeiten
  - Gewichtung anhand von Wahrscheinlichkeiten
- Kontinuierliche Daten werden unterstützt
  - Alle "sinnvollen" Splits berechnen und den Besten wählen
- Lösung für Overfittingprobleme: Post-Pruning für jeden Teilbaum
  - Ast durch Blatt ersetzen
  - Ast durch Teilast ersetzen
- Attribute können mehrfach entlang eines Pfades vorkommen

# Decision Trees

## CART (Classification and Regression Trees) Algorithmus

- Breiman et al., 1984
- Erzeugt binäre Entscheidungsbäume
- Kontinuierliche Daten werden unterstützt (wie C4.5), aber kategorische führen zu vielen Splits
- Verwendet Gini-Impurity als Splitting-Kriterium (bei Klassifikation), Varianzreduktion / MSE (bei Regression)
- Unbekannte Attributwerte:
  - Sucht alternatives Attribut, das die Daten ähnlich teilt (Surrogate Splits)
- Genutzt in scikit-learn und rpart
- Cost-Complexity Pruning
  - Erzeugt mehrere Teilbäume mit unterschiedlicher Größe und wählt den Baum mit den besten Kosten
  - Minimiere für ein gegebenes  $\alpha$
  - Kosten = Fehler +  $\alpha$  \* Anzahl Blätter

# Decision Trees

Gini Impurity für einen Knoten

$$G = \sum_{i=1}^C p(i) * (1 - p(i))$$

- C = Anzahl der Klassen
- p(i) = Anteil (Wahrscheinlichkeit) der Klasse i im Knoten


Entscheidung des Splits über höchsten Gini Gain

$$\text{Gini Gain} = G_{\text{parent}} - \left( \frac{N_{\text{links}}}{N_{\text{gesamt}}} G_{\text{links}} + \frac{N_{\text{rechts}}}{N_{\text{gesamt}}} G_{\text{rechts}} \right)$$

$G_{\text{parent}}$  = Gini Impurity des aktuellen Knotens vor dem Split

$G_{\text{links}}, G_{\text{rechts}}$  = Gini Impurity der beiden Kinderknoten

$N_{\text{links}}, N_{\text{rechts}}, N_{\text{gesamt}}$  = Anzahl der Elemente im linken, rechten und aktuellen Knoten



$$G_{\text{parent}} = 0.5 * 0.5 + 0.5 * 0.5 = 0.5$$



# Decision Trees

Gini Impurity für einen Knoten

$$G = \sum_{i=1}^C p(i) * (1 - p(i))$$

- C = Anzahl der Klassen
- p(i) = Anteil (Wahrscheinlichkeit) der Klasse i im Knoten


Entscheidung des Splits über höchsten Gini Gain

$$\text{Gini Gain} = G_{\text{parent}} - \left( \frac{N_{\text{links}}}{N_{\text{gesamt}}} G_{\text{links}} + \frac{N_{\text{rechts}}}{N_{\text{gesamt}}} G_{\text{rechts}} \right)$$

$G_{\text{parent}}$  = Gini Impurity des aktuellen Knotens vor dem Split

$G_{\text{links}}, G_{\text{rechts}}$  = Gini Impurity der beiden Kinderknoten


$N_{\text{links}}, N_{\text{rechts}}, N_{\text{gesamt}}$  = Anzahl der Elemente im linken, rechten und aktuellen Knoten



Perfekter Split

$$G_{\text{left}} = 1 * (1 - 1) + 0 * (1 - 0) = \boxed{0}$$

$$G_{\text{right}} = 0 * (1 - 0) + 1 * (1 - 1) = \boxed{0}$$





Unperfekter Split

$$G_{\text{left}} = 1 * (1 - 1) + 0 * (1 - 0) = \boxed{0}$$

$$\begin{aligned} G_{\text{right}} &= \frac{1}{6} * (1 - \frac{1}{6}) + \frac{5}{6} * (1 - \frac{5}{6}) \\ &= \frac{5}{18} \\ &= \boxed{0.278} \end{aligned}$$

Bilderquelle: <https://victorzhou.com/blog/gini-impurity/>

# Decision Trees



Bildquelle und Beispiel: <https://www.justinmath.com/decision-trees/>

# Decision Trees

## Zusammenfassung

### Pro:

- Regeln können einfach abgeleitet werden
- Relativ robust gegenüber
  - Fehlenden Werten
  - Unwichtigen Attributen
- Einfach erweiterbar  
(z. B. Random Forest)

### Kontra:

- Baum kann sehr groß werden
- Schnelles Overfitting
- Bleibt oft in lokalen Optima stecken  
(Top-Down Greedy Tree Induction)
- Empfindlich gegenüber kleinen Änderungen im Trainingsdatensatz
- Wenn die Klassen stark unausgeglichen sind, bevorzugt der Baum oft die Mehrheitsklasse.


# Ensemble-Methoden

- Kombination mehrerer Modelle zur Steigerung der Genauigkeit und Reduktion von Overfitting
- Mehrere Modelle werden trainiert und ihre Vorhersagen zusammengeführt
- Kombination z. B. durch:
  - Voting (Klassifikation)
  - Mittelwertbildung (Regression)
- Bagging (Bootstrap Aggregating)
  - Modelle werden unabhängig trainiert
  - Nutzung von Bootstrap-Sampling (Ziehen mit Zurücklegen)
  - Beispiel: Random Forest
- Boosting
  - Modelle werden sequentiell trainiert
  - Fokus auf Fehler vorheriger Modelle
  - Beispiele: XGBoost, AdaBoost, Gradient Boosting


# Random Forest

- Ensemble-Verfahren, das viele Entscheidungsbäume kombiniert
- Weniger interpretierbar als einzelne Bäume
- Größerer Rechenaufwand, aber parallelisierbar
- Bootstrap-Sampling (siehe Vorlesung Evaluierung)
  - Aus den Trainingsdaten werden mehrere Stichproben mit Zurücklegen gezogen.
  - Jeder Baum wird auf einer anderen Stichprobe trainiert.
- Zufällige Merkmalswahl
  - Für jeden Split wird nur eine zufällige Teilmenge der Attribute betrachtet, wodurch die Korrelation zwischen Bäumen reduziert wird.
- Mehrheitsentscheidung (Voting)
  - Klassifikation: die Klasse mit den meisten Stimmen aller Bäume gewinnt.
  - Regression: Mittelwert der Vorhersagen aller Bäume.
- Reduziert Overfitting


# Random Forest




# Decision Tree Visualisierungen



# Decision Tree Visualisierungen



Artwork by @allison\_horst (colors modified)






# Decision Tree Visualisierungen


dtreeviz

- Farbe = Klasse
- In jedem inneren Knoten wird ein Histogramm des Attributs dargestellt für die Datenpunkte, die diesen Knoten erreichen (also die Teilmenge nach vorherigen Splits).
- Blätter zeigen Klassen als Pie Chart



Bildquelle: <https://github.com/parrrt/dtreeviz>


# Decision Tree Visualisierungen



# Decision Tree Visualisierungen



## Baobab Tree

- Der gleiche Baum wie auf der Folie davor
- Breite Kanten = Datenmenge (Flow)
  - Wichtige Teile des Baums für den Datensatz werden hervorgehoben
- Farbe = Klassen
- Van Den Elzen, S., & Van Wijk, J. J. Baobabview: Interactive construction and analysis of decision trees. In *2011 IEEE conference on visual analytics science and technology (VAST)*




Bildquelle: <https://pypi.org/project/pybaobabdt/>

# Decision Tree Visualisierungen



# Decision Tree Visualisierungen



Sondag, M., Meinecke, C., Collaris, D., Von Landesberger, T., & Van Den Elzen, S. (2025). Cluster-Based Random Forest Visualization and Interpretation. *IEEE Transactions on Visualization and Computer Graphics*.