



UNIVERSITÄT
LEIPZIG

1. Vorlesung: Einführung

INTERACTIVE VISUAL DATA MINING


Organisation

- Vorlesung wird im Tandem mit der Informationsvisualisierung gehalten
- Das Praktikum nutzt Kenntnisse aus beiden Vorlesungen
- Alle Veranstaltungen sind in diesem Semester in präsenz
- Praktikum ist Prüfungsvorleistung
- Modulprüfung: Klausur 90 Minuten

Vorstellung

- Dr. Christofer Meinecke
- 2023 Dissertation
 - Visual Analytics for the Exploratory Analysis and Labeling of Cultural Data
- Anwendungsfelder
 - Digital Humanities
 - Kartographie
 - Kunstgeschichte
 - GLAM-Sektor (Galleries, Libraries, Archives, Museums)
 - Medizin & Biologie
- Forschungsinteressen
 - Informationsvisualisierung
 - Visual Analytics
 - Interactive Data Labeling
 - Guidance und Mixed-Initiative Systeme
 - Computer Vision
 - Objekterkennung & Segmentierung
 - Zero, Few-Shot Learning

Übersicht der Vorlesung



Übersicht der Vorlesung

07.4. Einführung
14.4. Data Mining & Datenaufbereitung
21.4. Entscheidungsbäume
28.4. Regression und Nearest Neighbor Klassifikation
05.5. Clustering
12.5. Dimensionsreduktion
19.5. **Kein Termin**
26.5. Evaluierung
02.6. Neuronale Netze 1
09.6. Voraussichtlich **kein Termin**
16.6. Support Vektor Maschine
23.6. Neuronale Netze 2
30.6. Vertiefung: Transformer?
07.7. Wiederholung

Übersicht

1. Einführung

- 1.1 Warum Datenvisualisierung?
- 1.2 DIW Pyramide
- 1.3 Data Science
- 1.4 Geschichte Datenvisualisierung
- 1.5 Visual Analytics Anwendungsfelder

Lernziele:

- Erklären, warum Datenvisualisierung notwendig ist und begründen, weshalb eine vollständig automatisierte Datenanalyse nicht ausreichend ist.
- Die DIW-Pyramide beschreiben und deren Bedeutung im Kontext der Datenanalyse erläutern.
- Den Begriff Data Science definieren und zentrale Aufgaben sowie Bestandteile benennen.
- Den Begriff Visual Analytics erklären, typische Anwendungsfelder und Herausforderungen anhand von Beispielen darstellen.

1.1 Warum Datenvisualisierung?

- Exploration
 - Suche in Daten
 - Analyse von Daten
 - Extraktion von Information, welche implizit in den Daten enthalten ist
 - Identifizieren von
 - Mustern
 - Strukturen
 - Trends
 - Beziehungen
 - Anomalitäten
 - Entdecken von neuen Informationen
- Automatisierter Ansatz
 - Statistik
 - Machine-Learning
 - Knowledge Discovery in Databases (KDD, Extraktion von „Wissen“ aus Datenbanken)
 - Data Mining
 - ...





1.1 Warum Datenvisualisierung?

- Wie verarbeitet man große Datensätze?
- Statistik!
 - Mittelwert?
 - Median?
 - Varianz?
 - Standardabweichung?
 - Korrelationen?

	A	B	C	D	E	F	G	H
1	away	away	bullseye	bullseye	circle	circle	dino	dino
2	32.3311102266	61.411101248	51.2038911373	83.3397766053	55.9930301513	79.2772636977	55.3846	97.1795
3	53.4214628807	26.1868803879	58.9744699018	85.499817612	50.0322537946	79.013071199	51.5385	96.0256
4	63.92020226	30.8321939163	51.8720726696	85.8297376348	51.2884586593	82.4359398425	46.1538	94.4872
5	70.2895057187	82.5336485877	48.1799307865	85.0451167372	51.1705368873	79.1652941091	42.8205	91.4103
6	34.1188302357	45.7345513203	41.6832004024	84.0179406019	44.3779145287	78.1646280036	40.7692	88.3333
7	67.6707164012	37.110947969	37.8904155015	82.5674929978	45.0102700721	77.8808631153	38.7179	84.8718
8	53.2591294055	97.4757710964	39.5489736947	80.812601774	48.559816719	78.7883706035	35.641	79.8718
9	63.5149808671	25.1000785788	39.6495738769	82.6645338713	42.1422682922	76.8806345544	33.0769	77.5641
10	67.9805388133	80.9571652197	34.7505970472	80.0110909897	41.0269715735	76.4095884613	28.9744	74.4872
11	67.3724659005	29.720400203	27.560835291	72.8478255927	34.5753090115	72.7248411845	26.1538	71.4103
12	15.5607495229	80.0656402858	24.6355399754	71.6107148256	31.1686007236	69.2454213193	23.0769	66.4103
13	71.7907676942	71.0654666627	20.9594648125	66.0414983826	32.6442540714	70.7325550334	22.3077	61.7949
14	70.2425464362	24.1095975542	20.6891490538	62.7213052064	26.6666456539	62.9809712052	22.3077	57.1795
15	64.9374355444	81.5542049945	19.2882047369	62.0630593582	26.4592623274	62.6346733709	23.3333	52.9487
16	62.2135245453	21.4758389969	20.0245005746	61.3426238695	25.5380076465	60.6302361093	25.8974	51.0256
17	67.2694004772	18.7089683725	35.4695229971	43.1158849517	26.3207111933	62.3962811186	29.4872	51.0256
18	40.5701970446	79.3729634752	36.8943276507	47.7065559687	26.1633874648	62.0268148985	32.8205	51.0256
19	74.7411813341	21.1016372041	39.0555497751	55.5469737131	25.2137904611	60.2733986018	35.3846	51.4103
20	71.7683189223	20.0110618423	46.9570801494	65.2404073935	26.8595295604	63.1418346727	40.2564	51.4103
21	76.1669198143	75.9361704048	37.3104527352	45.2587508999	31.7606691716	69.7976553936	44.1026	52.9487
22	65.6236574431	15.5828033531	40.0096720019	60.9865825077	39.7932905744	75.8079642168	46.6667	54.1026
23	50.8506336394	13.9876016304	48.0143866846	65.7128195934	45.6174391854	78.1199702277	50	55.2564
24	33.0240700249	24.4678303872	53.7037759268	66.3894820363	53.7714606827	79.3029316435	53.0769	55.641
25	39.7063261674	84.2752871038	63.0674998921	64.0350004581	56.4514336733	79.2471070208	56.6667	56.0256
26	45.5964849542	9.76334884943	62.0480325076	63.8458632494	66.0937201989	77.0178182606	59.2308	57.9487
27	42.9680469104	17.9454583961	59.8399667124	64.4767644437	56.9258394194	79.2063186226	61.2821	62.1795
28	52.4944067819	16.0511142003	55.1609418175	65.2373081694	58.9882538467	78.9172589554	61.5385	66.4103
29	46.0822757831	23.1104578154	61.2797865792	65.766402504	57.9022660533	79.0808678187	61.7949	69.1026
30	74.2477082092	20.314187812	60.8349175348	64.6037697063	64.8128669568	77.4869389235	57.4359	55.2564

1.1 Warum Datenvisualisierung?

- Welcher der Plots hat die folgenden Eigenschaften?
- Mittelwert
 - $x = 54,02$
 - $y = 48,09$
- Standardabweichung
 - $x = 14,52$
 - $y = 24,79$
- Pearson's $r +0,32$



1.1 Warum Datenvisualisierung?

– Welcher der Plots hat die folgenden Eigenschaften?

– Mittelwert

– $x = 54,02$

– $y = 48,09$





– Standardabweichung

– $x = 14,52$

– $y = 24,79$


– Pearson's $r +0,32$

—> Alle Plots haben diese Eigenschaften!




1.1 Warum Datenvisualisierung?

- Datasaurus dozen (Anscombosaurus)
- Matejka, J., & Fitzmaurice, G. (2017). Same Stats, Different Graphs: Generating Datasets with Varied Appearance and Identical Statistics through Simulated Annealing. Proceedings of the Conference on Human Factors in Computing Systems.



1.2 DIW Pyramide


- Daten, Information, Wissen Hierarchie
- Bekanntes Modell aus dem Bereich Wissensmanagement
- Pyramidenstufen bauen hierarchisch aufeinander auf
- Prozesse transformieren Elemente zwischen den Stufen



<https://de.wikipedia.org/wiki/Datei:Wissenspyramide.svg>

1.2 DIW Pyramide - Daten


- Daten:
 - Unterste Stufe der DIW Pyramide
 - Unstrukturiert / Strukturiert
 - Texte
 - Sensordaten
 - Bilder
 - Ton
 - Messreihen
 - Dienen als „Rohstoff“
 - Werte ohne Kontext und ohne Interpretation



<https://de.wikipedia.org/wiki/Datei:Wissenspyramide.svg>

1.2 DIW Pyramide - Informationen


- Informationen:
 - 2. Stufe der DIW Pyramide
 - Werden aus Daten gewonnen
 - Kontextualisierung durch: Strukturieren, Beschriften, Einordnen, Aggregieren
- Information gibt Daten:
 - Bedeutung
 - Sinn



<https://de.wikipedia.org/wiki/Datei:Wissenspyramide.svg>

1.2 DIW Pyramide - Wissen


- Wissen:
 - 3. Stufe der DIW Pyramide
 - Wissen entsteht aus Informationen
 - Verknüpfung von Informationen
 - Schlüsse aus den Informationen
 - Wissen kann nicht „gespeichert“ werden
 - Gespeichert werden nur Strukturen, die Wissen repräsentieren z. B. Modelle oder Graphen



<https://de.wikipedia.org/wiki/Datei:Wissenspyramide.svg>

1.3 Data Science


- Interdisziplinär: Statistik, Informatik, Machine Learning, Domänenwissen
- Ziel: Daten analysieren, Muster erkennen, Wissen ableiten
- Prozess:
 - Daten sammeln & aufbereiten
 - Analysieren & modellieren
 - Interpretieren & visualisieren
 - Wissen anwenden & Entscheidungen ableiten



https://miro.medium.com/max/1400/1*wnaGuiQ59w9zAkMgBugB9A.png

1.3 Data Science


- Data Science kombiniert Methoden aus anderen Bereichen
- Data Mining
- Machine Learning
- KI
- Neuronale Netze
- Big Data



https://miro.medium.com/max/1400/1*wnaGuiQ59w9zAkMgBugB9A.png

1.3 Data Science


- Data Mining:
 - Erkennen von Mustern in vorhandenen Daten
- Beispiele:
 - Multivariate Statistik
 - Dimensionsreduktionen
 - Clustering
 - Klassifikation und Regression
 - Zeitreihenanalysen



https://miro.medium.com/max/1400/1*wnaGuiQ59w9zAkMgBugB9A.png

1.3 Data Science


- Machine Learning:
 - Modelle erstellen, die Muster in Daten erkennen
 - Neue Daten klassifizieren oder vorhersagen
- Aufteilung in
 - Überwacht: Mit gelabelten Daten lernen
 - Unüberwacht: Muster ohne vorherige Labels erkennen
 - Andere Spezialfälle: Semi-überwacht, Selbstüberwacht, Bestärkendes Lernen



https://miro.medium.com/max/1400/1*wnaGuiQ59w9zAkMgBugB9A.png

1.3 Data Science


- Machine Learning:
 - Überwacht (Supervised):
 - Klassifikation & Regression
 - Decision Trees
 - Support Vector Machines
 - Klassische Neuronale Netze
 - Ensemble-Methoden (meistens)
 - Unüberwacht (Unsupervised):
 - Clustering
 - Dimensionsreduktion
 - Autoencoder
 - Anomalieerkennung
 - Hidden Markov Modelle



https://miro.medium.com/max/1400/1*wnaGuiQ59w9zAkMgBugB9A.png

1.3 Data Science


- Künstliche Neuronale Netze:
 - Biologisch inspirierte Netzstruktur aus Neuronen
 - Neuronen sind verbunden und können durch Input aktiviert werden
 - Aktivierung basiert auf Gewichtsfunktion
 - Iterativer Lernprozess der Gewichte
 - Trainingsphase notwendig



https://miro.medium.com/max/1400/1*wnaGuiQ59w9zAkMgBugB9A.png

1.3 Data Science

- Künstliche Intelligenz:
 - Nachahmung/Simulation von intelligentem Verhalten
- Unterscheidung KI
 - Schwache KI
 - Lösung für eine bestimmte Problemklasse
 - Starke KI
 - Generelles System ähnlich dem menschlichen Verstand (Theorie oder Sci-Fi)



https://miro.medium.com/max/1400/1*wnaGuiQ59w9zAkMgBugB9A.png

1.4 Geschichte Datenvisualisierung



Es gibt vier grundsätzliche Einflüsse auf die heutige Datenanalyse:

1. Formale Theorien der Statistik
2. Verbesserung der Computer- und Ausgabetechniken
3. Die große Menge von Daten in vielen Bereichen
4. Der Schwerpunkt auf Quantifizierung in vielen Bereichen

—> Tukey & Wilk: Data Analysis & Statistics (1966)

1.4 Geschichte Datenvisualisierung



„Exposition, das effektive Offenlegen der Daten zur Darstellung des Unerwarteten, ist für uns ein wesentlicher Teil der Datenanalyse“

„Es ist nicht klar, wie die Formlosigkeit und Flexibilität, die dem explorativen Charakter der Exposition angemessen ist, in jede der bisher vorgeschlagenen Strukturen der formalen Statistik integriert werden kann.“

Tukey & Wilk: Data Analysis & Statistics (1966)

1.4 Geschichte Datenvisualisierung



„Dementsprechend müssen Ansätze und Techniken so konstruiert werden, dass die Beteiligung des Menschen erleichtert wird.“

„Einige Implikationen für eine effektive Analyse sind:

1. Es ist unerlässlich die Interaktion von Personen und Zwischenergebnissen zu erleichtern und
2. An jedem Punkt der Datenanalyse müssen die Ergebnisse auf die Fähigkeiten der Person abgestimmt werden, die sie nutzt.“

Tukey & Wilk: Data Analysis & Statistics (1966)

1.4 Geschichte Datenvisualisierung

Prim-9


- Darstellung von multivariaten Daten
- Rotation
- Filter
- Suchbereiche



1972 Tukey, Fisherkeller, Friedman, PRIM-9


1.4 Geschichte Datenvisualisierung

- Semiology of Graphics
- Jacques Bertin (1967)
- theoretisches Grundlagenwerk der Informationsvisualisierung
- Grafische Variablen um Informationen darzustellen




1.4 Geschichte Datenvisualisierung

- Scatterplot Brushing
- Darstellung von verschiedenen Dimensionen eines Datensatz als Matrix von Streudiagrammen
- Auswahl eines Teilbereichs markiert den gewählten Bereich in allen Diagrammen
- Becker & Cleveland (1987)




1.4 Geschichte Datenvisualisierung

- Scatterplot Brushing
- Darstellung von verschiedenen Dimensionen eines Datensatz als Matrix von Streudiagrammen
- Auswahl eines Teilbereichs markiert den gewählten Bereich in allen Diagrammen
- Becker & Cleveland (1987)




1.4 Geschichte Datenvisualisierung


- APT: A Presentation Tool
- System, um automatisch Grafiken von Daten zu erstellen
- Regelbasiert
- Ordnet Inputvariablen nach Priorität
- Mackinlay (1986)



1.4 Geschichte Datenvisualisierung




1.4 Geschichte Datenvisualisierung





Der Einfluss anderer Wissenschaften auf die Visualisierung ist enorm!

1.4 Geschichte Datenvisualisierung






1.4 Geschichte Datenvisualisierung




1.5 Visual Analytics - Geschichte

- 2005: Illuminating the Path: The Research and Development Agenda for Visual Analytics
 - *The Science of analytical reasoning facilitated by interactive visual interfaces*
- 2008: Visual Data Mining: Theory, Techniques and Tools for Visual Analytics
- 2010: Mastering the Information Age Solving Problems with Visual Analytics
 - *Visual analytics combines automated analysis with interactive visualisations for an effective understanding, reasoning and decision making on the basis of very large and complex dataset*
- Seit 2011 eigene Konferenz (ab 2021 Teil von IEEE VIS)




1.5 Visual Analytics

- „Visual Analytics is an iterative process that involves information gathering, data reprocessing, knowledge representation, interaction and decision making.“ - Keim et al. (2008), Visual Analytics: Scope and Challenges, *Visual Data Mining* (Lecture Notes in Computer Science)



1.5 Visual Analytics

- Kopplung von Modell und Visualisierung, um Wissen zu generieren
- Änderung der Parameter des Modells haben auch Auswirkungen auf die Visualisierung (und umgekehrt)
- Feedbackloop zwischen den Datenquellen und dem Wissen
 - Iterative Verbesserung der Datenanalyse



1.5 Visual Analytics - Anwendungsfelder

- Physik und Astronomie
 - Flow Visualization
 - Fluid Dynamics
 - Molecular Dynamics
 - Nuklearwissenschaften
 - Astrophysik
- Datengröße:
 - Sloan Digital Sky Survey, 1TB pro Tag
 - Large Hadron Collider, 1 PB pro Tag
- Ingenieurwissenschaften
 - Flow Visualization
 - Luftwiderstand von Objekten
 - Luftbewegung in Verbrennungsmotoren
 - Crashsimulationen
 - Materialwissenschaften
 - Wie stabil ist ein Bauteil
 - Zerstörungsfreie Analyse
 - Biegeeffekte

1.5 Visual Analytics - Anwendungsfelder

- Umweltwissenschaften
 - Klima und Wetter
 - Messwerte von Wetterstationen und Satelliten
 - Mustererkennung in historischen Daten
 - Vorhersage
 - Simulation von Modellen
 - Identifikation von Einflüssen
- Datengröße:
 - TB pro Tag
- Beispiele:
 - Wettervorhersage
 - Hurricane Warnungen
- Krisen- und Notfallmanagement
 - Planung von Gegenmaßnahmen bei Naturkatastrophen:
 - Überflutungen
 - Vulkanausbrüche
 - Sturm
 - Epidemien
 - Erdbeben
 - Reaktionen auf gesellschaftliche Krisen:
 - Industrieunfälle
 - Große Verkehrsunfälle
 - Terror

1.5 Visual Analytics - Anwendungsfelder

- Textdaten
 - Digitale Editionen und Annotationen
 - Literaturanalyse
 - Bibliometrie
 - Social-Media-Diskurse
 - Themenentwicklung über Zeit
 - Autorschaftsanalyse
- Kulturelle Daten (Cultural Analytics)
 - Analyse und Exploration von Sammelungen
 - Historische Netzwerke
 - Provenienzforschung
 - Multimedia Analyse
 - Spatial Humanities z. B. literarische Schauplätze oder historische Reisebewegungen

1.5 Visual Analytics - Anwendungsfelder

- Biologie
 - Genomsequenzierung
 - Vorhersage von RNA Strukturen
 - Proteonomics
 - Metabolomics
 - Epigenetik
 - Evolution
- Medizin
 - Computertomographie
 - Ultraschallbilder
 - Pharmazie
 - Patientendaten
 - Therapien
- Datengröße variiert bis zu TB

1.5 Visual Analytics - Anwendungsfelder

- Wirtschaft
 - Finanzmärkte mit Aktien, Derivate, Zertifikaten, Fonds, etc
- Herausforderungen:
 - Analyse der Daten aus verschiedenen Perspektiven und Annahmen
 - Vergleich Vergangenheit und Gegenwart
 - Vorhersage und Erkennen von Mustern
- Beispiele:
 - Smartmoney
 - FinDEx System
- Explainable AI & Mixed Initiative
 - Modellinspektion
 - Feature- und Konzeptverständnis
 - Fehleranalyse von Modellen
 - Vergleich mehrerer Modelle
 - Bias- und Fairnessanalyse
 - Datenerstellung und –annotation
 - Interaktive Modellsteuerung
 - Guidance

1.5 Visual Analytics

– Herausforderungen

1. Problemidentifikation und Lösungsansatz
2. Nutzerakzeptanz
3. Evaluation
4. Darstellung von Zusammenhängen
5. Datenqualität und Unsicherheit
6. Data provenance
7. Datastreams - Echtzeitdaten
8. Datenvolume – Skalierung
9. Datenvielfalt / Heterogenität
10. Integration in andere Systeme